

(1)

Jednorozměrná lin. regrese

predk., že rozdělujíme dvě veličiny x a y mezi sebou i s. e.

lin. závislost

$$y = \beta_0 + \beta_1 x \quad \beta_0, \beta_1 \text{ "parametry"}$$

provede n experiment - zjistíme u hmoty dvojice (x, y)

části y mohou' x prakticky mít pravou' (x je rozdělen na jednotky dle' výšky)

zelená y ne mohou' s chybou

chyba může být závislá a y lze lze dvojici zjistit jinou
moh. vel. a lze lze mít y

pro dvojice $(x_1, y_1), \dots, (x_n, y_n)$ se zavede model

$$Y_i = \beta_0 + \beta_1 x_i + \varepsilon_i, \quad (*) \quad i = 1, \dots, n$$

holý:

- y_i - vyčítačové' (závislé') proměnné'

- x_i - vyčítačové' (nezávislé') proměnné'
prediktor, regresor

- β_0, β_1 - parametry regresní' funkce

- ε_i - náhodný člen, (moh. chyba)

lze lze považovat, že ε_i je náhodný člen, (moh. chyba) a $\varepsilon_i \sim (0, \sigma^2)$

Nm. $E \varepsilon_i = 0$, $Var(\varepsilon_i) = \sigma^2$ $\forall i$
(homoskedasticita)

mérešim základne dátka $(x_1, y_1), \dots, (x_n, y_n)$

(2)

a cílem st. analýzy je určit, zda model (*) je schopen

představovat pozorovanou variabilitu y

první krok: určit normativní parametry $\beta_0, \beta_1, \sigma^2$

(predsévání dat prvního)

$$\hat{y}_i = \hat{\beta}_0 + \hat{\beta}_1 x_i$$

a později $\hat{\beta}_0 \approx \beta_0$ až
normativní pozorované adekvátnost
modelu

predsévání dat prvního: nechť empirické, základní hodnoty
modelu vypočítané v. a když \hat{y}_i

z hlediska a priori ne'zřejmě pro sít vypočítané a ne β_0, β_1

Druhé možnosti:

1) odhadovat β_0, β_1 pomocí metody nejmenších kvadrátů

2) užítelnost výrobkových předpokladů o rozdělení chyb,
odhadovat β_0, β_1 a potom ověřit předpoklady

Pozn.: Spec. důležitý případ je $e_i \sim N(0, \sigma^2)$ je-li uváděno

základní MLE odhadovat β_0, β_1 nestože na metodu nejmenších čtverců,
alež může být použit i když oblast ne rozděluje chyby

Oberhalb parameter

a) grundannahme, seien x_1, \dots, x_m i.i.d. $N(0, \sigma^2)$

Mer. $y_i \sim N(\beta_0 + \beta_1 x_i, \sigma^2) \Rightarrow y_1, \dots, y_m$ unabhängig

$$\text{Eq.: } \beta_0 + \beta_1 x_i = y_i \quad \text{mit der} \\ \text{+ allgemeine' Forme'}$$

MLB obere

$$\text{wir. Fre.: } L = L(\beta_0, \beta_1, \sigma^2) = \left(\frac{1}{\sqrt{2\pi\sigma^2}} \right)^m e^{-\frac{1}{2\sigma^2} \sum_{i=1}^m (\gamma_i - \beta_0 - \beta_1 x_i)^2}$$

$$l = \ln L = -\frac{m}{2} \ln 2\pi - \frac{m}{2} \ln \sigma^2 - \frac{1}{2\sigma^2} \sum_{i=1}^m (\gamma_i - \beta_0 - \beta_1 x_i)^2$$

für $\sigma^2 > 0$ je maximieren $l \Leftrightarrow$ minimieren S

$$\underline{S} = S(\beta_0, \beta_1) = \sum_{i=1}^m (\gamma_i - \beta_0 - \beta_1 x_i)^2$$

prob. methode
najmenší čívera

$$\frac{\partial S}{\partial \beta_0} = -2 \sum_{i=1}^m (\gamma_i - \beta_0 - \beta_1 x_i) = 0$$

$$\frac{\partial S}{\partial \beta_1} = -2 \sum_{i=1}^m (\gamma_i - \beta_0 - \beta_1 x_i) x_i = 0$$

1. nachie: $\sum_{i=1}^m \gamma_i - \beta_1 \sum x_i = m \beta_0 \Rightarrow \underline{\beta_0} = \frac{1}{m} \sum \gamma_i - \beta_1 \frac{1}{m} \sum x_i =$
 $\qquad\qquad\qquad = \bar{y}_m - \beta_1 \bar{x}_m$

2. nachie: $\sum \gamma_i x_i - \beta_0 \sum x_i - \beta_1 \sum x_i^2 = 0$

$$\sum \gamma_i x_i - \bar{y} \sum x_i + \beta_1 \bar{x} \sum x_i - \beta_1 \sum x_i^2 = 0$$

(4)

$$\hat{\beta}_1 = \frac{\sum_{i=1}^n x_i y_i - n \bar{x} \bar{y}}{\sum x_i^2 - n \bar{x}^2} \quad \hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}$$

odhad σ^2 :

$$\frac{\partial L}{\partial \sigma^2} = -\frac{n}{2} \cdot \frac{1}{\sigma^2} + \frac{1}{2(\sigma^2)^2} \sum_{i=1}^n (y_i - \beta_0 - \beta_1 x_i)^2 = 0$$

c když $\frac{\hat{\sigma}^2}{\sigma^2} = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{\beta}_0 - \hat{\beta}_1 x_i)^2 = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2 = \frac{1}{n} SSE$

lze $\hat{y}_i = \hat{\beta}_0 + \hat{\beta}_1 x_i$ je „prediktivní“ model

odhad $E[y_i]$ sum of
the squares
of errors

možnost $\hat{e}_i = y_i - \hat{y}_i$ i-th residual

velikost residiu' indikuje, jak dobré odhadnuté príkazy odpadí dobu

residiu' jinou vlastností odhadu e_i , než může být
významnou roli v ověření předpohledu: rovnosti' chyb

Pozn: pro odhad σ^2 je používáno častoji statistické

$$\frac{s^2}{\sigma^2} = \frac{1}{n-2} \sum_{i=1}^n (y_i - \hat{y}_i)^2 = \frac{1}{n-2} SSE$$

Stav' je nezávislý na odhadu σ^2 (pro lib. rovnosti' e_i)
začíná σ_{true}^2 je významný odhad - pro normální rovnosti' chyb

odhad σ : $s = \sqrt{\frac{1}{n-2} \sum (y_i - \hat{y}_i)^2}$

standardní chyba regrese
(standard error)
men' nezávislost'

(5)

b) bez počítání normativních chyb

poz. e_1, \dots, e_n nezávislé, $e_i \sim (0, \sigma^2)$

pro odhad β_0, β_1 lze použít minimizaci S

což je rozumná procedure, když je mezdovina závisející na výrobku

interpretaci

nestříďací $y = \beta_0 + \beta_1 x$ je novice nějakého průmyslu

pohromadě $y_{ij} - (\beta_0 + \beta_1 x_{ij})$ je vertikální vzdálenost

medzi (x_{ij}, y_{ij}) od průmyslu a

$$S = \sum_{i=1}^n (y_{ij} - \beta_0 - \beta_1 x_{ij})^2$$

je méně, že dala průmyslu

problematické data

dále můžete využít lehovou průměr, tedy minimizaci S

minimizaci S vzhledem k obecnému obdržet $\hat{\beta}_0, \hat{\beta}_1$ jde o MLE pro

normativní data

tedy neale nejvíce least squares estimation (LSE)

obdržet met. nejjednodušší číselnou

číselnou vše méně vlastnosti průmyslu

použití LSE pro lib. vlastnostech chyb méně důležitostné:

1) pro normativní ~~data~~ chyb LSE vypadá n MLE

2) LSE obdržel je noví BLUE (best linear unbiased estimator)

jeho vlastnosti ~ Gauss-Markov theorem

(6)

Fr. reell x_1, \dots, x_m jün i.i.d. \rightarrow buntan

$$f(\varepsilon) = \frac{1}{2} e^{-|\varepsilon|} \quad (\text{Laplace dist. double exponential})$$

posten buntan $y_i = \gamma$

$$f_{y_i}(\gamma_i) = \frac{1}{2} e^{-|\gamma_i - \beta_0 - \beta_1 x_i|}$$

$$\text{a mér. fü } L = \frac{1}{2^m} e^{-\sum_{i=1}^m |\gamma_i - \beta_0 - \beta_1 x_i|}$$

$$\ell = -m \log 2 - \sum_{i=1}^m |\gamma_i - \beta_0 - \beta_1 x_i|$$

MLE par. β_0, β_1 dohmenen minimizion'

$$A = \frac{\sum_{i=1}^m |\gamma_i - \beta_0 - \beta_1 x_i|}{MAD}$$

minimum absolute deviations

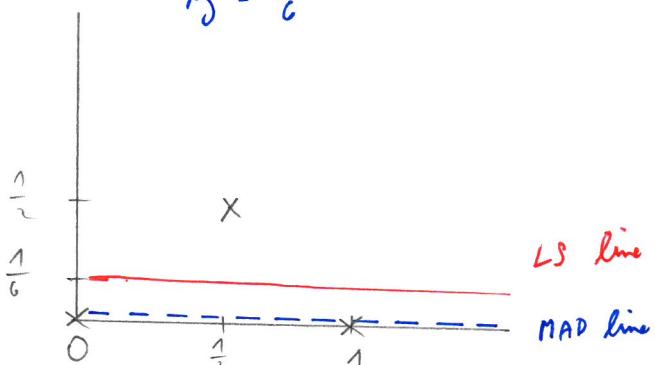
orthogonal buntan jün nci LSE

mozzime \rightarrow bunt: $(0,0), (1,0), (\frac{1}{2}, \frac{1}{2})$

$$\text{MLE: } \hat{\beta}_0 = \hat{\beta}_1 = 0 \quad A = \frac{1}{2} \quad \hat{\gamma} = 0$$

$$\text{LSE: } \bar{x} = \frac{1}{2} \quad \bar{y} = \frac{1}{6} \quad \sum x_i^2 = \frac{5}{4} \quad \sum x_i y_i = \frac{1}{4} \quad \hat{\beta}_1 = \frac{\frac{1}{4} - 3 \cdot \frac{1}{2} \cdot \frac{1}{6}}{\frac{5}{4} - 3 \cdot \frac{1}{4}} = 0$$

$$\hat{\gamma} = \frac{1}{6} \quad \hat{\beta}_0 = \frac{1}{6}$$



PoZN: (prakt. Orf) $\hat{\sigma}^2$ ist der Varianzschätzer von σ^2
 $\hat{\sigma}^2$ ist orthogonal zu $\hat{\sigma}^2$?

Ist die obige 'orthogonalität' (orthogonalität) richtig, nicht

$$\hat{\sigma}^2 \text{ varianzschätzer von } \sigma^2 \Rightarrow E\hat{\sigma}^2 \leq \sigma^2$$

ausreißerfreie m. a. d. X für Stern $\text{Var} X < +\infty$

$$E\hat{\sigma}^2 = \text{Var} X + (EX)^2 \quad \text{dann kann } X = \lambda \text{ durchfahren}$$

$$\begin{aligned} E\hat{\sigma}^2 &= \text{Var} \lambda + (E\lambda)^2 \\ &\stackrel{||}{=} (E\lambda)^2 \leq \sigma^2 \quad E\lambda \leq \sigma \end{aligned}$$

a normal multivariate $\Leftrightarrow \text{Var} \lambda = 0$

Rezip. für normalen chlby ist $\hat{\sigma}^2 \propto x^2 \Rightarrow E\hat{\sigma}^2 < \sigma^2$

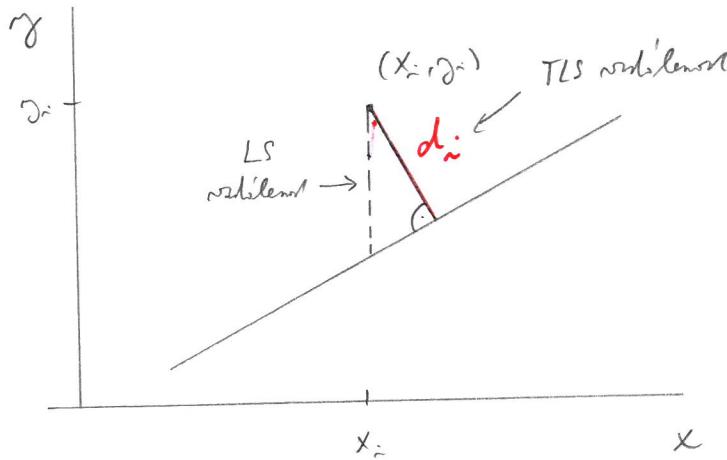
PoZN: prädikt. givne, reihe x_i givne dann prädikt., cui reman' bzgl.
 nicht prädikt.

Wora die Relativität (x_i) givne werden, neprädict.

→ EIV models "errors in variable"

→ Testt modelled givne z. B. prädikt. givne' orthog. zur LSE

populärer methode: total least squares (orthogonal least squares)



minimierung $\sum_{i=1}^n d_i^2$

neuprädict. Relativität x ,
 alle prädikt. $\lambda x_i = y$
 zusammen

Pozn: v literatuře se někdy x nazývá jiné realizace měr. vel. (ne vždy x x nazývají prediktorem nebo xi jimi dene' (třeba poklum' - jin model me' poklum' bude)

$$E(Y_i | X_i) = \beta_0 + \beta_1 X_i \quad \text{Var}(Y_i | X_i) = \sigma^2$$

pro většinu výsledků prezentovaných v této přednášce ale nem' 'podobné', zatím co x charakterizují jeho pravděpodobnost

Díky tomu výsledky o podmíněném výrazu (E , Var , ...) jsou dene' hodnoty x místu napomínený.

Nicméně věta' používá si třeba u odvozování asymptotického rozdělení' odhadu.

Nearsteur orthoestri: $\hat{\beta}_0, \hat{\beta}_1, \hat{\sigma}^2$

(9)

Wet: Neutre $\hat{\beta}_0, \hat{\beta}_1$ zijn LSE per. β_0, β_1 o.v. lin. modelen

$$Y_i = \beta_0 + \beta_1 x_i + \epsilon_i, \quad i=1, \dots, n,$$

hier ϵ_i zijn 'residu' 'orthogone' verandering (perhaal' meehorend) o.v. steegijn resulyten σ^2 . Onder plot'

$$1) \quad E(\hat{\beta}_1) = \beta_1, \quad E(\hat{\beta}_0) = \beta_0 \quad (\text{nearsteur orthoestri})$$

$$2) \quad \text{Var}(\hat{\beta}_1) = \frac{\sigma^2}{S_{xx}}, \quad \text{hier} \quad S_{xx} = \sum_{i=1}^n (x_i - \bar{x})^2$$

$$3) \quad \text{Var}(\hat{\beta}_0) = \sigma^2 \left(\frac{1}{n} + \frac{\bar{x}_m^2}{S_{xx}} \right)$$

4) postuur model plot' $\epsilon_i \sim N(0, \sigma^2)$, $i=1, \dots, n$, volgen

$$\hat{\beta}_{\hat{j}} \sim N(\beta_{\hat{j}}, \text{Var}(\hat{\beta}_{\hat{j}})), \quad \hat{j} = 0, 1.$$

DL: 1) opvinden $\hat{\beta}_1$:

$$\hat{\beta}_1 = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^n (x_i - \bar{x})^2} = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^n (x_i - \bar{x})^2} =$$

$$= \frac{1}{S_{xx}} \cdot \left(\sum_{i=1}^n (x_i - \bar{x}) y_i - \underbrace{\bar{y} \sum_{i=1}^n (x_i - \bar{x})}_{= \sum_{i=1}^n x_i - n \bar{x}} \right) =$$

$$= \frac{1}{S_{xx}} \sum_{i=1}^n (x_i - \bar{x}) y_i$$

(10)

$$E(\hat{\beta}_1) = E\left(\frac{1}{S_{xx}} \sum_{i=1}^n (x_i - \bar{x}) y_i\right) = \frac{1}{S_{xx}} \sum_{i=1}^n (x_i - \bar{x}) E y_i$$

$$= \frac{1}{S_{xx}} \sum_{i=1}^n (x_i - \bar{x}) (\beta_0 + \beta_1 x_i) = \underbrace{\frac{\beta_0}{S_{xx}} \sum_{i=1}^n (x_i - \bar{x})}_{=0} + \underbrace{\frac{\beta_1}{S_{xx}} \sum_{i=1}^n (x_i - \bar{x}) x_i}_{= S_{xx}}$$

$$\underline{\underline{\beta_1}}$$

$$\sum (x_i - \bar{x})(x_i - \bar{x}) \\ = \sum (x_i - \bar{x}) x_i + 0$$

$$E(\hat{\beta}_0) = E(\bar{y} - \hat{\beta}_1 \bar{x}) = E\bar{y} - \bar{x} E \hat{\beta}_1 =$$

$$= \frac{1}{n} \sum_{i=1}^n E y_i - \bar{x} \beta_1 = \beta_0 + \frac{\beta_1}{n} \sum x_i - \bar{x} \beta_1 = \underline{\beta_0}$$

$$= \beta_0 + \beta_1 x_i$$

$$2) \quad \text{Var}(\hat{\beta}_1) = \text{Var}\left(\frac{1}{S_{xx}} \sum_{i=1}^n (x_i - \bar{x}) y_i\right) = \frac{1}{S_{xx}^2} \sum_{i=1}^n (x_i - \bar{x})^2 \text{Var} y_i$$

$$= \frac{\sigma^2 S_{xx}}{S_{xx}^2} = \frac{\sigma^2}{S_{xx}}$$

$$3) \quad \text{Var}(\hat{\beta}_0) = \text{Var}(\bar{y} - \hat{\beta}_1 \bar{x}) = \text{Var} \bar{y} + \bar{x}^2 \text{Var} \hat{\beta}_1 - 2 \bar{x} \text{cov}(\bar{y}, \hat{\beta}_1)$$

$$= \frac{\sigma^2}{n} + \frac{\bar{x}^2 \sigma^2}{S_{xx}} - 2 \bar{x} \underbrace{\text{cov}(\bar{y}, \hat{\beta}_1)}_{=0 \text{ da } \hat{\beta}_1 \text{ unabh.}} \\$$

$$\text{cov}(\bar{y}, \hat{\beta}_1) = \text{cov}\left[\bar{y}, \frac{1}{S_{xx}} \sum_{i=1}^n (x_i - \bar{x}) y_i\right] = \frac{1}{S_{xx}} \sum_{i=1}^n (x_i - \bar{x}) \text{cov}(\bar{y}, y_i)$$

$$\text{cov}(\bar{y}, y_i) = \text{cov}\left(\frac{1}{n} \sum_{j=1}^n y_j, y_i\right) = \frac{1}{n} \sum_{j=1}^n \underbrace{\text{cov}(y_j, y_i)}_{=0 \text{ } i \neq j} = \frac{1}{n} \text{cov}(y_i, y_i) = \frac{\sigma^2}{n}$$

$$\Rightarrow \text{cov}(\bar{y}, \hat{\beta}_1) = 0 = \frac{\sigma^2}{n S_{xx}} \sum_{i=1}^n (x_i - \bar{x}) \\ = 0$$

$$4) \text{ proto } \hat{\beta}_1 = \frac{1}{S_{xx}} \sum_{i=1}^n (x_i - \bar{x}) y_i$$

$$\hat{\beta}_0 = \frac{1}{n} \sum_{i=1}^n y_i - \hat{\beta}_1 \bar{x}_n$$

(11)

je $\hat{\beta}_0 \approx \hat{\beta}_1$ LK nezávislý mimořádně mal. vel. y_i

\Rightarrow mož' mimořádní rozdíly, E a Var jsou správné

Q.E.D.

Nálež: Ze předchozího ještě ještě

$$\underline{E(\sigma_m^2) = \sigma^2}. \quad (\hat{\sigma}_m^2 \text{ je neštější odhad } \sigma^2)$$

Důk:

$$E(\sigma_m^2) = \frac{1}{n-2} E \sum_{i=1}^n (y_i - \hat{y}_i)^2 = \frac{1}{n-2} \underbrace{\sum_{i=1}^n E(y_i - \hat{y}_i)^2}_A$$

$$\text{proto } E(\hat{y}_i) = E(\hat{\beta}_0 + \hat{\beta}_1 x_i) = \beta_0 + \beta_1 x_i = E y_i$$

$$\text{tak, má } \underline{E(y_i - \hat{y}_i)^2 = \text{Var}(y_i - \hat{y}_i)}$$

$$E(y_i - \hat{y}_i)^2 = \left(E(y_i) - \hat{y}_i \right)^2$$

$$A = \sum_{i=1}^n \text{Var}(y_i - \hat{y}_i) = \sum_{i=1}^n \left[\text{Var}(y_i) + \text{Var}(\hat{y}_i) - 2 \text{Cov}(y_i, \hat{y}_i) \right]$$

$$= n\sigma^2 + \sum_{i=1}^n \text{Var}(\hat{y}_i) - 2 \sum_{i=1}^n \text{Cov}(y_i, \hat{y}_i) \quad (\#)$$

$$\text{Var} \hat{y}_i = \text{Var}(\hat{\beta}_0 + \hat{\beta}_1 x_i) = \text{Var} \hat{\beta}_0 + x_i^2 \text{Var} \hat{\beta}_1 + 2 x_i \text{Cov}(\hat{\beta}_0, \hat{\beta}_1)$$

$$\text{Cov}(\hat{\beta}_0, \hat{\beta}_1) = \text{Cov}(\bar{y} - \hat{\beta}_0 \bar{x}, \hat{\beta}_1) = \underbrace{\text{Cov}(\bar{y}, \hat{\beta}_1)}_{= 0 \text{ v.r. důvěr.}} - \bar{x} \text{Var}(\hat{\beta}_1) = - \frac{\sigma^2 \bar{x}}{S_{xx}}$$

a rocky

$$\text{Var} \hat{y}_i = \sigma^2 \left[\frac{1}{n} + \frac{\bar{x}_m^2}{s_{xx}} + x_i^2 \frac{1}{s_{xx}} - \frac{2x_i \bar{x}_m}{s_{xx}} \right] = \sigma^2 \left[\frac{1}{n} + \frac{(x_i - \bar{x}_m)^2}{s_{xx}} \right]$$

$$\text{a } \sum_{i=1}^m \hat{\text{Var}} x_i = \sigma^2 + \frac{\sigma^2}{S_{xx}} \underbrace{\sum_{i=1}^m (x_i - \bar{x})^2}_{= S_{xx}} = 2\sigma^2$$

$$\text{Cov}(\hat{Y}_n, \hat{q}_n) = \text{Cov}(Y_n, \hat{\beta}_0 + \hat{\beta}_1 x_n) = \text{Cov}(Y_n, \hat{\beta}_0) + x_n \text{Cov}(Y_n, \hat{\beta}_1)$$

$$\text{Cov}(y_i, \hat{\beta}_1) = \frac{1}{S_{xx}} \sum_{j=1}^n (x_j - \bar{x}) \text{Cov}(y_j, y_i) = \frac{\sigma^2(x_i - \bar{x})}{S_{xx}}$$

||
 0 $i \neq j$

$$\text{Cov}(\hat{\gamma}_n, \hat{\beta}_0) = \text{Cov}(\hat{\gamma}_n, \bar{\hat{\gamma}}_n - \bar{x}_n \hat{\beta}_1) = \text{Cov}(\hat{\gamma}_n, \bar{\hat{\gamma}}_n) - \bar{x}_n \text{Cov}(\hat{\gamma}_n, \hat{\beta}_1)$$

$$= \frac{\sigma^2}{n} - \frac{\bar{x}_m^2 \sigma^2 (x_i - \bar{x}_m)}{S_{xx}}$$

$$\text{a.t. } \text{Cov}(\hat{y}_i, \hat{y}_j) = \frac{\sigma^2}{n} - \frac{\bar{x}_i \sigma^2 (x_i - \bar{x})}{s_{xx}} + \frac{\sigma^2 x_i (x_i - \bar{x})}{s_{xx}}$$

$$= \frac{\sigma^2}{n} + \frac{\sigma^2}{S_{xx}} \left(x_i - \bar{x}_n \right)^2$$

$$\sum_{i=1}^n \text{Cov}(y_i, \hat{y}_i) = \sigma^2 + \frac{\sigma^2}{S_{xx}} \sum_{i=1}^n (x_i - \bar{x})^2 = \underline{2\sigma^2}$$

dorsum do (#)

$$A = n\sigma^2 + 2\sigma^2 - 4\sigma^2 = (n-2)\sigma^2$$

$$\text{cellular} \quad E(n_m^2) = \frac{1}{m-2} A = \pi r^2.$$

Q.E.D.

(13)

Tvorze!: Nechť pak' předpoklady sítý 1 a nechť
 e_1, \dots, e_m i.i.d. $N(0, \sigma^2)$. Pak' pak' :

$$a) \frac{\frac{(m-2) \hat{\beta}_m^2}{\sigma^2}}{\sim \chi^2(m-2)}$$

b) $\hat{\beta}_m^2$ je rozložitelný mezi $\hat{\beta}_0$ a $\hat{\beta}_n$

tl: myšlenka je obecnější tvorze' pro víceměřní regresi

Pozn: Moretti jiné

$$\text{Var}(\hat{\beta}_0) = \sigma^2 \left[\frac{1}{m} + \frac{\bar{x}_m^2}{S_{xx}} \right] \quad \text{Var}(\hat{\beta}_n) = \frac{\sigma^2}{S_{xx}}$$

\parallel var
 $\hat{\sigma}^2(\hat{\beta}_0)$ $\hat{\sigma}^2(\hat{\beta}_n)$

nestandardní odhady jinou:

$$\hat{\sigma}^2(\hat{\beta}_0) = \hat{\beta}_m^2 \left[\frac{1}{m} + \frac{\bar{x}_m^2}{S_{xx}} \right] = \hat{\beta}_m^2 \sigma_0^2$$

$$\hat{\sigma}^2(\hat{\beta}_n) = \frac{\hat{\beta}_m^2}{S_{xx}} = \hat{\beta}_m^2 \sigma_n^2 \quad \swarrow \quad (\text{nestandardní množstviční faktory})$$

odhad nestandardních odhadů rel. $\hat{\beta}_0, \hat{\beta}_n$ až jin

$$\hat{\sigma}(\hat{\beta}_0) = \hat{\beta}_m \sqrt{\sigma_0^2} \quad \text{a} \quad \hat{\sigma}(\hat{\beta}_n) = \hat{\beta}_m \sqrt{\sigma_n^2}$$

standardní chybky odhadů $\hat{\beta}_0, \hat{\beta}_n$

bez' závislosti naži půjčeného je a TH.

Gauss - Markov theorem

(14)

- „chťo normáln“ \Rightarrow LSE pro $\hat{\beta}_0, \hat{\beta}_1$ je MLE těch parametrů
(eficientní vždy)
- pokud nějaký normální, záleží na opatrnosti pro použití LSE?
jisté, že LSE jsou BLUE (best linear unbiased estimators)
tedy normální vždy $\xrightarrow{\text{lin.}}$ minimální rozdíl
- je ale třeba poznamenat, že mimo ex. relineární mívají
rozdílné vzhledy pro β_0, β_1 , které jsou eficientní
ne-LSE, pokud se normální chťe lin. využije od
normálních (tzn. v závislosti robustní regresní analýz)

Naučujeme model

$$Y_i = \beta_0 + \beta_1 x_i + \varepsilon_i, \quad i = 1, \dots, n \quad (*)$$

Def: Lineární vzhled parametrů β_0, β_1 je statistické

termín $\hat{\beta}_1 = \sum_{i=1}^n c_i Y_i$,

kde c_i jsou dané reálné konstanty, ($i = 1, \dots, n$)

Věta (Gauss - Markov): Neži $\varepsilon_1, \dots, \varepsilon_n$ jsou normální (*)

jsou nezávislé a mají stejný rozdíl $\text{Var}(\varepsilon_i) = \sigma^2$, $i = 1, \dots, n$.

Takže LSE $\hat{\beta}_j$ ($j = 0, 1$) je BLUE parametrů β_j .

DR: unbekannt pro β_1 , pro β_0 ist daher 'restlos'

$$\text{meist } \hat{\beta}_1 = \sum_{i=1}^m c_i y_i, \quad \text{f\"ur}$$

$$\text{Var } \hat{\beta}_1 = \sum_{i=1}^m c_i^2 \text{Var } y_i = \sigma^2 \sum_{i=1}^m c_i^2$$

\uparrow unbekannt y_i \downarrow muss noch

also ist $\hat{\beta}_1$ unbekannt, man' geht $E \hat{\beta}_1 = \beta_1$, test

$$E \hat{\beta}_1 = \sum_{i=1}^m c_i E y_i = \beta_0 \underbrace{\sum_{i=1}^m c_i}_{=} + \beta_1 \sum_{i=1}^m c_i x_i = \beta_1$$

$$= \beta_0 + \beta_1 x_i$$

potr\"at zu man' geht für lib. β_0, β_1 darin

$$\underbrace{\sum_{i=1}^m c_i = 0}_{=} \quad \text{und} \quad \underbrace{\sum_{i=1}^m c_i x_i = 1}_{=}$$

gleichzeitig, man' möchte erhalten β_1 & testy restlos

man' minimiert $\sum_{i=1}^m c_i^2$ ^{restlos} zu $\sum c_i = 0$ $\sum c_i x_i = 1$

Lagrange'sche Forme: $L = \sum_{i=1}^m c_i^2 - 2\lambda_1 (\sum_{i=1}^m c_i) - 2\lambda_2 (\sum_{i=1}^m c_i x_i - 1)$

$$\frac{\partial L}{\partial c_i} = 2c_i - 2\lambda_1 - 2\lambda_2 x_i = 0 \quad i = 1, \dots, m$$

$$\frac{\partial L}{\partial \lambda_1} = -2 (\sum c_i) = 0$$

$$\frac{\partial L}{\partial \lambda_2} = -2 (\sum c_i x_i - 1) = 0$$

system przed n równie

(16)

$$\underbrace{\sum_{i=1}^m c_i}_{=0} - \lambda_1 - \lambda_2 \sum_{i=1}^m x_i = 0 \Rightarrow \underline{\lambda_1 + \lambda_2 \sum x_i = 0}$$

system przed n równie wyznacz x_i

↓

$$\underline{\lambda_1 = -\lambda_2 \bar{x}_n}$$

$$\underbrace{\sum_{i=1}^m c_i x_i}_{=1} - \lambda_1 \sum x_i - \lambda_2 \sum x_i^2 = 0$$
$$\Rightarrow \underline{\lambda_1 \sum x_i + \lambda_2 \sum x_i^2 = 1}$$

$$-\lambda_2 \bar{x}_n \cdot m \bar{x}_n + \lambda_2 \sum x_i^2 = 1$$

$$\lambda_2 (\underbrace{\sum x_i^2 - m \bar{x}^2}_{= S_{xx}}) = 1 \Rightarrow \underline{\lambda_2 = \frac{1}{S_{xx}}}$$
$$\underline{\lambda_1 = -\frac{\bar{x}_n}{S_{xx}}}$$

dowolne λ_1, λ_2

$$c_i + \frac{\bar{x}_n}{S_{xx}} - \frac{x_i}{S_{xx}} = 0 \Rightarrow \underline{c_i = \frac{x_i - \bar{x}_n}{S_{xx}}}$$

a $\hat{\beta}_1 = \frac{1}{S_{xx}} \sum_{i=1}^m (x_i - \bar{x}_n) y_i$ w⁻zi LSE .

Pozn: aby jasne parze, aby mogły stać się
aby był nam \sim minimum wariancji \sim obecnych mit
w 'wicewspom' regresie .

IS pro β_0, β_1

(17)

- IS "předpog" ještě méně pěnovat' vlastností odkazů.
- pro jejich použití potřebujeme mít rozdělení f. vlastních odkazů
- dostatek řady možností možných chyb
- Možnost IS ne ale často používají - když rozdělení chyb není normální, ještě použijí se relativně málo,
- že LSE odkazy par. B jsou lineární funkce $y_i, i=1, \dots, n$ až umožňuje aplikaci CLT a dostatek asymptotické normálních odkazů $\hat{\beta}_0, \hat{\beta}_1$.

možné model $y_i = \beta_0 + \beta_1 x_i + \varepsilon_i, \quad \varepsilon_i \text{ i.i.d. } N(0, \sigma^2)$

není $\hat{\beta}_i \sim N(\beta_i, \hat{\sigma}^2(\hat{\beta}_i)), \quad \frac{(n-2) \hat{\sigma}_m^2}{\sigma^2} \sim \chi^2(n-1)$
 a názorně m. $\hat{\beta}_0, \hat{\beta}_1$

PořN: $X \sim N(0, 1), \quad Y \sim \chi^2(n), \quad X, Y \text{ nez.} \Rightarrow \frac{X}{\sqrt{\frac{Y}{n}}} \sim A(n)$

Nechy

$$T_i = \frac{\frac{\hat{\beta}_i - \beta_i}{\sigma(\hat{\beta}_i)}}{\frac{\hat{\sigma}_m}{\sigma}} = \frac{\frac{\hat{\beta}_i - \beta_i}{\hat{\sigma}(\hat{\beta}_i)}}{\frac{\hat{\sigma}_m}{\sigma}} \sim A(n-2), \quad i=0, 1$$

málo $\sigma(\hat{\beta}_i) = \sigma \sqrt{\hat{\sigma}_i}, \quad \hat{\sigma}(\hat{\beta}_i) = \hat{\sigma}_m \sqrt{\hat{\sigma}_i}.$

$$\text{Mon. } P \left[-L_{1-\frac{\alpha}{2}}(m-2) \leq \frac{\hat{\beta}_n - \beta_n}{\hat{\sigma}(\hat{\beta}_n)} \leq L_{1-\frac{\alpha}{2}}(m-2) \right] = 1-\alpha$$

a výslednému $\hat{\beta}_n$ dostaneme

$$P \left[\hat{\beta}_n - L_{1-\frac{\alpha}{2}}(m-2) \hat{\sigma}(\hat{\beta}_n) \leq \hat{\beta}_n \leq \hat{\beta}_n + L_{1-\frac{\alpha}{2}}(m-2) \hat{\sigma}(\hat{\beta}_n) \right] = 1-\alpha$$

a tedy

$$\underline{\left(\hat{\beta}_n \pm L_{1-\frac{\alpha}{2}}(m-2) \hat{\sigma}(\hat{\beta}_n) \right)} \quad \text{j. } 100(1-\alpha)\% \text{ IS pro } \beta_n$$

$n=0,1$

dostaneme se $\hat{\sigma}(\hat{\beta}_n)$ dostaneme:

$$\underline{100(1-\alpha)\% \text{ IS pro } \beta_0:} \quad \left(\hat{\beta}_0 \pm L_{1-\frac{\alpha}{2}}(m-2) \cdot \hat{\sigma}_m \sqrt{\frac{1}{m} + \frac{\bar{x}_m^2}{S_{xx}}} \right)$$

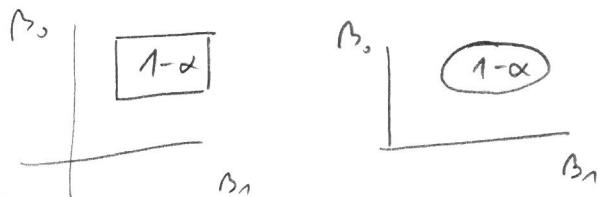
$$\underline{100(1-\alpha)\% \text{ IS pro } \beta_1:} \quad \left(\hat{\beta}_1 \pm L_{1-\frac{\alpha}{2}}(m-2) \hat{\sigma}_m \frac{1}{\sqrt{S_{xx}}} \right)$$

Pozn: ne každý IS je pravý, jež IS pro β_0
ještě ne může prohlížet jiného než IS pro β_1

Mon. Monika je obecně ovládatel s měšáčkem
než absolvent člen (intercept).

Oz.: —

Pozn: metoda se konstruuje simulacemi IS pro oba parametry



minimální počet obzorů v mimořádné regrese

TH pro β_0, β_1

(13)

chli bychom ovět' plnomoř předpohledu lin. rovnice mezi

$$x = \gamma$$

předpohledem $y = \gamma$, kdy model je lineární a x je jistý
doklady "ognětluží" proměna'

doklady je, že x a y jsou mezi ognětluží variability a že

člene když ~~obecně~~ ~~obecně~~

rozhodnout mezi dvěma možnostmi:

$$\underline{Y_i = \beta_0 + \epsilon_i} \quad \text{a} \quad \underline{Y_i = \beta_0 + \beta_1 x_i + \epsilon_i}$$

Prv. odkročit hypotéza $H_0: \beta_1 = 0$ \times $H_1: \beta_1 \neq 0$

plnomoř rozdílnéme H_0 , když lze, že x neognětluží
mezi y variability a nemá mezi ognětluží
ognětluží

rozdílnéme H_1 , když x je ognětluží

Pozn.: Když ráviny jsou ale správné pouze za předpohled,
že model je lineární?

- rozdílné H_0 ~~nemá~~, moment, že x nemá vliv na y ,
může to pouze mít hru, že vždy mezi $y - x$
nemá lineární

- rozdílné H_0 napsat řečí, že existuje lineární trend
mezi $y - x$, ale mohou tomu být i jiné hypotézy
ognětluží

pro kontrukční testu využívajícího IS
odvozené'

$H_0: \theta = \theta_0 \times H_1: \theta \neq \theta_0$. $(\theta, \bar{\theta})$ je $100(1-\alpha)\%$ IS pro θ

tedy $W = \{x \mid \theta_0 \notin (\theta, \bar{\theta})\}$ je hřešitelný obor testu m= kvantil α

$H_0: \beta_1 = 0$ záměr, pakže $0 \notin (\hat{\beta}_1 \pm t_{1-\frac{\alpha}{2}}(n-2) \frac{D_m}{\sqrt{S_{xx}}})$

tedy lze $\hat{\beta}_1 + t_{1-\frac{\alpha}{2}}(n-2) \frac{D_m}{\sqrt{S_{xx}}} < 0 \Leftrightarrow \hat{\beta}_1 \frac{\sqrt{S_{xx}}}{D_m} < -t_{1-\frac{\alpha}{2}}(n-2)$

nebo $\hat{\beta}_1 - t_{1-\frac{\alpha}{2}}(n-2) \frac{D_m}{\sqrt{S_{xx}}} > 0 \Leftrightarrow \hat{\beta}_1 \frac{\sqrt{S_{xx}}}{D_m} > t_{1-\frac{\alpha}{2}}(n-2)$

zpravidla ohromuje

$$|T_m| = \left| \hat{\beta}_1 \right| \frac{\sqrt{S_{xx}}}{D_m} > t_{1-\frac{\alpha}{2}}(n-2)$$

Pozn. intuitivní interpretace:

$$|T_m| = |\hat{\beta}_1| \frac{\sqrt{S_{xx}}}{D_m} = \frac{|\hat{\beta}_1|}{\hat{\sigma}(\hat{\beta}_1)} \quad \text{přesného' hromadu' relaci' chyb}$$

$$\frac{\hat{\sigma}(\hat{\beta}_1)}{|\hat{\beta}_1|}$$

podle je $\hat{\beta}_1$ dobrý odhad, očekávané maly' rozdíly $\hat{\sigma}(\hat{\beta}_1)$ mezi $\hat{\beta}_1$, když T lze v některém směru řídit, je záměr H_0 podle významných obdobou je relaci' chyb v obou možnostech

Pozv: někdy dojde smíšená korelace b_1 , jeho
korelační parametr β_1 a chybou výsledku testovat

(21)

$$H_0: \beta_1 = b_1 \quad \times \quad H_1: \beta_1 \neq b_1$$

test vlastní rozdílu H_0 proved

$$|\beta_1 - b_1| \cdot \frac{\sqrt{s_{xx}}}{D_m} > t_{1-\alpha/2}(n-2)$$

Test významnosti interceptu:

obrácení, že první "pravděpodobnost" $(0,0)$, když

$$\underline{H_0: \beta_0 = 0} \quad \times \quad H_1: \beta_0 \neq 0$$

nezamítat H_0 znamená, že jednoduchý model

$y = \beta_1 x + e$ lepší popisuje data než $y = \beta_0 + \beta_1 x + e$

H_0 zkontrolovat, pokud

$$T_m = \frac{|\hat{\beta}_0|}{\hat{\sigma}(\hat{\beta}_0)} = |\hat{\beta}_0| \frac{1}{D_m \sqrt{\frac{1}{m} + \frac{\bar{x}^2}{s_{xx}}}} > t_{1-\alpha/2}(n-2)$$

ANOVA průkaz pro koeficienty

(22)

odvozují jsme R-test pro test významnosti koeficientu; myží odvozují ehravého F-test, myží může být záležit na tom, celkové významnosti několikačekrát regresních modelů (testy významnosti jednotlivých koeficientů mohou být totiž rozdílní).

upřesnění metody (analyze rozložení ANOVA) je určit, kolik variability v pozorováních (y_1, \dots, y_m) je „vyváženo“ regresním modelem (průměrem).

mezi variability v datech: Total sum of squares
celkové součet čtverců

$$SST = \sum_{i=1}^m (y_i - \bar{y}_m)^2$$

představují průměr dobré podobnosti dat, tedy $\hat{y}_i \approx y_i$

$$y = \hat{\beta}_0 + \hat{\beta}_1 x$$

když platí $\sum_{i=1}^m (\hat{y}_i - \bar{y}_m)^2 \approx \sum_{i=1}^m (y_i - \bar{y}_m)^2$

uhodíme, že $\bar{\hat{y}}_m = \bar{y}_m$ a tak

$$\sum_{i=1}^m (\hat{y}_i - \bar{y}_m)^2 = \sum_{i=1}^m (\hat{y}_i - \bar{\hat{y}}_m)^2 = SSR$$

regression sum
of squares

regresní součet čtverců

počítí

$$\underline{R^2} = \frac{\text{SSR}}{\text{SST}} \Rightarrow \frac{\sum_{i=1}^n (\hat{y}_i - \bar{y}_i)^2}{\sum_{i=1}^n (y_i - \bar{y}_i)^2}$$

je výsledek ~~počítání~~ variability $\approx (y_1, \dots, y_n)$ využití lineárního modelu

R^2 - coefficient of determination (coefficient of determination)

(pro dobrý model by měl být hodnota $R^2 \approx 1$)

- uvedeme, že R^2 je kvadratickým korelačním koeficientem mezi y a \hat{y} , což dává vkl. R^2 význam někdy „dobre“ nebo „zřejmě dobré“.
- pokud počítanou součtu rozdílů f. vkl. R^2 mohou ne vždy počítat pro hipo. $H_0: \beta_1 = 0$, tedy když je vypočítáno, že $R^2 \approx 1$ pakže hipo. může být vypočítáno ekvivalentně k hipo. o existenci pozitivního vztahu (pro využití v anal. met.)

$$\underline{F = \frac{(n-2) R^2}{1-R^2}}$$

Věta: Pokud je $SST \neq 0$. Pak platí

1) $0 \leq R^2 \leq 1$

2) $\underline{R^2 = 1 - \frac{SSE}{SST}}$ ($SSE = \sum_{i=1}^n (y_i - \hat{y}_i)^2$ - residualní soudí)

3) $\underline{R^2 = 1} \Leftrightarrow \hat{y}_i = y_i \quad \forall i \in \hat{n}$ (residua jsou leží na prázdroji)

4) pokud sm. $x = (x_1, \dots, x_m) \quad a \quad y = (y_1, \dots, y_n)$, pak

(24)

$$\underline{R^2 = \rho^2(x, y)},$$

dále $\rho^2(x, y) = \frac{\left(\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y}) \right)^2}{S_{xx} S_{yy}}$

je druhé možné
významové hodnoty
koefficientu regrese.

5) $F = \frac{SSR}{\sigma^2} = T_x^2$

6) pokud jsou obaly e_1, \dots, e_m n.i.d. $\mu(0, \sigma^2)$ a $B_0 = 0$ (platí $H_0: B_0 = 0$)

v modelu, pak

$$\underline{F \sim F(1, m-2)}$$

Pozn: 5) a 6) \Rightarrow paralelní lib. stříhly T_x, R^2 nebo F může
ne ekvivalentní test významnosti regrese

- R^2 je používán k tomu představit o kvalitě modelu,
čímž je blíže 1, tím lepší je kvalita modelu
(nicméně je třeba jisté obzrežnost, že může poslat)
- F lze dát jeho vztah pro tento významnostní test hodnoty R^2

dále můžeme rozložit nezávislosti mezi hodnotami

$$\sum_{i=1}^n (y_i - \hat{y}_i)^2 = \sum_{i=1}^n (\hat{y}_i - \bar{y})^2 + \sum_{i=1}^n (\hat{y}_i - \bar{y}_i)^2$$

nebo: $\underline{SST = SSR + SSE}$

pro další potřebujeme lemmu

Lemma: Nach $\hat{e}_i = y_i - \hat{y}_i$ seien Residuen, habe

(25)

$\hat{y}_i = \hat{\beta}_0 + \hat{\beta}_1 x_i$ a. $\hat{\beta}_0, \hat{\beta}_1$ givn LSE. Daben

$$1) \sum_{i=1}^n \hat{e}_i = 0$$

$$2) \bar{\hat{y}}_m = \bar{y}_m$$

$$3) \sum_{i=1}^n \hat{e}_i \hat{y}_i = 0$$

Dgl: 1) a. ronie $\frac{\partial S}{\partial \beta_0} = 0$ daben

$$0 = \sum_{i=1}^n (y_i - \hat{\beta}_0 - \hat{\beta}_1 x_i) = \sum_{i=1}^n (y_i - \hat{y}_i) = \sum_{i=1}^n \hat{e}_i$$

2) a. bilden 1) ghe, $\bar{\hat{y}}_m = \sum_{i=1}^n \hat{y}_i = \sum_{i=1}^n y_i$, potetan' n

daben vorz'

3) a. ronie $\frac{\partial S}{\partial \beta_1} = 0$ daben

$$0 = \sum_{i=1}^n (y_i - \hat{\beta}_0 - \hat{\beta}_1 x_i) x_i = \sum_{i=1}^n \hat{e}_i x_i$$

a. Nach

$$\begin{aligned} \sum_{i=1}^n \hat{e}_i \hat{y}_i &= \sum_{i=1}^n \hat{e}_i (\hat{\beta}_0 + \hat{\beta}_1 x_i) = \sum_{i=1}^n \hat{e}_i \hat{\beta}_0 + \sum_{i=1}^n x_i \hat{e}_i \hat{\beta}_1 = \\ &= \underbrace{\hat{\beta}_0 \sum_{i=1}^n \hat{e}_i}_{=0} + \underbrace{\hat{\beta}_1 \sum_{i=1}^n x_i \hat{e}_i}_{=0} = 0 . \end{aligned}$$

Q.E.D.

Während weiter nachschau:

$$SST = \sum_{i=1}^n (y_i - \bar{y}_m)^2 = \sum_{i=1}^n [(y_i - \hat{y}_i) + (\hat{y}_i - \bar{y}_m)]^2 =$$

$$= \sum_{i=1}^n (\gamma_i - \hat{\gamma}_i)^2 + \sum_{i=1}^n (\hat{\gamma}_i - \bar{\gamma}_i)^2 + 2 \sum_{i=1}^n (\gamma_i - \hat{\gamma}_i)(\hat{\gamma}_i - \bar{\gamma}_i)$$

(26)

$$= SSE + SSR + 0$$

merkt

$$\sum_{i=1}^n (\underbrace{\gamma_i - \hat{\gamma}_i}_{= \hat{e}_i})(\hat{\gamma}_i - \bar{\gamma}_i) = \underbrace{\sum_{i=1}^n \hat{e}_i \hat{\gamma}_i}_{= 0} - \bar{\gamma}_i \underbrace{\sum_{i=1}^n \hat{e}_i}_{= 0} = 0.$$

DR mit:

$$1) \text{ prüfen } SST = SSE + SSR \text{ plausibel}$$

$$0 \leq R^2 = \frac{SSR}{SST} \leq \frac{SST}{SST} = 1$$

$$2) SSR = SST - SSE \Rightarrow R^2 = \frac{SST - SSE}{SST} = 1 - \frac{SSE}{SST}$$

$$3) \text{ zu beiden 2 plausibel, da } R^2 = 1 \Leftrightarrow SSE = 0$$

$$SSE = \sum_{i=1}^n (\gamma_i - \hat{\gamma}_i)^2 = 0 \Leftrightarrow \gamma_i = \hat{\gamma}_i \quad \forall i \in \hat{n}$$

$$4) \hat{\gamma}_i = \hat{\beta}_0 + \hat{\beta}_1 x_i = \bar{\gamma}_m + \hat{\beta}_1 (\bar{x}_m - x_i)$$

$$\text{Nahme } \overline{\hat{\gamma}_m - \hat{\beta}_1 \bar{x}_m}$$

$$SSR = \sum_{i=1}^n (\hat{\gamma}_i - \bar{\gamma}_m)^2 = \hat{\beta}_1^2 \sum_{i=1}^n (x_i - \bar{x}_m)^2 = \frac{\hat{\beta}_1^2 S_{xx}}{S_{yy}}$$

$$\text{prüfen } \hat{\beta}_1 = \frac{1}{S_{xx}} \sum_{i=1}^n (x_i - \bar{x}_m)(\gamma_i - \bar{\gamma}_m), \text{ durchnehmen}$$

$$R^2(x, y) = \frac{\left[\sum_{i=1}^n (x_i - \bar{x}_m)(\gamma_i - \bar{\gamma}_m) \right]^2}{S_{xx} S_{yy}} = \frac{\hat{\beta}_1^2 S_{xx}}{S_{yy}} = \frac{SSR}{SST} = R^2$$

$$\text{merkt } S_{yy} = \sum_{i=1}^n (\gamma_i - \bar{\gamma}_m)^2 = SST.$$

5) r def. R

$$F = \frac{(n-2) R^2}{1-R^2} = \frac{(n-2) \frac{SSR}{SST}}{\frac{SSE}{SST}} = \frac{SSR}{\frac{SSE}{n-2}} = \frac{SSR}{R^2}$$

proto $T_m = \hat{\beta}_1 \frac{\sqrt{S_{xx}}}{R_m}$ (nh. 2.) ,

$$\overline{T_k^2} = \frac{\cancel{\hat{\beta}_1^2}}{\cancel{R_m^2} S_{xx}} = \frac{\hat{\beta}_1^2 \frac{S_{xx}}{R_m^2}}{\cancel{R_m^2}} = \frac{SSR}{R_m^2} = F$$

6) $T_k^2 \sim \chi^2(n-2)$ (nh. 19)

$$\left(\frac{\chi^2(1)}{\sqrt{\frac{2^k(n-2)}{m-2}}} \right)^2 = \frac{\chi^2(1)}{\frac{2^k(n-2)}{m-2}} \sim F(1, m-2)$$

↓

Q.E.D.

$$F = \overline{T^2} \sim F(1, n-2)$$

Významný je někdy možné v ANOVA:

Source	df	SS	MS	F
Regression	1	SSR	$MSR = SSR$	$\frac{MSR}{MSE}$
Residual	$n-2$	SSE	$MSE = \frac{SSE}{n-2} = R_m^2$	
Total	$n-1$	SST		

$$R^2 = \frac{SSR}{SST}$$

Source - rozdíl mezi obecnou a

df - počet stupňů volnosti přidruženého danému rozdílu obecnou

SS - rozdíl obecnou

MS - "mean squares" $MS = \frac{SS}{df}$ F - jehož $\frac{MSR}{MSE}$

Počet: $H_0: \beta_1 = 0$ je závratná, pokud

$$F > F_{1-\alpha}(1, n-2)$$

nebo jednorozemén písmo je do charakterní χ^2 -testu
(mezi $F = \chi^2$)

Někdo: Nechť x_1, \dots, x_m jsou i.i.d. $N(0, \sigma^2)$. Za plnost.

$H_0: \beta_1 = 0$ je ekvivalent:

$$\frac{SSR}{\sigma^2} \sim \chi^2(1), \quad \frac{SSE}{\sigma^2} \sim \chi^2(n-2), \quad \frac{SST}{\sigma^2} \sim \chi^2(n-1)$$

Pozn: pokud $n = m$ pak má ANOVA vlivy df pro testy $1, n-2, n-1$

používají se: ~ písmo je v rozdílu od jiného

představit v leto:

- $SSE = \sum \hat{e}_i^2$, ne m -residuum $\hat{e}_1, \dots, \hat{e}_m$ máce 2自由度
 $\sum \hat{e}_i = 0$ a $\sum x_i \hat{e}_i = 0 \Rightarrow m-2$ svobodné volnosti
- $SST = \sum (y_i - \bar{y})^2$ $y_i - \bar{y}$ máce optimální $\sum (y_i - \bar{y}) = 0$
 $\Rightarrow m-1$ svobodné volnosti
- $SSR = SST - SSE$, počet svobodné volnosti je $(n-1)-(m-2) = 1$

Zd: ~ předchozí dr. jme názvem. $SSR = \hat{\beta}_1^2 S_{xx}$, kde

$$\frac{SSR}{\sigma^2} = \left(\frac{\hat{\beta}_1 \sqrt{S_{xx}}}{\sigma} \right)^2, \text{ náleží } \hat{\beta}_1 \sim N(\beta_1, \frac{\sigma^2}{S_{xx}}) \sim \text{testy}$$

$$(\hat{\beta}_1 - \beta_1) \frac{\sqrt{S_{xx}}}{\sigma} \sim N(0, 1)$$

pro $\beta_1 = 0$: $\hat{\beta}_1 \frac{\sqrt{S_{xx}}}{\sigma} \sim N(0, 1) \Rightarrow \frac{SSR}{\sigma^2} \sim \chi^2(1)$

$$\frac{SSE}{\sigma^2} = \frac{(m-2) \hat{\beta}_n^2}{\sigma^2} \sim \chi^2(m-2) \quad \text{vì dříve}$$

(užitíme postoji)

a rezidu' me $\hat{\beta}_n$

$$\Rightarrow \frac{SSR}{\sigma^2} \text{ a } \frac{SSE}{\sigma^2} \text{ jsou nezávislé}$$

$$\text{protože } \frac{SST}{\sigma^2} = \frac{SSR}{\sigma^2} + \frac{SSE}{\sigma^2} \Rightarrow \frac{SST}{\sigma^2} \sim \chi^2(m-1).$$

$$\chi^2(1) + \chi^2(m-2) = \chi^2(m-1)$$

$\swarrow \searrow$
res.

Q.E.D.

Ozn. -

Pozn: R^2 relativní - prozaikovatelné hodnoty kvalit modelu

- nízké hodnoty R^2 nemají smysl, jež reprezentují model nemají význam, až do této výše lze velle' možností neoprávněnitelné' nahodné ~~variability~~ variability

např. upohování hodnoty regresoru x nízké hodnoty R^2 opakovaného modelu o význam x

- velle' hodnoty R^2 mohou být způsobeny velkými náhodami (S_{xx} velké)

- plati' totiž $E(R^2) \approx \frac{\hat{\beta}_n^2 S_{xx}}{\hat{\beta}_n^2 S_{xx} + \sigma^2}$

což je normální funkce S_{xx}

- velký rozptyl (x_1, \dots, x_m) může mít na následkách velké R^2 protože měříme a kvalit modelu
- $E(R^2)$ je také normální funkce $\hat{\beta}_n^2$ obecně může mít velké R^2 nebo může mít malé R^2

Práv. hodiňovem' hodiňov mohou počítat všechny všechny

(30)

maximální počet napsí:

1) „velké“ R^2

2) „velké“ F mimo ITI hodnoky

3) „malé“ hodnoky D_m vzhledem k \bar{D}_m

doba britského povstání

Práv. Velké hodnoty R^2 indikují přiblížení linearu vzhledem
x a \bar{D} , ale významy těchto hodnot nemají závislost
přesnosti vzhledem.

data: 1924 - 1937

y_i - počet mentální onemocnění
na 100 000 obyvatel Anglie

(Ex 3.17 f. 83)

x_i - počet rodin v populaci

model $y_i = \beta_0 + \beta_1 x_i + \epsilon_i$

$$\hat{\beta}_0 = 4,5822, \quad \hat{\beta}_1 = 2,2042$$

$$\underline{R^2 = 0,984}$$

Práv. velké významy linearu
vzhledem x a \bar{D}

počet by mohl být, že rodina s vysokou mentální onemocnění
je hodně by se mohla být pravidla, neboť je mnohem většinou
vysvětlitelné; a tože x i \bar{D} mohou lineárně souviset, tzn.
 \bar{D} mohou lineárně souviset s x

rodina byla s časem dostupnější, dejm. diagnostický procesus
možnou významnou identifikací všechny s mentálními problémy