

Vícezměrné regrese

(47)

předz., řešme kvadratickou pro hledání $\hat{\beta}_i \in \hat{\beta}$

a díky tomu máme proměnné $x_{i1}, x_{i2}, \dots, x_{im}$

Model:

$$Y_i = \beta_0 + \sum_{j=1}^m \beta_j x_{ij} + \varepsilon_i, \quad i = 1, \dots, n$$

hde $\varepsilon_1, \dots, \varepsilon_n$ jsou nezávislé (neshorelávající) chyby $\sim \mathcal{N}(0, \sigma^2)$.

ne scháděj pozorování $(x_{i1}, \dots, x_{im}, Y_i)$, $i = 1, \dots, n$

číslo vektoru par. $\beta = (\beta_0, \beta_1, \dots, \beta_m)^T$ (projektion do $m+1$ dim. prostoru pozorování)

předz. $n > m+1$ (více dle nej parametrů)

maticej zápis:

$$\mathbf{Y} = (Y_1, \dots, Y_n)^T, \quad \boldsymbol{\beta} = (\beta_0, \dots, \beta_m)^T, \quad \mathbf{E} = (\varepsilon_1, \dots, \varepsilon_n)^T$$

$$\mathbf{X} = \begin{bmatrix} 1 & x_{11} & \dots & x_{1m} \\ 1 & x_{21} & \dots & x_{2m} \\ \vdots & \vdots & \ddots & \vdots \\ 1 & x_{m1} & \dots & x_{mm} \end{bmatrix} \quad \begin{array}{l} \text{design matrix} \\ \text{matrix modelu} \\ \text{regresní matrix} \end{array}$$

model:

$$\mathbf{Y}_{m \times 1} = \mathbf{X}_{m \times (m+1)} \boldsymbol{\beta}_{(m+1) \times 1} + \mathbf{E}_{m \times 1} \quad (**)$$

- myšlení bude dle pravidla. x_1, \dots, x_m nez., $\varepsilon_i \sim N(0, \sigma^2)$,

$$\text{Mn. } \boldsymbol{\varepsilon} \sim N_m(0, \sigma^2 I_m) \quad \text{a} \quad \underline{\boldsymbol{\gamma}_I \sim N_m(X\beta, \sigma^2 I_m)}$$

verhočnostní funkce: $L(\beta, \sigma^2) = f_{\boldsymbol{\gamma}_I}(y) = \prod_{i=1}^m \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{1}{2\sigma^2} (\gamma_i - y_i)^2}$

$$\begin{aligned} y_i &= \beta_0 + \sum_{j=1}^m \beta_j x_{ij} \\ y &= (y_1, \dots, y_m)^T = X\beta \\ &= \frac{1}{(2\pi\sigma^2)^{\frac{m}{2}}} \cdot e^{-\frac{1}{2\sigma^2} \sum_{i=1}^m (\gamma_i - y_i)^2} = \\ &= \frac{1}{(2\pi\sigma^2)^{\frac{m}{2}}} \cdot e^{-\frac{1}{2\sigma^2} (\boldsymbol{\gamma} - \boldsymbol{y})^T (\boldsymbol{\gamma} - \boldsymbol{y})} = \\ &= \frac{1}{(2\pi\sigma^2)^{\frac{m}{2}}} \cdot e^{-\frac{1}{2\sigma^2} (\boldsymbol{\gamma} - X\beta)^T (\boldsymbol{\gamma} - X\beta)} \end{aligned}$$

pro parametr σ^2 je

$$\max_{\sigma^2} L(\beta, \sigma^2) \Leftrightarrow \min_{\sigma^2} (\boldsymbol{\gamma} - X\beta)^T (\boldsymbol{\gamma} - X\beta)$$

$g(\beta)$

do jisté pomoci derivací, mohou se algebraicky pořídit

Věta: Uvažujme model (***) a nechť $\boldsymbol{\varepsilon} \sim N(0, \sigma^2 I_m)$.

Potom $\hat{\beta}$ je MLE $\beta \Leftrightarrow \hat{\beta}$ je řešením rovnice

$$\underline{X^T X \beta = X^T \boldsymbol{\gamma}_I} \quad (\text{rovnice normované rovnice}) \quad (A)$$

X -b. možné $X^T X$ neinverzibilní, ne' bude rovnice jednoznačná

řešení ne' bude

$$\underline{\hat{\beta} = (X^T X)^{-1} X^T \boldsymbol{\gamma}_I}.$$

$\mathcal{D} \hat{\beta} :=$ whosene, sic herde' rere' $\hat{\beta}$ mabey (A) minimizige $g(\beta)$ 43

pro herde' β plati:

$$g(\beta) = (\gamma_1 - X\beta)^T (\gamma_1 - X\beta) = \underbrace{\gamma_1^T \gamma_1}_{\text{minimizing } g(\beta)} - 2 \underbrace{\gamma_1^T X \beta}_{\hat{\beta}^T X^T X} + \underbrace{\beta^T X^T X \beta}_{\text{minimizing } g(\beta)} =$$

min' plati \approx pro $\hat{\beta}$:

$$g(\hat{\beta}) = \underbrace{\gamma_1^T \gamma_1}_{\text{minimizing } g(\hat{\beta})} - 2 \underbrace{\hat{\beta}^T X^T X \hat{\beta}}_{\text{minimizing } g(\hat{\beta})} + \underbrace{\hat{\beta}^T X^T X \hat{\beta}}_{\text{minimizing } g(\hat{\beta})} =$$

a lehrg $\underline{g(\beta) - g(\hat{\beta})} = \beta^T X^T X \beta - 2 \hat{\beta}^T X^T X \beta + \hat{\beta}^T X^T X \hat{\beta} =$

$$= (X\beta - X\hat{\beta})^T (X\beta - X\hat{\beta}) = (X(\beta - \hat{\beta}))^T (X(\beta - \hat{\beta}))$$

$$= \langle X(\beta - \hat{\beta}); X(\beta - \hat{\beta}) \rangle \geq 0 \quad \cancel{\forall \beta} \quad (\#)$$

$\hat{\beta}$ minimizige $g(\beta)$

\approx lehrg MLE fer. β

\Rightarrow : probly., in $\hat{\beta}_n$ min. $g(\beta)$ (lehrg MLE)

Pro. $g(\hat{\beta}_n) \leq g(\beta) \quad \forall \beta$, spez. $g(\hat{\beta}_n) \leq g(\hat{\beta})$ falle $\hat{\beta}$ ist reell (A)

zu (#) $\Rightarrow g(\hat{\beta}_n) \geq g(\hat{\beta})$, cellar lehrg $\underline{g(\hat{\beta}_n) = g(\hat{\beta})}$

daraus folgt (#) $0 = g(\hat{\beta}_n) - g(\hat{\beta}) = \langle X(\hat{\beta}_n - \hat{\beta}); X(\hat{\beta}_n - \hat{\beta}) \rangle$

\approx lehrg $X(\hat{\beta}_n - \hat{\beta}) = 0 \quad | X^T \text{ platt}$

$X^T X \hat{\beta}_n - \underbrace{X^T X \hat{\beta}}_{X^T \gamma_1} = 0 \quad \Rightarrow \quad \underline{X^T X \hat{\beta}_n = X^T \gamma_1} \quad \approx \hat{\beta}_n \text{ mabey mabey (A)}$

Aby bylo dílo korektní, je třeba uvažovat, že rovnice (A)

má několik řešení a řešení

představí $(X^T X)^{-1}$ nebo je dekompozice, řešení přímo může
se hodit je $X^T X$ singulární?

(50)

Lemma: Lineární rovnice $Ax = \gamma_1$ má řešení (\Rightarrow)

$$\Leftrightarrow \langle \gamma_1, \alpha \rangle = 0 \quad \text{pro všechny } \alpha \text{ splňující } A^T \alpha = 0.$$

Důkaz: Lineární rovnice (A) má několik řešení jistou řešení.

$$D\text{f} \cdot \quad X^T X \gamma_1 = X^T \gamma_1$$

musíme uvažovat, že $\langle X^T \gamma_1, \alpha \rangle = 0 \quad \forall \alpha$ splňující $X^T \alpha = 0$

$$X^T X \alpha = 0 \Rightarrow \langle X^T X \alpha, \alpha \rangle = \langle X \alpha, X \alpha \rangle = 0 \quad \text{a tedy } X \alpha = 0$$

obecné platí

$$\text{celkově } \langle X^T \gamma_1, \alpha \rangle = \langle \gamma_1, X \alpha \rangle = 0. \quad \langle X, A \gamma_1 \rangle = \langle A^T X, \gamma_1 \rangle$$

Pozn: Z této výplývá, že MLE B může být množstvo řešení
 $m+1$ lin. rovnice o $m+1$ neznámých.

Můžeme uvažovat analytické řešení, je třeba použít numerické metody.

Můžeme $X^T X$ může být - prohl. aplikační řešení - podmíněné,

což ovšem může mít řešení B. Tento reálný řešení

metody jako jsou Choleskeho rozklad, QR rozklad, singularní
rozklad (SVD).

minimální řešení ovšem být může

(57)

Obrátili jsme pro normální chyby. Minimizace $\hat{\beta}$ bude tehdy možná i pro jiné důvody chyb, pokud ne je $\hat{\beta}$ "najednoznačná".

ordinary least squares estimate (OLS)

objektivní nejmenší čtvereček
an nejvýznamnější metoda pro odhad β .

Jde o takový, že mají normální rozložení jednotlivé řešení bez matematické výrovnatelnosti $X^T X$?

Náha: Matice $X^T X$ je neinvolutivní \Leftrightarrow jiné sloupcy matici X LHK

28. \Leftrightarrow : Matici musí mít sloupcy X LHK a matice $X^T X$ sing.

Nebo $\exists c \neq 0$ tak, že $X^T X c = 0$

$$0 = \langle c, X^T X c \rangle = \langle Xc, Xc \rangle \Rightarrow Xc = 0, \sum c_i x_i^c = 0,$$

tedy $c = (c_1, \dots, c_m)^T \in \mathbb{R}^m$ je základní sloupec matici X

\Rightarrow sloupec X jen L2 norm

\Rightarrow : matici právky $X^T X$ regulérní = sloupcy X L2

12. $x - c \neq 0$ takové, že $Xc = 0 \quad | \cdot X^T$

$$X^T X c = 0 \Rightarrow X^T X \text{ je singulární, } \text{moc}$$

Pozn: $X_{m \times (m+1)}$, $m > m+1$, $h(X) = m+1$, $\epsilon \sim N(0, \sigma^2 I_m)$

\Rightarrow sloupcy matici X L2 je $X^T X$ singulární, což je některou

Pozn: • pokud jen sloupcy X L2 je $X^T X$ singulární, což je některou
detektování numerických maticových výrobní $\hat{\beta}$

- horší situace je, pokud jsou sloužecí X „lépe“ L2

Náv. multikolinearita

spisovatý problém při rovnici $\hat{\beta}$ proti β je vlastně je $X^T X$ „lépe“ singularne' jde ji' detektovat probírat na horší přístupech.

Ostatní parametr σ^2

- pro normální chyby získáme MLE σ^2 derivací $\ln L(\beta, \sigma^2)$
z této funkce

$$\hat{\sigma}^2 = \frac{1}{n} SSE = \frac{1}{n} (\gamma - X\hat{\beta})^T (\gamma - X\hat{\beta}) = \frac{1}{n} \sum_{i=1}^n (\gamma_i - \hat{\beta}_i)^2$$

$$\text{Jinde } \hat{\beta}_i = (X\hat{\beta})_i = \underline{X_i^T \hat{\beta}} \quad i = 1, \dots, n$$

Jinde $X_i^T \gamma_i = -b$ řešit metodu X.

protože nejsou 'o vychýlení' odhad, používáme obecní odhad

$$\hat{\sigma}_m^2 = \frac{1}{n-(m+1)} SSE = \frac{1}{n-m-1} \sum_{i=1}^n (\gamma_i - \hat{\beta}_i)^2$$

a $\hat{\sigma}_m = \sqrt{\hat{\sigma}_m^2}$ jdeho odhad σ (viz některé poznámky)

- pro $\epsilon_i \sim N(0, \sigma^2)$ se řekne' používání odhadů $\hat{\sigma}_m^2$, $\hat{\sigma}_m$

Úř. (Ex. 5.13, str. 158)

Úř. (Ex. 5.15, str. 203)

Werkzeug: ols schätzung $\hat{\beta}$, $\hat{\sigma}_m^2$

Neh: Merkt $\hat{\beta}$ ist OLS schätzung für β \sim Modell $(\star \star)$,

hole $\hat{L}(x) = m-1$ a. e_1, \dots, e_m unabhängig, $e_i \sim N(0, \sigma^2)$.

Folgerung:

$$1) E(\hat{\beta}) = \beta \quad (\hat{\beta} \text{ ist unbias})$$

$$2) \text{Cov}(\hat{\beta}) = \sigma^2 (x^T x)^{-1}$$

$$3) E(\hat{\sigma}_m^2) = \sigma^2 \quad (\hat{\sigma}_m^2 \text{ ist unbias})$$

4) gegebene rausch $e_i \sim N(0, \sigma^2), i=1, \dots, m$, folger

$$\hat{\beta} \sim N_{m-1}(\beta, \sigma^2 (x^T x)^{-1})$$

spezielle $\hat{\beta}_i \sim N(\beta_i, \sigma^2 \sigma_{ii}^{-1})$, hole $\sigma_{ii}^{-1} \approx -1$ diag.
prob matric $(x^T x)^{-1}$

$$\sigma_{ii}^{-1} = (x^T x)_{ii}^{-1}$$

$$\text{DR: } 1) \hat{L}(x) = m-1 \Rightarrow \hat{\beta} = (x^T x)^{-1} x^T y$$

$$E\hat{\beta} = E[(x^T x)^{-1} x^T y] = \underbrace{(x^T x)^{-1} x^T}_{= X\hat{\beta}} E(y) = (x^T x)^{-1} x^T x \beta = \beta$$

2) $(Y_{m \times 1} \text{ mit achtz}, \text{ Cov}(y) = \Sigma, A_{m \times m} \text{ matrix}, \text{ folger}$

$$\text{Cov}(AY) = A \Sigma A^T$$

prob $\hat{\beta} = A\bar{y}$, hole $A = (x^T x)^{-1} x^T$, $\hat{\beta}$ ist Lk y_1, \dots, y_m a.

$$\text{Cov}(\hat{\beta}) = \sigma^2 I_m$$

$$\text{Cov}(\hat{\beta}) = (x^T x)^{-1} x^T \sigma^2 I_m x (x^T x)^{-1} =$$

$$= \sigma^2 (x^T x)^{-1}.$$

3) meistreine präzise mehrere residuen' $\hat{e} = \bar{y} - \hat{x}\hat{\beta} = \bar{y} - \hat{y}$

$$\hat{y} = \hat{x}\hat{\beta} = \hat{x}(\hat{x}^T\hat{x})^{-1}\hat{x}^T\bar{y} = H\bar{y}, \text{ bkt } H = \underline{\hat{x}(\hat{x}^T\hat{x})^{-1}\hat{x}^T} \text{ ist projektion' matrix}$$

$$\hat{e} = \bar{y} - H\bar{y} = (I_m - H)\bar{y}$$

dito plz:

$$(I_m - H)\hat{x} = \hat{x} - \hat{x}(\hat{x}^T\hat{x})^{-1}\hat{x}^T\hat{x} = \hat{x} - \hat{x} = 0, \text{ bkt}$$

$$\hat{e} = (I_m - H)\bar{y} = (I_m - H)(\hat{x}\beta + \varepsilon) = \underbrace{(I_m - H)\hat{x}\beta}_{=0} + (I_m - H)\varepsilon = \underline{(I_m - H)\varepsilon}$$

$$\text{wegen } \underline{H^T} = H \quad \text{a } \underline{H^2} = [\hat{x}(\hat{x}^T\hat{x})^{-1}\hat{x}^T] [\hat{x}(\hat{x}^T\hat{x})^{-1}\hat{x}^T] = \hat{x}(\hat{x}^T\hat{x})^{-1}\hat{x}^T = \underline{H}$$

$$\text{a } (I_m - H)^2 = I_m - H \quad (\text{H ist symmetrische a idempotente})$$

$$SSE = (\bar{y} - \hat{y})^T(\bar{y} - \hat{y}) = \hat{e}^T \hat{e} = \varepsilon^T (I_m - H)(I_m - H)\varepsilon = \varepsilon^T (I_m - H)\varepsilon$$

$$= \sum_{i=1}^n \sum_{j=1}^m g_{ij} e_i e_j \quad \text{bkt } g_{ij} \text{ ist } (i,j)-\text{punkt nach } I_m - H$$

$$E(SSE) = \sum_{i=1}^n \sum_{j=1}^m g_{ij} E(e_i e_j) \stackrel{\text{reduziert}}{=} \sum_{i=1}^n g_{ii} \text{ Var } e_i = \sigma^2 \sum_{i=1}^n g_{ii}$$

$$\text{Cov}(e_i, e_j) \quad E e_i = 0$$

$$\begin{aligned} \sum_{i=1}^n g_{ii} &= \text{rk}(I_m - H) = \text{rk}(I_m) - \text{rk}(H) = n - \text{rk}(\hat{x}(\hat{x}^T\hat{x})^{-1}\hat{x}^T) \\ &\stackrel{A, B \in \mathbb{R}^{m,n}}{=} \text{rk}(A+B) = \text{rk } A + \text{rk } B \\ &\quad = n - \text{rk}(\hat{x}^T\hat{x}(\hat{x}^T\hat{x})^{-1}) = n - \text{rk}(I_{m+n}) \\ &\quad = n - (m+1) \end{aligned}$$

$$\text{daher } \underline{E S_m^2} = \frac{1}{n-(m+1)} E(SSE) = \frac{1}{n-(m+1)} \cdot \sigma^2(n-(m+1)) = \underline{\sigma^2}$$

4) $\hat{\beta}$ ist LK y_1, \dots, y_m , 'nichtscheinbar', 'nichtscheinbar'

$$\hat{\beta} \sim N_{m+1}(\beta, \sigma^2 (\mathbf{x}^T \mathbf{x})^{-1})$$

Q.E.D.

Pozn. Vektorwertige 'projektive' Matrix:

$$H = \mathbf{X} (\mathbf{x}^T \mathbf{x})^{-1} \mathbf{x}^T \quad \hat{Y} = H Y \quad H^T = H, \quad (I_m - H)^T = (I_m - H) \quad \text{symmetrisch}$$

$$H^2 = H, \quad (I_m - H)^2 = I_m - H \quad (\text{idempotentisch})$$

$$H(\mathbf{x}) = \mathbf{x} \quad \text{rk}(H) = \sum_{i=1}^m h_{ii} = m+1$$

$$H(I_m - H) = (I_m - H)H = 0$$

Notiz: Merkt $Y = \mathbf{X}\beta + \epsilon$ ist LM, habe $L(Y) = m+1$ a $\epsilon \sim N_m(0, \sigma^2 I_m)$.

Orthon

1) $\hat{\beta}$ a D_m^2 von nichtscheinbar nch. vgl.

$$2) (m-m-1) \frac{D_m^2}{\sigma^2} \sim \chi^2(m-m-1)$$

$$3) \text{größte } r_i = (\mathbf{x}^T \mathbf{x})_{ii}^{-1}, \text{ vgl. } T_i = \frac{\hat{\beta}_i - \beta_i}{\sigma \sqrt{r_i}} \sim \mathcal{N}(0, 1)$$

4) merkt $C \in \mathbb{R}^{n, m+1}$ 'keine', $\tilde{c} \in L(C) = n$. Vgl.

'orthogonal' bema

$$\frac{q}{\sigma^2} = \frac{(\hat{\beta} - \beta)^T C^T [C (\mathbf{x}^T \mathbf{x})^{-1} C^T]^{-1} C (\hat{\beta} - \beta)}{\sigma^2} \sim \chi^2(n)$$

DR:

$$1) \hat{\beta} = (\mathbf{x}^T \mathbf{x})^{-1} \mathbf{x}^T Y = (\mathbf{x}^T \mathbf{x})^{-1} \mathbf{x}^T (\mathbf{x}\beta + \epsilon) = \beta + (\mathbf{x}^T \mathbf{x})^{-1} \mathbf{x}^T \epsilon$$

$$\text{a. d.h. } \hat{\beta} - \beta = (\mathbf{x}^T \mathbf{x})^{-1} \mathbf{x}^T \epsilon$$

diese wäre, $\tilde{\epsilon} = (I_m - H)\epsilon$ a. mehr $(\hat{\beta} - \beta, \tilde{\epsilon})^T$ lze rezipr

$$\text{jeho } Z = \begin{pmatrix} \hat{\beta} - \beta \\ \hat{\epsilon} \end{pmatrix} = \begin{pmatrix} (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \\ \mathbf{I}_m - \mathbf{H} \end{pmatrix} \boldsymbol{\epsilon} = \begin{pmatrix} \mathbf{A} \\ \mathbf{B} \end{pmatrix} \boldsymbol{\epsilon}, \text{ kde } \mathbf{Z} \text{ je buňkové}$$

$\hat{\epsilon}$ pouze $(\hat{\epsilon}_1, \dots, \hat{\epsilon}_m) = \boldsymbol{\epsilon} \sim N(0, \sigma^2 \mathbf{I}_m) \Rightarrow \mathbf{Z}$ má nerozložitelnou normální rozdělení' (v bývá degenerována', protože $\text{Cov}(\mathbf{Z})$ je singulární)

abychom moheli, že $\hat{\beta}$ a $\hat{\epsilon}$ jsou nezávislé' ($\hat{\beta}_m^2 = \frac{1}{m-m-n} \hat{\epsilon}^T \hat{\epsilon}$, když je $\hat{\beta}$ a $\hat{\epsilon}$ mimo),

ale? mohel, že $\text{Cov}(\hat{\beta}_i, \hat{\epsilon}_j) = 0 \quad \text{Cov}(\hat{\beta}_i, \hat{\epsilon}_i) = 0 \quad i=0, \dots, m$
 $j=1, \dots, n$

Můžeme $\text{Cov}(\mathbf{Z})$:

$$\text{Cov}(\mathbf{Z}) = \begin{pmatrix} \mathbf{A} \\ \mathbf{B} \end{pmatrix} \text{Cov}(\boldsymbol{\epsilon}) (\mathbf{A}^T \mathbf{B}^T) = \sigma^2 \begin{pmatrix} \mathbf{A} \\ \mathbf{B} \end{pmatrix} (\mathbf{A}^T \mathbf{B}^T) = \sigma^2 \begin{pmatrix} \mathbf{A} \mathbf{A}^T & \mathbf{A} \mathbf{B}^T \\ \mathbf{B} \mathbf{A}^T & \mathbf{B} \mathbf{B}^T \end{pmatrix}$$

$$\left(\text{Cov}(\hat{\beta}_i, \hat{\epsilon}_j) \right)_{\substack{i=0, \dots, m \\ j=1, \dots, n}} = \mathbf{A} \mathbf{B}^T = (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T (\mathbf{I}_m - \mathbf{X} (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T) =$$

$$= (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T - (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T = 0$$

2) významný je CA:

- spektrální rozložení matice:

$A_{m \times n}$ symetrická matice \Rightarrow ex. ortogonální matice Q a diagonální

matice Λ t. d. t. z. $A = Q \Lambda Q^T$, kde slouží Q pro OR

vlastní vektory matice A a diag. prob. matice Λ jsou jen jen odpovídající vlastní čísla

- $A_{m \times n}$ idempotentní \Rightarrow vlastní čísla jsou pouze 0 nebo 1
 $\Rightarrow L(A) = \text{Rz}(A)$

54

z dle. předchozí věty $\frac{\sum_{i=1}^m \hat{\beta}_i - \beta_i}{\sigma^2} = \frac{SSE}{\sigma^2} = \frac{1}{\sigma^2} \mathbf{x}^T (\mathbf{I}_m - \mathbf{H}) \mathbf{x}$

předp. je $\mathbf{I}_m - \mathbf{H}$ symetrické a diagonální

$$\mathbf{I}_m - \mathbf{H} = \mathbf{Q} \Delta \mathbf{Q}^T$$

\mathbf{Q} ortogonální matici
 Δ diag. s vlastními čísly $\mathbf{I}_m - \mathbf{H}$

předp. vět. že $\mathbf{I}_m - \mathbf{H}$ jde o matici \mathbf{A} a $\text{rk}(\mathbf{I}_m - \mathbf{H}) = \text{rk}(\mathbf{I}_m - \mathbf{H}) = m-m-1$

A může být rozložena ve tvaru

$$\mathbf{A} = \left(\begin{array}{c|c} \mathbf{I}_{m-m-1} & \mathbf{0} \\ \hline \mathbf{0} & \mathbf{0} \end{array} \right)$$

Nahoru

$$\mathbf{x}^T (\mathbf{I}_m - \mathbf{H}) \mathbf{x} = \mathbf{x}^T \mathbf{Q} \Delta \mathbf{Q}^T \mathbf{x} = \mathbf{q}_1^T \Delta \mathbf{q}_1, \text{ kde } \mathbf{q}_1 = \mathbf{Q}^T \mathbf{x}$$

V: $\mathbf{U} \sim N_m(0, \mathbf{I}_m)$ a \mathbf{Q} je ortogonální matici, potom $\mathbf{Q} \mathbf{U} \sim N_m(0, \mathbf{I}_m)$

Nen. \mathbf{q}_1 je vektor rov. $N(0, \sigma^2)$ veličin ($\mathbf{q}_1 \sim N_m(0, \sigma^2 \mathbf{I}_m)$)

$$\text{a } \frac{1}{\sigma^2} \mathbf{x}^T (\mathbf{I}_m - \mathbf{H}) \mathbf{x} = \frac{1}{\sigma^2} \mathbf{q}_1^T \mathbf{A} \mathbf{q}_1 = \frac{1}{\sigma^2} \sum_{i=1}^{m-m-1} \frac{q_{1i}^2}{\sigma^2} \sim \chi^2(m-m-1)$$

je tato soudobý množství $m-m-1$ rov. $N(0, 1)$ veličin, tzn.

3) z předchozí věty $\frac{\hat{\beta}_1 - \beta_1}{\sigma \sqrt{\text{var}} \hat{\beta}_1} \sim N(0, 1)$

$$T_{11} = \frac{\hat{\beta}_1 - \beta_1}{\frac{\text{var}}{\sigma^2} \hat{\beta}_1} = \frac{\frac{\hat{\beta}_1 - \beta_1}{\sigma \sqrt{\text{var}} \hat{\beta}_1}}{\frac{\text{var}}{\sigma^2}} \sim N(0, 1)$$

$$\frac{\text{var}}{\sigma^2} = \sqrt{\frac{(m-m-1) \hat{\beta}_1^2}{\sigma^2}} = \sqrt{\frac{\chi^2(m-m-1)}{m-m-1}}$$

1) \Rightarrow nezávislost

$$4) \hat{\beta} \sim N_n(\beta, \sigma^2 C(X^T X)^{-1} C^T) \text{ a. a.}$$

$$C(\hat{\beta} - \beta) = C\hat{\beta} - C\beta \sim N_n(0, \sigma^2 C(X^T X)^{-1} C^T)$$

Nach a. a. schreibt, da probst $Z \sim N_n(0, \Sigma)$, probst

$$Z^T \Sigma^{-1} Z \sim \chi^2(n)$$

probst Σ ist PD, u. regulär' matrix M tehn'; da $\Sigma = M M^T$

probst $M = \bar{M}^T Z$, probst $E V = \bar{M}^T E Z = 0$

$$\text{Cov}(V) = \bar{M}^T \Sigma (\bar{M})^T = \bar{M}^T M M^T (\bar{M}^T)^{-1} = \cancel{M} I_n \text{ a. a. } V \sim N_n(0, \sigma^2 I_n)$$

Nach a. a. schreibt V im zentralen $N(0, \sigma^2 I_n)$ verteilt' nach. uel.

$$Z^T \Sigma^{-1} Z = V^T M^T (\bar{M}^T)^{-1} M V = V^T V = \sum_{i=1}^n V_i^2 \sim \chi^2(n)$$

$$\text{da } Z = C(\hat{\beta} - \beta)$$

$$\Sigma^{-1} = \frac{1}{\sigma^2} [C(X^T X)^{-1} C^T]^{-1} \quad Q.E.D.$$

Werkzeug: mehrere residuum' $\hat{\epsilon}$

Def: Messungsmodell $y = X\beta + \epsilon$, da $\epsilon_1, \dots, \epsilon_n$ jem mehrere' a $\epsilon_i \sim N(0, \sigma^2)$. Nach $\hat{\beta}$ ist OLS β a $\hat{\epsilon} = \hat{y} - \hat{y}$ jem mehrere' residuum'. Daraus folgt:

$$1) \underline{E \hat{\epsilon}} = 0 \quad 2) \underline{\text{Cov}(\hat{\epsilon})} = \sigma^2 (I_n - H)$$

$$3) \text{ probst matrix } \epsilon \sim N_n(0, \sigma^2 I_n), \text{ probst } \hat{\epsilon} \sim N_n(0, \sigma^2 (I_n - H))$$

$$4) \text{jelliz. modell intercept, } \beta_0 \neq 0, \text{ probst } \sum_{i=1}^n \hat{\epsilon}_i = 0$$

$$5) \sum_{i=1}^n \hat{\epsilon}_i \hat{\beta}_{j,i} = 0 .$$

28. užíváme jiné, méně $\hat{e} = (I_m - HH) e$

(59)

1) $E \hat{e} = (I_m - HH) E e = 0$

2) $Cov(\hat{e}) = (I_m - HH) Cov(e) (I_m - HH)^T = \sigma^2 (I_m - HH)$

3) \hat{e} je LK následkem $e \Rightarrow \hat{e} \sim N(0, \sigma^2 (I_m - HH))$

4) musíme ~~zjistit~~ možnoučky rovnice $X^T X \beta = X^T y$ být řešitelné

$$X^T (y - X\beta) = 0 \quad \text{1 pro model s interceptem}$$

první rovnice: $\sum_{i=1}^m x_{i,1} \cdot (y_i - X^T \beta) = 0$

pro $\hat{\beta}$ lze platit $0 = \sum_{i=1}^m (y_i - X^T \hat{\beta}) = \sum_{i=1}^m (y_i - \hat{y}_i) = \sum_{i=1}^m \hat{e}_i$

5) z předchozího lze platiť pro OLS $\hat{\beta}$

$$X^T (y - X\hat{\beta}) = 0 \quad \text{první rovnice s tvarom } \hat{\beta}^T$$

$$0 = \hat{\beta}^T X^T (y - X\hat{\beta}) = \hat{\beta}^T (y - \hat{y}) = \hat{\beta}^T \hat{e} = \sum_{i=1}^m \hat{\beta}_i \hat{e}_i \quad \text{Q.E.D.}$$

Důkaz k body 4) a 5) dostaneme (stejně jako v jednorázové regrese)

$$\sum_{i=1}^m (y_i - \bar{y})^2 = \sum_{i=1}^m (\hat{y}_i - \bar{y})^2 + \sum_{i=1}^m (y_i - \hat{y}_i)^2$$

tedy $\underline{SST = SSR + SSE}$ (o modelu s interceptem)