

## Gauss - Markov Theorem

$\left. \begin{array}{l} \text{e}_i \text{ i.i.d.} \\ \sim N(0, \sigma^2) \end{array} \right\} \Rightarrow \text{OLS } \hat{\beta} \text{ is MLE, th. ji efficient' MVUE for } \beta$

- obzírce, že OLS  $\hat{\beta}$  je BLUE (best linear unbiased est.)
- parametr  $\beta$  (je jistě jediný)
- mohou ale ex. existovat lineární 'vzájemné' vztahy
- nebo nelineární vztahy

Def. Nechť  $\beta$  je reálný reprezent parametrů v LM. Rezidu,  $\hat{e}_i$  je lineární vztah  $\beta$ , tj. jisté hodnoty  $\beta_i$  je LK pozorování  $y_i$ ,  $i = 1, \dots, n$ , tedy

$$\hat{\beta}_i = \sum_{j=1}^m a_{ij} y_j \quad i = 0, \dots, m$$

v maticevém zapisu

$$\hat{\beta} = A y, \text{ kde } A = (a_{ij}) \quad i = 0, \dots, m \\ j = 1, \dots, n$$

Pozn: Obažd v modelu  $y = X\beta + \epsilon$  platí  $\dim(X) = n \times p$ , potom

OLS  $\hat{\beta}$  je lineární, neboť  $\hat{\beta} = \underbrace{(X^T X)^{-1}}_A X^T y$ .

### Věta (Gauss - Markov)

Uvažujme model  $y_i = X\beta + \epsilon_i$ , kde matice  $X$  má  $n \times p$  řádků,  $\epsilon_i, i = 1, \dots, n$ , jsou nezávislé a  $\epsilon_i \sim N(0, \sigma^2)$ . Potom OLS  $\hat{\beta}$  je BLUE parametr  $\beta$ .

Dů: nechť  $\hat{\beta} = A y$  je lineární vztah  $\beta$ , aby byl nezávislý mezi platin

$$E \hat{\beta} = \beta, \text{ tm. } E(A y) = A E y = A X \beta = \beta, \text{ tedy } (A X - I_{p+1}) \beta = 0$$

protože řádky řádků  $A X \in \mathbb{R}^{n \times p+1}$ , dležíme  $A X - I_{p+1} = 0$ , nebo ebo.  $A X = I_{p+1}$

Mördene horizontale mitte  $\hat{\beta}$

$$\text{Cov}(\hat{\beta}) = \text{Cov}(AY) = A \underbrace{\text{Cov} Y A^T}_{= \sigma^2 I_m} = \underbrace{\sigma^2 A A^T}_{= \sigma^2 I_m}$$

zeipte A ne kren  $A = (X^T X)^{-1} X^T + D$

(D je ročník mož A a matice pro OLS vektor)

počítat obrazce, že pro nehomogéní lin. vektor  $\hat{\beta} = A\gamma$ , tedy minimizuje rozdíl, můžeme diktovat  $D=0$ , kde máme dohoda

dohoda o dohodě

$$\begin{aligned} \text{Cov}(\hat{\beta}) &= \sigma^2 ((X^T X)^{-1} X^T + D)(X(X^T X)^{-1} + D^T) = \\ &= \sigma^2 \left[ (X^T X)^{-1} + D X (X^T X)^{-1} + (X^T X)^{-1} X^T D^T + D D^T \right] \end{aligned}$$

z počítání nehomog.

$$AX = [(X^T X)^{-1} X^T + D]X = I_{n+1} + D X = I_{n+1} \Rightarrow D X = 0 \text{ a} \\ \text{takže } X^T D^T = 0$$

Nm.  $\text{Cov}(\hat{\beta}) = \sigma^2 [(X^T X)^{-1} + D D^T]$

pro diagonální prob. slouč.

$$\text{Var} \hat{\beta}_i = \sigma^2 \left[ \cancel{n_i} n_i + \sum_{j=1}^n d_{ij}^2 \right] \quad i = 0, \dots, m$$

protože  $n_i \geq 0$  a  $\sum_{j=1}^n d_{ij}^2 \geq 0 \Rightarrow \text{Var} \hat{\beta}_i$  je minimizovaná vždy

$$\sum_{j=1}^n d_{ij}^2 = 0, \text{ t. j. } d_{ij} = 0 \quad j = 1, \dots, m$$

ještě  $\forall i = 0, \dots, m \Rightarrow D = 0$

Nm. lin. nehomog. vektor  $\hat{\beta}$ , tedy minimizuje  $\text{Var}(\hat{\beta}_i)$ ,  $i = 0, \dots, m$

je  $\hat{\beta} = (X^T X)^{-1} X^T Y$ .

Q.E.D.

## Tichovského modely - kolmá ANOVA

(62)

### a) Celkový F-test (overall F-test)

- pojďme říct, že je model stat. možná výhodný, tj. že aleponi jsou s hrb.  $\beta_1, \dots, \beta_m$  si něco
- mohli bychom testovat jednotlivé hrb.  $H_0: \beta_i = 0$  pomocí alternativního F-testu
- celkový člen I. druhu by mohl být něčemu, pokud máme hrbní proměnné  
množství bychom hrbní můžeme pro jednotlivé hrb., což může provést jednotlivé členy II. druhu (tzn. můžeme obecnou proměnnou hrb. jeho můžeme a testy významnosti významnosti proměnných a modelu)
- nově je řešení problém multikolinearity (vzájemného vlivu jednotlivých vlivů) množství vlivů a obecnou proměnnou, kdy můžeme mít i obecnou proměnnou všechny koeficienty  $\beta_i = 0$ , tedy říct že řešení je model celkové významnosti (vzhledem na říct)
- řešení je dobré mít řešení statistické pro tento člen by dobré mít řešení statistické pro tento

$$H_0: \beta_1 = \beta_2 = \dots = \beta_m = 0 \quad \times \quad H_1: (\exists i \in \hat{m}, \quad \beta_i \neq 0) \\ \text{aleponi jich } \beta_i \neq 0, \quad i=1, \dots, m$$

ANOVA průbuz pro jedn. regresi nerozdíl, tedy vlastnosti

$$F = \frac{\frac{SSR}{m}}{\frac{SSE}{n}} \quad \text{by mohla být významná}$$

(významnost je v obecných průbuzech & Tichovského postoji)

Ortsvektor:  $\bar{x}_j = \frac{1}{m} \sum_{i=1}^m x_{ij}$  primer  $j$ -teh řádu matice  $X$

$$\bar{X} = \begin{pmatrix} \bar{x}_0 & \bar{x}_1 & \cdots & \bar{x}_m \\ \vdots & \vdots & & \vdots \\ \bar{x}_0 & \bar{x}_1 & \cdots & \bar{x}_m \end{pmatrix}_{m \times m+1}$$

$$\underbrace{(X_c)_{ij}}_{\text{centrovane' matice regresion'}} = x_{ij} - \bar{x}_j \quad \begin{matrix} i = 1, \dots, m \\ j = 1, \dots, m \end{matrix}$$

Vek.:  $\approx$  model  $y = XB + \varepsilon$ , kde  $\varepsilon$  je náhodové a  $\varepsilon_i \sim (0, \sigma^2)$ ,

$i = 1, \dots, m$  plati

$$E\left(\frac{SSR}{n}\right) = \sigma^2 + \frac{\hat{\beta}^T (X - \bar{X})^T (X - \bar{X}) \hat{\beta}}{m} = \sigma^2 + \frac{\hat{\beta}^T X_c^T X_c \hat{\beta}}{m}$$

kde  $\hat{\beta} = (\beta_0, \dots, \beta_m)$ .

D&Z:

$$\hat{y}_j = \hat{\beta}_0 + \sum_{i=1}^m x_{ij} \hat{\beta}_i \quad \frac{\partial SSE}{\partial \beta_0} = \sum_{i=1}^m (y_i - (\beta_0 + \sum_{j=1}^m x_{ij} \hat{\beta}_j)) = 0$$

||

$$\hat{\beta}_0 = \bar{y} - \sum_{j=1}^m \bar{x}_j \hat{\beta}_j$$

celkovy  $\hat{y}_j - \bar{y} = \sum_{i=1}^m (x_{ij} - \bar{x}_j) \hat{\beta}_i \quad i = 1, \dots, m$

respone' matice  $\hat{y} - \bar{y} = (X - \bar{X}) \hat{\beta} \quad$  kde  $\bar{y} = (\bar{y}_1, \bar{y}_2, \dots, \bar{y}_m)^T$

potom říkame řádové  
matice  $X - \bar{X}$  je řádový

$$\underline{SSR} = \sum_{i=1}^m (\hat{y}_i - \bar{y}_i)^2 = (\hat{y} - \bar{y})^T (\hat{y} - \bar{y}) = \hat{\beta}^T \underbrace{(X - \bar{X})^T (X - \bar{X})}_{A} \hat{\beta} = \hat{\beta}^T A \hat{\beta}$$

V:  $Z = \bar{y}^T A \bar{y}$  je kvadratické forma - necht  $E\bar{y} = \mu$  a  $Cov\bar{y} = \Sigma$ .

potom platí  $\underline{EZ = \mu^T A \Sigma + \mu^T A \mu}$

nejistotné rozloženie matice  $A$

$$\bar{X} = \frac{1}{m} BX, \text{ kde } B = \begin{pmatrix} 1 & 1 & \cdots & 1 \\ 1 & 1 & \cdots & 1 \\ \vdots & \vdots & \ddots & \vdots \\ 1 & 1 & \cdots & 1 \end{pmatrix}_{m \times m} \text{ je loby}$$

$$X - \bar{X} = \left( I_m - \frac{1}{m} B \right) X \quad (X - \bar{X})^T = X^T \left( I_m - \frac{1}{m} B \right)$$

$$\underline{A} = (X - \bar{X})^T (X - \bar{X}) = X^T \left( I_m - \frac{1}{m} B \right)^2 X = \underline{X^T \left( I_m - \frac{1}{m} B \right) X}$$

$$I_m - \frac{2}{m} B + \frac{B^2}{m}$$

dile  $A\Sigma = \sigma^2 X^T \left( I_m - \frac{1}{m} B \right) X (X^T X)^{-1}$   
 $\text{cov } \hat{\beta}$

$$\underline{\mu(A\Sigma)} = \mu(A\hat{\beta}\Sigma\hat{\beta}) = \sigma^2 \mu \left\{ X (X^T X)^{-1} X^T \left( I_m - \frac{1}{m} B \right) \right\} = \sigma^2 \mu \left\{ H - \frac{1}{m} H B \right\}$$

$$\mu(AB) = \mu(BA)$$

$$= \sigma^2 \left( \mu(H) - \frac{1}{m} \mu(HB) \right) = \sigma^2 \left( \mu(H) - \frac{1}{m} \mu(B) \right) = \underline{\sigma^2 m}$$

— nere  $HX = X$  a  $\|H\| = 1$   
 $\|H\| = (1, -1, 1)^T$  je pravé sloupec  $X$ , kde  $H\| = 1$   
 — a loby  $HB = B$

celková loby

$$\underline{E\left(\frac{SSR}{m}\right)} = \frac{1}{m} \left( \sigma^2 m + \beta^T (X - \bar{X})^T (X - \bar{X}) \beta \right) = \underline{\sigma^2 + \frac{1}{m} \beta^T (X - \bar{X})^T (X - \bar{X}) \beta}$$

dile  $(X - \bar{X}) \beta = X_c \beta$ , protože pravé sloupec matice  $X - \bar{X}$  je nulový vektor.

Pozn: pokud  $\beta_0 = 0$  pak  $E \frac{SSR}{m} = \sigma^2 = E \beta_m^2$

Q.E.D.

Když  $\beta_0 \neq 0$  získáme, že  $E \frac{SSR}{m} > \sigma^2$ , tedy mohou být loby

$F = \frac{\frac{SSR}{m}}{\frac{\beta_m^2}{m}}$  loby můžeme zjistit  $H_0: \beta_0 = 0$   
 lobě potřebujeme mít  $F$  na  $H_0$ .

Notiz:  $\hat{\gamma}_i \sim \text{normal } \hat{\gamma} = X\beta + \varepsilon$  (\*\*\*) given  $x_1, \dots, x_n$  (65)

$\sim \text{i.i.d. } N(0, \sigma^2)$ .  $\text{Fehler } \beta_0 = 0$  ( $\beta_1 = \beta_2 = \dots = \beta_m = 0$ ),

polar

$$\underline{F \sim F(m, m-m-1)}$$

2.  $\sim$  der mind. mit gleicher Wahrscheinlichkeit

$$SSR = \hat{\beta}^T X^T (I_m - \frac{1}{m} B) X \hat{\beta} = \hat{\gamma}^T (I_m - \frac{1}{m} B) \hat{\gamma}$$

nutzbarer Zählerausdruck

$$\begin{aligned}\hat{\gamma} &= H\gamma = H(X\beta + \varepsilon) = H(\underbrace{H\beta_0}_{\parallel} + Hx_0\beta_0 + H\varepsilon) = \beta_0 \underbrace{H\parallel}_{\parallel} + \underbrace{Hx_0\beta_0}_{\parallel} + H\varepsilon \\ &= \beta_0 \parallel + H\varepsilon\end{aligned}$$

$$\underline{SSR = (\beta_0 \parallel^T + \varepsilon^T H) (I_m - \frac{1}{m} B) (\beta_0 \parallel + H\varepsilon)} = \varepsilon^T H (I_m - \frac{1}{m} B) H \varepsilon$$

$$\text{ale } (I_m - \frac{1}{m} B) \parallel = 0 \quad \text{a } (I_m - \frac{1}{m} B) \text{ ist symmetrisch}$$

daher steht  $H = H^T$ ,  $H^2 = H$  a  $H^T B = B H = B$  (weil  $H\parallel = \parallel$ )

celles steht darum

$$\underline{SSR = \varepsilon^T \underbrace{(H^T - \frac{1}{m} B)}_{C} \varepsilon = \varepsilon^T C \varepsilon}$$

$$\text{pro Matrie } C \text{ steht } \underline{C^T = (H^T - \frac{1}{m} B^T)^T = (H^T - \frac{1}{m} B)^T = C}$$

$$\begin{aligned}\sim \underline{C^2} &= (H^T - \frac{1}{m} B^T)(H^T - \frac{1}{m} B) = H^2 - \frac{1}{m} H^T B - \frac{1}{m} B^T H + \frac{1}{m^2} B^2 = \\ &= H^2 - \frac{2}{m} B^T H + \frac{1}{m^2} B^2 = H^2 - \frac{1}{m} B^T H = \underline{C}\end{aligned}$$

da  $C$  ist symmetrisch a idempotenter Koeff.

$$\underline{L(C)} = \text{rk}(C) = \text{rk}(H^T - \frac{1}{m} B) = m+1-1 = \underline{m}$$

met o spektrum rooklaag  $\Rightarrow$   $\exists Q$  og a diag d tel,  $\bar{u}$

$$C = Q^T \Lambda Q = Q^T \begin{pmatrix} I_m & 0 \\ 0 & 0 \end{pmatrix} Q$$

identical with notice no.  
rebook with a new?

$$\underline{SSR} = \underbrace{\mathbf{x}^T Q^T \begin{pmatrix} I_m & 0 \\ 0 & 0 \end{pmatrix} Q \mathbf{x}}_{\mathbf{Z}} = \mathbf{Z}^T \begin{pmatrix} I_m & 0 \\ 0 & 0 \end{pmatrix} \mathbf{Z} = \sum_{i=1}^n Z_i^2 \quad \text{byle}$$

$$Z_i \sim N(0, \sigma^2) \text{ merkni!}$$

$$\frac{Z_i}{\sigma} \sim N(0,1) \quad \text{and} \quad \frac{\sum Z_i^2}{\sigma^2} \sim \chi^2(m)$$

$$\text{Ans. } \frac{\frac{\chi^2(m)}{m} \left\{ \frac{SSR}{\sigma^2 \cdot m} \right.}{\left. \frac{(m-m-1) P_m^2}{\sigma^2} \cdot \frac{1}{m-m-1} \right\}} = \frac{\frac{SSR}{m}}{P_m^2} = F \sim F(m, m-m-1)$$

podvod náhodnosti, tzn.  $\frac{SSR}{m} \sim P_m^2$

jej rezonancie'

Não nulos, se  $s_{ii}$  é zero ou não residuais  $\hat{e}_i$ ,  $i = 1, \dots, n$

$$SSR = \mathbf{e}^T H \left( I_n - \frac{1}{m} B \right) H \mathbf{e} = \underbrace{\mathbf{e}^T H \left( I_n - \frac{1}{m} B \right)}_{= I_m - \frac{1}{m} B} \underbrace{\left( I_n - \frac{1}{m} B \right) H \mathbf{e}}_{= H^T \mathbf{e}} = \cancel{\mathbf{e}^T H^T H \mathbf{e}} = \cancel{m^T m}$$

$$\text{bore mat} = (I_n - \frac{1}{n} B) H x = K x$$

$$\hat{x} = (I_m - \lambda H)x \equiv Lx$$

$$\begin{pmatrix} \text{as} \\ \hat{x} \end{pmatrix} = \begin{pmatrix} K \\ L \end{pmatrix} \text{to} \quad \text{Na. na' vierosérme' } \\ \text{manghi' nodéan'}$$

$$\text{Cov} \begin{pmatrix} w \\ \hat{z} \end{pmatrix} = \begin{pmatrix} K & L \\ L^T & I_L \end{pmatrix} \text{Cov } \begin{pmatrix} x \\ y \end{pmatrix} \begin{pmatrix} K^T & L^T \\ L & I_L \end{pmatrix} = \sigma^2 \begin{pmatrix} K K^T & K L^T \\ L K^T & L L^T \end{pmatrix}$$

$$KLL^T = \underbrace{\left(I_m - \frac{1}{m}B\right)H\left(I_m - H\right)}_{= H - H^2} = 0$$

Most likely whistlers, the  
two are a bit more resonant,  
whistling

TEST:  $H_0: \beta_1 = \beta_2 = \dots = \beta_m = 0$   $F > F_{1-\alpha}(m, m-m-1)$

Pozn.: odvozen pro  $\epsilon_i \sim N(0, \sigma^2)$ , obecně se používá i logika  
neživé, pro velkou m může být cesta odvození pouze CLV

### Tabelka ANOVA

Source	df	SS	MS	F
Regression	m	SSR	$MSR = \frac{SSR}{m}$	$\frac{MSR}{MSE}$
Residual	$m-(m+1)$	SSE	$MSE = \frac{SSE}{m-m-1} = \sigma^2$	
Total	$m-1$	SST	$R^2$	$\bar{R}^2$

### Definice (vzácnostní) determinace $R^2$

podobně jako u jednorozné represe, kdy F-test slouží k  
test významnosti  $R^2$ , ~~definice~~ definování jeho

$$\underline{R^2 = \frac{SSR}{SST} = 1 - \frac{SSE}{SST}} \quad (SST = SSR + SSE)$$

protože

$$F = \frac{\frac{SSR}{m}}{\frac{SSE}{m-m-1}} = \frac{m-m-1}{m} \left( \frac{\frac{SSR}{SST}}{\frac{SSE}{SST}} \right) = \frac{m-m-1}{m} \frac{R^2}{1-R^2}$$

což je vlastně funkce  $R^2$ . (opis  $R^2 \in (0,1)$ )

Pozn.:  $R^2$  je možné vypočítat přidáním ~~nej~~ nových proměnných  $x_i$ ,  
= logikou vlastností nezávislosti. (pro m LN proměnných  $x$   
= m poskytují dlešence „perfect fit“). - overfitting

vyvážené:

$R^2 = 1 - \frac{SSE}{SST}$ , kde  $SST$  je sume čtverců dat a  
ale  $SSE$  může být méně pravdivý  
přenášejí  $x$   
minimizujeme tvar  $(y - X\beta)^T (y - X\beta)$   
přes vektory rozdílů  $\beta$

Zn.  $\frac{SSE}{SST}$  je rezidualní funkce prož působení a když  
 $R^2$  je nelesník "funkce prož působení"  
proto se někdy definuje adjusted coefficient of determination  
(adjusted coefficient of determination)

$$\bar{R}^2 = R_{adj}^2 = 1 - \frac{\frac{SSE}{n-m-1}}{\frac{SST}{n-m-1}} = \frac{1 - \frac{n-1}{n-m-1} \frac{SSE}{SST}}{n-m-1}$$

( $n$  počtem dat alespoň  $SSE$  ale  $= n-m-1$ )  
jisté kompenzace