

## IS a $t$ -testy pro parametry

(69)

- pokud je model správný, lze mít zajímavé statistické hodnoty
- $\Rightarrow$  ta první je a TH stejně jako v jednorázovém regrese
- výsledek je odvozený pro normální chyby
- $\Rightarrow$  používá se pouze i pro jiné typy chyb  
(je jistě předpokladem, že je chyba normální a výsledek je vypočítán pro některou m)

pro konstrukci používajeme dekomponovanou vlastnost

$$T_{ij} = \frac{\hat{\beta}_{ij} - \beta_0}{\sigma_m \sqrt{v_{ij}}} \sim t(n-m-1), \text{ kde } v_{ij} = (\mathbf{x}' \mathbf{x})_{jj}^{-1}$$

Normalizovaný rozložení sítance  $100(1-\alpha)\%$  je pro  $\beta_0$  ve formě

$$(\hat{\beta}_0 - L_{1-\frac{\alpha}{2}}(n-m-1) \sigma_m \sqrt{v_{00}}, \hat{\beta}_0 + L_{1-\frac{\alpha}{2}}(n-m-1) \sigma_m \sqrt{v_{00}})$$

$\Rightarrow$  jejich pravoukové hodnoty musí být vzdáleny od nuly pro test

$$H_0: \beta_0 = b_0 \quad \times \quad H_1: \beta_0 \neq b_0$$

( $H_0$  znamená, že  $b_0 \notin (\hat{\beta}_0, \bar{\beta}_0)$ , kde je  $\bar{\beta}_0$  pro  $\beta_0$ )

nebo

$$\frac{|\hat{\beta}_0 - b_0|}{\sigma_m \sqrt{v_{00}}} > L_{1-\frac{\alpha}{2}}(n-m-1)$$

pro  $b_0 = 0$  dostaneme test významnosti  $\beta_0$ , tzn.  $H_0: \beta_0 = 0$

Závěr, pokud

$$\frac{|\hat{\beta}_0|}{\sigma_m \sqrt{v_{00}}} > L_{1-\frac{\alpha}{2}}(n-m-1)$$

- Po2N.
- pokud nejsou používáni předpohledy modelu  
nebo není přítomen bivariatek, ale může  
existovat několik nezávislých proměnných (dle R-testu)
  - v případě bivariatek, model může být významný  
(dle celkového F-testu), ale vtedy může být významný  
proměnný se mohou jevit jiné nezávislosti (dle R-testu)
  - například, pokud může model všechny používat nezávislé proměnné,  
některé proměnné se mohou jevit významné, i když jsou  
vzhledem k nim
  - při použití R-testu je třeba být obecněm  
(postupným obecněm)

Prí. 5.26, str. 230

Prí. 5.27, str. 231

Po2K: vlastnosti F,  $R^2$  a t jsou vžilací pro rozbor vlivu  
jedn. proměnných, nemohou být ale používány vlivu autovariabil

## Obeza' linearin' hipoteza

F-test (celhoy) a  $n$ -beri giv spe. prüfender obeza' linearin' hipoteza

(77)

$$H_0 : C\beta = b \quad \times \quad H_1 : C\beta \neq b,$$

höre  $C \in \mathbb{R}^{n \times (m+1)}$  a  $l(C) = n$  (d.h.  $n \leq m+1$ )

- mani  $C\beta = b$  representasi re lin. regressiyel polinom

$$\sum_{j=0}^m c_{ij} \beta_j = b_i \quad i = 1, \dots, n$$

Pozn: a) volle  $b = (0, \dots, 0)^T$  a  $C = \left( \begin{array}{c|cccc} 0 & 1 & 0 & \dots & 0 \\ 0 & 0 & 1 & \dots & 0 \\ \vdots & & & \ddots & \\ 0 & 0 & \dots & 0 & 1 \end{array} \right)_{m \times (m+1)}$   
niedre und null

$$H_0 : C\beta = 0 \quad \Leftrightarrow \quad H_0 : \beta_1 = \beta_2 = \dots = \beta_m = 0$$

b) volle  $b = 0$  a  $C = (0, \dots, 1, 0, \dots, 0)$  niedre und null

$$H_0 : \beta_j = 0$$

c)  $\sim$  model  $Y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \beta_3 x_3 + \beta_4 x_4 + \epsilon$

chene berücksichtigen, si  $\beta_2 = 0$  a  $\beta_3 = \beta_4$

to da niedre volle  $C = \begin{pmatrix} 0 & 1 & 0 & 0 \\ 0 & 0 & 1 & -1 \end{pmatrix}$   $b = (0, 0)^T$

Ora test  $H_0$  modelline 2 modell:

- 1) full model (full model) - ber polinom in  $C\beta$
- 2) reduzierter model (reduced model) - re-prüfbar, in full  
 $H_0 : C\beta = b$

(72)

Osnové příslušné reziduální rovnice:  $SSE_F$  a  $SSE_R$

(kde platí  $SSE_F \leq SSE_R$ )

- pokud neplatí  $H_0$ , dílčí význam, kdy  $\Delta SSE = SSE_R - SSE_F$  lze vysvětlit netriviálními vlivy chyby  $\sigma^2$ ,  $H_0$  lze odmítnout, pokud  $\frac{\Delta SSE}{\sigma^2}$  bude výška

- základní F-testu  $F = \frac{\frac{\Delta SSE}{n}}{\frac{SSE_F}{n_m}}$  ~  $F(n, n-m-1)$

Předpoklad pro normální chyby  
je platnost  $H_0$ .

Obr. možné F-testy pro  $H_0: \beta_1 = \beta_2 = \dots = \beta_m = 0$  ~ model  $(*)$   
(full model)

neobhájený model model:  $Y_i = \beta_0 + \epsilon_i, i=1, \dots, n \Rightarrow \hat{\beta}_0 = \bar{Y}$

a  $SSE_R = \sum_{i=1}^n (\gamma_i - \bar{Y})^2 = SST$ , lze

$$\underline{\Delta SSE} = SST - SSE_F = \sum_{i=1}^n (\gamma_i - \bar{Y})^2 - \sum_{i=1}^n (\hat{Y}_i - \bar{Y})^2 = SSR$$

a relativní  $F = \frac{\frac{SSR}{m}}{\frac{SSE_F}{n_m}} = F_{\text{overall}} \sim F(m, n-m-1)$   
jde jen jen o obhájení

Věta: Neplatí ~ model  $(*)$  pokud  $x_1, x_2, \dots, x_m$  jsou nezávislé a  
 $a f(x) = m+1$   
 $\epsilon_i \sim N(0, \sigma^2)$ . Osnové  $SSE_F$  reziduální p.č. plní modelu

~  $SSE_R$  res. o.č. ~~plní~~ plní  $H_0: CB = b$ . Ostatně, že plní modelu, kde

$H_0$  je splněno:  $F = \frac{\frac{\Delta SSE}{n}}{\frac{SSE_F}{n_m}} \sim F(n, n-m-1)$ .

Lemma: Derivative  $\hat{\beta}_F$  zu  $\hat{\beta}_R$  LSE für  $\beta$  in einem reduzierten Modell. Dasselbe gilt.

(73)

$$1) \hat{\beta}_F = \hat{\beta}_R - (\mathbf{x}^T \mathbf{x})^{-1} \mathbf{C}^T \mathbf{A} (\mathbf{C} \hat{\beta}_P - b), \text{ bsp } \mathbf{A} = (\mathbf{C} (\mathbf{x}^T \mathbf{x})^{-1} \mathbf{C}^T)^{-1}$$

$$2) \Delta SSE = SSE_R - SSE_F = \underline{(\mathbf{C} \hat{\beta}_F - b)^T \mathbf{A} (\mathbf{C} \hat{\beta}_F - b)}$$

$$\text{Z.B. 1) wäre } \hat{\beta}_F = (\mathbf{x}^T \mathbf{x})^{-1} \mathbf{x}^T \gamma_1, \text{ manche reicht } \hat{\beta}_R$$

$$\text{Lösung minimiert } g(\beta) = (\gamma - \mathbf{x}\beta)^T (\gamma - \mathbf{x}\beta) \text{ zu gewünscht } \mathbf{C}\beta = b$$

Lagrangean Formel

$$L = L(\beta, \lambda) = g(\beta) - 2\lambda^T (\mathbf{C}\beta - b), \text{ bsp } \lambda = (\lambda_1, \dots, \lambda_n)$$

$$L = \underbrace{\gamma^T \gamma}_{} - 2 \underbrace{\gamma^T \mathbf{x}\beta}_{= \beta^T \mathbf{x}^T \gamma_1} + \underbrace{\beta^T \mathbf{x}^T \mathbf{x}\beta}_{= \beta^T \mathbf{C}^T \beta} - \cancel{b^T \beta} - 2 \underbrace{\lambda^T \mathbf{C}\beta}_{= \beta^T \mathbf{C}^T \lambda} + 2 \underbrace{\lambda^T b}_{= \beta^T \mathbf{C}^T b}$$

$$\frac{\partial L}{\partial \beta} = \left( \frac{\partial L}{\partial \beta_0}, \frac{\partial L}{\partial \beta_1}, \dots, \frac{\partial L}{\partial \beta_m} \right)^T = \underline{2 \mathbf{x}^T \mathbf{x}\beta - 2 \mathbf{x}^T \gamma_1 - 2 \mathbf{C}^T \lambda} = 0$$

$$\frac{\partial L}{\partial \lambda} = \left( \frac{\partial L}{\partial \lambda_1}, \dots, \frac{\partial L}{\partial \lambda_n} \right)^T = \underline{\mathbf{C}\beta - b} = 0$$

$$\approx \text{from' vorne} \quad \hat{\beta}_R = (\mathbf{x}^T \mathbf{x})^{-1} \mathbf{x}^T \gamma_1 + (\mathbf{x}^T \mathbf{x})^{-1} \mathbf{C}^T \lambda = \hat{\beta}_F + (\mathbf{x}^T \mathbf{x})^{-1} \mathbf{C}^T \lambda$$

dann ist das drückt:

$$\mathbf{C} \hat{\beta}_R - b = \mathbf{C} \hat{\beta}_F - b + \mathbf{C} (\mathbf{x}^T \mathbf{x})^{-1} \mathbf{C}^T \lambda = 0$$

$$\text{Mz. } \lambda = - (\mathbf{C} (\mathbf{x}^T \mathbf{x})^{-1} \mathbf{C}^T)^{-1} (\mathbf{C} \hat{\beta}_F - b)$$

$$\hat{\beta}_R = \hat{\beta}_F - (\mathbf{x}^T \mathbf{x})^{-1} \mathbf{C}^T \underbrace{(\mathbf{C} (\mathbf{x}^T \mathbf{x})^{-1} \mathbf{C}^T)^{-1} (\mathbf{C} \hat{\beta}_F - b)}_{= A} = \hat{\beta}_F - (\mathbf{x}^T \mathbf{x})^{-1} \mathbf{C}^T \mathbf{A} (\mathbf{C} \hat{\beta}_F - b)$$

2)  $\approx$  dr. with  $\hat{\beta} = (X^T X)^{-1} X^T \gamma$  min.,  $\tilde{\alpha}$

(75)

$$g(\beta) - g(\hat{\beta}_F) = (\beta - \hat{\beta}_F)^T X^T X (\beta - \hat{\beta}_P) + \epsilon$$

$$\text{donc } \beta = \hat{\beta}_R$$

$$\Delta SSE = g(\hat{\beta}_R) - g(\hat{\beta}_F) = (\hat{\beta}_R - \hat{\beta}_F)^T X^T X (\hat{\beta}_R - \hat{\beta}_P) =$$

$$= (C \hat{\beta}_F - b)^T A^T C (X^T X)^{-1} X^T X (X^T X)^{-1} C^T A (C \hat{\beta}_P - b) = *$$

provoz  $A^T = A$ , steh'  $A^T \underbrace{C(X^T X)^{-1} C^T A}_{A^{-1}} = A$

$$* = (C \hat{\beta}_P - b)^T A (C \hat{\beta}_P - b) \quad Q.E.D.$$

Dl. věž: nejdříve minime,  $\tilde{\alpha} \sim \frac{\Delta SSE}{\sigma^2} \sim \chi^2(n)$   $\approx H_0: C\beta = b$

$$\approx H_0: Y \sim N(X\hat{\beta}_R, \sigma^2 I_m) \Rightarrow \hat{\beta}_P = (X^T X)^{-1} X^T Y, \text{ tzn.}$$

$$\hat{\alpha} = C \hat{\beta}_P - b \sim N(E(\hat{\alpha}), \text{cov}(\hat{\alpha}))$$

$$E \hat{\alpha} = E(C \hat{\beta}_P - b) = E(C(X^T X)^{-1} X^T Y) - b = C(X^T X)^{-1} X^T EY - b =$$

$$= C(X^T X)^{-1} X^T \beta_R - b = C\beta_R - b = \underline{0 \text{ na } H_0}$$

$$\text{cov}(\hat{\alpha}) = C \text{cov}(\hat{\beta}_P) C^T = \sigma^2 \underbrace{C(X^T X)^{-1} C^T}_{= A^{-1}} = \sigma^2 (A^{-1})$$

$$\Rightarrow \hat{\alpha} = C \hat{\beta}_P - b \sim N(0, \sigma^2 A^{-1}) \approx H_0$$

$$\text{tzn. } \frac{\Delta SSE}{\sigma^2} = \frac{\hat{\alpha}^T A \hat{\alpha}}{\sigma^2} \sim \chi^2(n) \quad \left( \text{bod 4) věž vln. (55)} \right)$$

$$Z \sim N_n(0, \Sigma) \Rightarrow Z^T \Sigma^{-1} Z \sim \chi^2(n)$$

bod 1)  $\Rightarrow \hat{\beta}_F \sim D_m^2$  nezávisl'

$\Delta SSE$  je funkce pořadí  $p_f$ , tzn. maximální je  $p_m$

(75)

Ahoj

$$F = \frac{\frac{\Delta SSE}{\sigma^2 \cdot n}}{\frac{(n-m-1) / p_m}{\sigma^2 (n-m-1)}} = \frac{\Delta SSE}{\frac{n}{p_m}} \sim F(n, n-m-1)$$

Q.E.D.

T02N: Příslušný rozložení  $SST = SSE + SSR$  doložené

$$\Delta SSE = SSR_F - SSR_R$$

interpretace: ↓ minimální regresního raciontu čtvrti dle hypoteze  $H_0$ .

dále

$$\underline{SSR_F = SSR_R + \Delta SSE}$$

extra sum of squares      přidání k SSR dle hypoteze  $H_0$

Např. pokud  $\beta = (\beta_0, \beta_1, \dots, \beta_{m-1}, 0)$  tzn.  $\beta_m = 0$

a shatkový model m'  $\beta = \beta_F$ , potom  $\Delta SSE$  je extra regresní raciont čtvrti zahrnující přidanou  $\beta_m$  do modelu.

- umožňuje rozložit SSR shatkového modelu na jednotlivé části  $(x_1, x_2 | x_1, x_3 | x_2 x_1, \dots)$

Fr. analogie k Fr. 5.25 str. 238

T02N: joint confidence regions viz Ek. 5.30 str. 233 ???

Prediktör

jméno může odvozovat' model, můžeme ho použít pro bodové  
a intervalové predikce i když je jednorozměrná regrese

a) prediktér  $E\hat{Y}_{x_0}$ 

nechť  $x_0 = (1, x_{0,1}, \dots, x_{0,m})^T$  je nový bod pro kterého se

$$\text{bodový odhad } E(\hat{Y}_{x_0}) \text{ je } \hat{Y}_{x_0} = \hat{\beta}_0 + \sum_{j=1}^m x_{0,j} \hat{\beta}_j = x_0^T \hat{\beta}$$

Nu.  $\text{Var}(\hat{Y}_{x_0}) = x_0^T \text{Var}(\hat{\beta}) x_0 = \underbrace{\sigma^2 x_0^T (X^T X)^{-1} x_0}_* \text{ a může být výraznější}$

pozor!  $\hat{\sigma}^2(\hat{Y}_{x_0}) = \sigma^2 [x_0^T (X^T X)^{-1} x_0]$

realní prediktér

spec. případ  $x_0^T = x_0^T$  (z - 1' řádku nulového řádku  $X$ )

$$\hat{\sigma}^2(\hat{Y}_{x_0}) = \sigma^2 [x_0^T (X^T X)^{-1} x_0] = \underbrace{\sigma^2 h_{00}}_{\text{hude } h_{00} = (H)_{00}}, \quad \text{kde } H = X(X^T)^{-1} X^T$$

pro normální chybky lze odvodit IS pro  $E\hat{Y}_{x_0} = y_{x_0}$ .

představte  $\hat{Y}_{x_0}$  je Lk náh. vel. o několikařadovém norm. rozdělení,

na normální rozdělení je  $E\hat{Y}_{x_0} = y_{x_0} = x_0^T \beta$  a  $\text{Var}(\hat{Y}_{x_0}) = *$

Nu.  $\frac{\hat{Y}_{x_0} - y_{x_0}}{\sigma \sqrt{x_0^T (X^T X)^{-1} x_0}} \sim N(0, 1)$  a dle rozdílnosti  $\hat{\beta} - \beta = \sigma^2$

$$\frac{\hat{Y}_{x_0} - y_{x_0}}{\sigma_m \sqrt{x_0^T (X^T X)^{-1} x_0}} \sim t_{(n-m-1)} \Rightarrow \frac{100(1-\alpha)\%}{\left( \hat{Y}_{x_0} \pm t_{\frac{n-m-1}{2}} \cdot \sigma_m \sqrt{x_0^T (X^T X)^{-1} x_0} \right)}$$

b) intervaly predikce pro  $\hat{Y}_{x_0}$

~~cestou~~ volej' volej' je  $\hat{Y}_{x_0}$ .

pohled  $\hat{Y}_{x_0}$  je shodný s hodnotou  $\hat{Y}_{x_0} = \text{body } x=x_0$ , pohled  $\hat{Y}_{x_0}$  a  $\hat{Y}_{x_0}$

musíte rozvíjet' na předpohlasku, že poz.  $\hat{Y}_{x_0}, Y_1, \dots, Y_m$  jsou rozdílné  
(což je předpokládáno)

pohled

$$\text{Var}(\hat{Y}_{x_0} - Y_{x_0}) = \text{Var}(\hat{Y}_{x_0}) + \text{Var}(Y_{x_0}) = \sigma^2(1 + x_0^T (X^T X)^{-1} x_0),$$

Abeceda

$$\frac{\hat{Y}_{x_0} - Y_{x_0}}{\sigma \sqrt{1 + x_0^T (X^T X)^{-1} x_0}} \sim N(0, 1) \quad \text{a} \quad \frac{\hat{Y}_{x_0} - Y_{x_0}}{D_m \sqrt{1 + x_0^T (X^T X)^{-1} x_0}} \sim t(n-m-1)$$

je předpohlaska normality chyb

100(1-α)% IP pro  $\hat{Y}_{x_0}$  tedy je

$$\left( \hat{Y}_{x_0} \pm t_{1-\alpha/2}(n-m-1) \cdot D_m \sqrt{1 + x_0^T (X^T X)^{-1} x_0} \right)$$

Obr.

Pozn: extrapolační

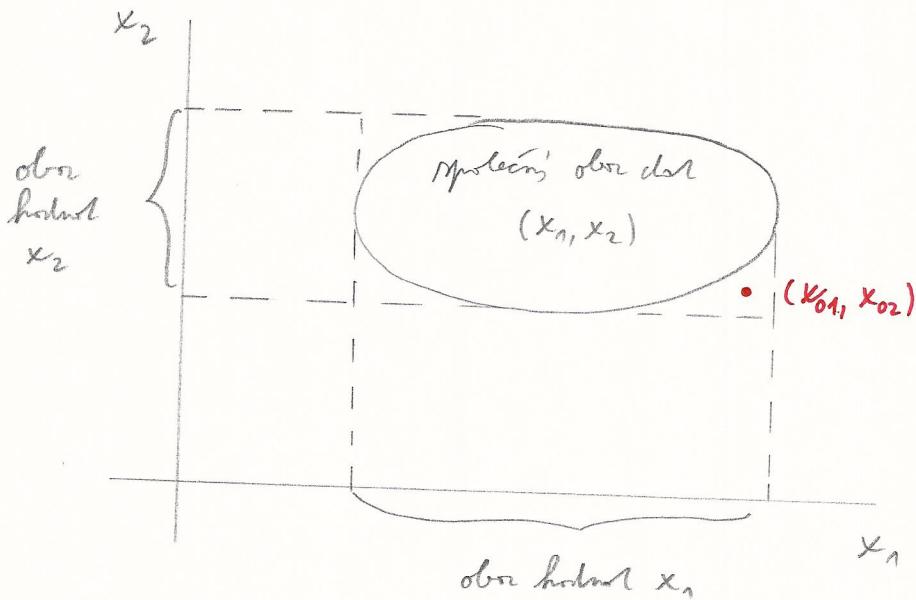
- u jednostrané LR houlit predikce závisí na rozdílenosti  $x_0$  od  $\bar{x}$
- je třeba si dát pozor na predikce mimo  $(x_{\min}, x_{\max})$
- prediktivní rozdíly plati' i pro univariovanou LR
- prediktivní rozdíly predikce je úměrné  $x_0^T (X^T X)^{-1} x_0$ , ne ~~je~~ někdy hodně někdy někdy někdy spolehlivé!
- spec. pohled  $x_i^T$  je jinou posuzovací datou, může se očekávat, že body s největšími hodnotami  $x_i^T (X^T X)^{-1} x_i = k_{ii}$  budou se hranicemi rozdílu, kde je predikce spolehlivá

Nun, es möchte eigentlich

(48)

$$\underline{x^T (X^T X)^{-1} x \leq \max_{1 \leq i \leq n} h_i}$$

mitte liegt positionen zu größtmöglicher oder pro größtmöglicher



$(x_{01}, x_{02})$  liegt seitlich oben höchst pro obere  $x_1$  &  $x_2$  alle möglichen Möglichkeiten oben möglichst hoch