

Rozdělení, diagnostika a transformace

- je třeba ověřit adekvátnost modelu
mimo R^2 , L, F relativit., by ale byl ohovozeny se předpoklady
linearity modelu a dalšími postupem ne všechny obecné
pro ověření - analyse rozdílu
je důležitým nástrojem
- je třeba ověřit vliv jednotlivých pozorování na model
analyse vlivných (outliers) a influenčních pozorování
 (vlnky 'residuum pro i -třídu' pro i -třídu naznačují problem s modelom
ale může to být i naprod, vlivný poz. nemusí mít vlnky 'residuum'
obr. 3.9 str. 111)
- pokud detekujeme nějaké 'problems' s modellem, mohou pomoci
transformace proměnných nebo měny neboch vložených
parametrů

Rozdílu

připomínka: $\hat{y} = X\hat{\beta} = H\gamma$, kde $H = X(X^T X)^{-1} X^T$
 $\hat{\epsilon} = \gamma - \hat{y} = (I_m - H)\gamma = (I_m - H)\epsilon$

dle jiné uhrada: $E\hat{\epsilon} = 0$, $Cov(\hat{\epsilon}) = \sigma^2(I_m - H)$

pokud máme $\epsilon \sim N(0, \sigma^2 I_m)$, potom $\hat{\epsilon} \sim N(0, \sigma^2(I_m - H))$

pokud osnovné $h_{ii} = H_{ii}$, $\hat{e}_i \sim N(0, \sigma^2(1-h_{ii}))$, $Cov(\hat{e}_i, \hat{e}_j) = -\sigma^2 h_{ij}$

obecně lze 'vložit' novou pozorování do standardizovaných rozdílu;

pokud $Var(\hat{e}_i) = \sigma^2(1-h_{ii})$, pro $r_i = \frac{\hat{e}_i}{\sigma\sqrt{1-h_{ii}}}$ pak $Var(r_i) = 1$

T otázka novou pozorování $s_m = \sqrt{\frac{1}{m-m-1} SSE}$, definováno

$$\hat{r}_i = \frac{\hat{e}_i}{\hat{\sigma}_{(i)} \sqrt{1-h_{ii}}}, \quad i=1, \dots, n$$

interně studentizované
residua

(někdy se nazývají studentizovaná
residua)

R: `residual(-)`

pohled σ^2 odhadováne ve zhlédnuté modelu, ve kterém bylo vymezeno
 i -té pozorování, osamělou lze odhad $\hat{\sigma}_{(i)}^2$, proto

$$\hat{r}_i = \frac{\hat{e}_i}{\hat{\sigma}_{(i)} \sqrt{1-h_{ii}}}, \quad i=1, \dots, n$$

externě studentizované residua

(někdy se nazývají studentizované')

R: `studentRes(.)`

např. $\hat{\sigma}_{(i)}^2 = \frac{SSE_{(-i)}}{n-n-2}$ je vzdálost' odhadu σ^2 o i modelu ($-i$)

- PozN:
- pohled h_{ii} je mali', pro velké n lze o něm
 $\hat{e}_i, \hat{r}_i, \hat{z}_i$ chovat jídelní sloužit - $\hat{r}_i, \hat{z}_i \approx N(0,1)$
 - pro malé n ($n < 20$) a/nebo $h_{ii} \approx 1$
je preferováno použít \hat{r}_i nebo \hat{z}_i a alternativně
čísloji ~~pozitivní~~ \hat{z}_i (i-té poz. o některá hodnota může
zvyšovat odhad σ^2 a tím může
velikost některého residua)
 - h_{ii} hraniční hodnota v diagnostickém modelu, prokazuje
než i kdy zhlédnutí vlastnosti

Leverage h_{ii} - potenciálně lehké poz.

[leverage point - pohodlné bod
rozdílnější bod]

- $\text{Var } \hat{e}_i = \sigma^2(1-h_{ii}) \geq 0 \Rightarrow \underline{h_{ii} \leq 1}$

- $H^2 = H \Rightarrow h_{ii} = \sum_{j=1}^m h_{ij}, h_{ii} = \sum_{j=1}^m (h_{ij})^2$, lebys $h_{ii} > 0$

(da' n' aktif' n' negativ' horzen': $h_{ii} \geq \frac{1}{m}$)

- $HX = X \Rightarrow A_{i1} = \sum_{j=1}^m h_{ij} x_{j1} = \sum_{j=1}^m h_{ij} = x_{i1} = 1$, lebys
 $\sum_{j=1}^m h_{ij} = 1 \quad \forall j \in \mathbb{N}$

• význam h_{ii} uplyne z množstvem mohy.

$$\hat{\gamma}_i = H^{-1} \gamma \Rightarrow \hat{\gamma}_i = \sum_{j=1}^m h_{ij} \gamma_j = \underline{h_{ii} \gamma_i + \sum_{j \neq i}^m h_{ij} \gamma_j}$$

pokud $h_{ii} \approx 1$, pak $\hat{\gamma}_i \approx \gamma_i$ a model je méně
přesný pravdě podle $(x_i, \gamma_i) \sim$ když lze neplatit
body s „velkými h_{ii} “ - lebys s velkým potenciálem
(high leverage points)

High body do méně lehkého detektování pro dala? schannen!

~~pokud $\hat{\gamma}_i$ je bod s velkým potenciálem, pak je méně lehké mít mohy,
ale $\hat{\gamma}_i$ je „velké“, lebys potenciál poz. $\hat{\gamma}_i$ mohy efekt
množství mohy $\sim \gamma_i$~~

- doslova je „jako“ horzna h_{ii} je „velké“
heuristické princip:

$$\sum_{i=1}^m h_{ii} = \text{tr } H = m+1, \text{ tzn. } \frac{m+1}{m} \text{ je první horzna } h_{ii}$$

z-tekoucí poz. má velký potenciál, jestliže $\underline{h_{ii} > \frac{3(m+1)}{m}}$

(takže detekce $\sim R$)

Graph residual'

A) overén' normality - histogram, Q-Q plot

Abz obrazov residual' na počtu rezidualů proměnných x , může vypadat jinak než jednorodost LK

B) pro overén' funkce' formy pro $E(Y_i)$ a/nebo homoskedastické rozložení nejčastěji používají:

1) grafy \hat{e}_i, \hat{r}_i nebo \hat{r}_i proti \hat{x}_j^c , $j=1, \dots, n$
kde \hat{x}_j^c je j -tý záložec X

2) grafy \hat{e}_i, \hat{r}_i nebo \hat{r}_i proti $\hat{\beta}_j$

3) partial residual plots

Počet: • relativním' 1):

normální rozložení $X^T(\gamma_j - X\hat{\beta}) = 0$ implikuje $X^T(\gamma_j - \hat{\gamma}) = X^T\hat{\epsilon} = 0$

$$\text{pojmenování: } Y_i = \beta_0 x_i + \epsilon_i, \quad \hat{\beta}_0 = \frac{\sum_{i=1}^n x_i \gamma_i}{\sum x_i^2} = \frac{X^T \gamma}{\|X\|^2}$$

pokud když relativní LK model bez interceptu pro $\hat{\epsilon}$ má rozložení

ne \hat{x}_j^c , může příbuzné být

$$\hat{\beta}_{0j} = \frac{(\hat{x}_j^c)^T \hat{\epsilon}}{\|\hat{x}_j^c\|^2} = 0$$

graf $\hat{e}_i, \hat{r}_i, \hat{r}_i$ proti \hat{x}_j^c by měl dletož mít hodnoty rozložené
bodem kolem nuly (bez trendu, \hat{r}_i, \hat{r}_i mohou pribl. ± 2)

pokud když lze nové, může k normální rozložení v \hat{x}_j^c
nebo mít rozložení rozložit

- odhadnutí 2):

$$\text{uvažte jinou } \sum_{i=1}^n \hat{\epsilon}_i = \hat{\epsilon}_i = 0$$

pro LM bys mohla pro $\hat{\epsilon}_i$ opti $\hat{\beta}_i$ když platí

$$\hat{\beta}_i = \frac{\hat{\epsilon}_i^T \hat{\gamma}}{\|\hat{\gamma}\|^2} = 0$$

- body by opti měly byt mat. rovnice 'holeny' a
- bez významu bys mohla mít mnoho různých
- ~~bez významu~~ mohly mít mnoho různých

3) Partial residual plots

- i faktu grafy $\hat{\epsilon}_i$ opti \hat{x}_j^c a $\hat{\beta}_j$ mohou indikovat nevhodný model, nemusí být správné, že by nevhodný byl
- ne SLE graf je pro x_j lze použít pro detektaci vlivnosti
- ale ne MLR bylo graf, stejně jako scatterplot, mohou být zavádějící, protože je zivý se svého prediktora, nemusí být když zvlášť efekt dom' pravého' při odstranění kterého odstříknut
- pro závratné' efekty y_j -le' pravého' lze použít partial residual plots
 - tzn. je dojedou jeho ekvivalent scatterplotu - ne SLE

def. $\hat{\epsilon}_j^*$ = $\hat{\epsilon}_j + \hat{\beta}_j x_j^c$, kde $\hat{\epsilon}_j$ je vhodný residual' modelu
 $\hat{\beta}_j$ je LSE pro β_j
 x_j^c - j -tý sloupec X

PRP: graf $\hat{\epsilon}_j^*$ opti x_j^c , $j = 1, \dots, n$

pokud je model správný, měly by být body rovnoběžně rozmištěny kolem původní mimořádné $\hat{\beta}_j$

odhadování:

(83)

vezde máme \hat{e}_j^* a x_j^c mít formu SLR bez interceptu

podle ji model opisuje, $\hat{e}_j^*, j = 1, \dots, n$, platí $E\hat{e}_j^* = 0$
 $\text{Var } \hat{e}_j^* = \sigma^2(I - H_{xx})$

máme tedy možnost vypočítat RM pro \hat{e}_j^* oproti x_j^c ($\hat{e}_j^* = \hat{\beta}_j x_j^c + \varepsilon$)
pro odhad koef. $\hat{\beta}_j$

$$\hat{\beta}_j = \frac{(\hat{e}_j^*)^T x_j^c}{\|x_j^c\|^2} = \frac{(\hat{\varepsilon} + \hat{\beta}_j x_j^c)^T x_j^c}{\|x_j^c\|^2} = \frac{\hat{\varepsilon}^T x_j^c + \hat{\beta}_j \|x_j^c\|^2}{\|x_j^c\|^2} = \hat{\beta}_j$$

$$\text{protože } \hat{\varepsilon}^T x_j^c = 0$$

Obr. housing price data str. 253

Obr. birth weight data Ex 6.2, str. 253

PoZN: PRP, jiné řešení kritizujíce nevhodnostování' efektu x_j^c

alternativa: partial regression plot (added variable plot)

motivace: plánuje se, že přidá novou proměnnou do modelu
a cílem bychom odhadnout její efekt

Endene řešení může mít rozšířený model

$$Y = X\beta + \gamma w + \varepsilon \quad w \text{ je nový neštandardní regresor}$$

de rovnat je

$$y = (Xw) \begin{pmatrix} \beta \\ \gamma \end{pmatrix} + \varepsilon = Xw\beta_w + \varepsilon$$

pozitivní normované různice pro β_w lze odvodit formule pro $\hat{\beta}$

$$\hat{\gamma} = \frac{\hat{\varepsilon}^T (I - H)w}{\| (I - H)w \|^2} \quad (\#)$$

$\hat{\gamma}$ je minimální RM pro $\hat{\varepsilon}$ v normov.
na množině $= \frac{(I - H)w}{\| (I - H)w \|^2}$
(residual model pro w v normov. na X)

nový množinový model, kde w je sloupec prvních X , zahrnuje x_j^c

a vzn. $X_{(-j)}$ matici X bez sloupců j

• předchozím modelu polomé $\hat{X} = X_{(-j)}$ a $w = x_j^c$

příslušný LSE $\hat{\beta}_j$ pro x_j je

$$\hat{\beta}_j = \frac{\hat{x}_{(-j)}^T x_{j,res}^c}{\|x_{j,res}^c\|^2}, \text{ kde}$$

$\hat{x}_{(-j)}$ je matrice modelu bez x_j

$$x_{j,res}^c = (I - H_{(-j)}) x_j^c, \text{ kde}$$

je matrice residua modelu pro

x_j^c a rezidua m. ovlivně
pronájem, když ne $X_{(-j)}$

($x_{j,res}^c$ je tedy odstoupení
efektu ovlivnění regresion.)

je to méně RM pro $\hat{x}_{(-j)}$
a rezidua m. $x_{j,res}^c$



added variable plot: graf $\hat{\beta}_j$ proti $x_{j,res}^c$, $j=1,..,m$

příslušný k modelu $y_{(j)}$, když by měl být mohutně rozptýlený, kdežto
příslušný k méněm $\hat{\beta}_j$ proč. počítaný

příslušný reziduál m. x_j^c méně lineární, pojednává o vlivu jednoho
příslušného

PoN: Je vlnka (#) je vidit, že MCR méně bývá důležitá zde
porovnat SLR, kde porovnáváme modely pro
novou proměnnou s novým rezidualem pro modely pro předchozí
proměnnou

PRESS residue (PRESS residual, deleted residuals)

- příslušný kdežto článek modelu použit nejen k vyvážení vlnky
mezi pronájem a vlnku pro predikci, kdyžže by se měla
vyjádřit vlnka jde dobré modelu predikci (dopad jde obecně jen
jde dobré popisuje)
- když by vlnka IS měla IP, kdyžže ale již není možné snít
kdyžže m. Méněj chce prediktovat

- nejjednodušší přístup, jde mít prediktivní průvod model, by byl analyzovat rezidua pro jednotlivé hodnoty a možné bylo zjistit, že všechny hodnoty jsou stejně a tedy je pouze jedna hodnota modelu
- jedna možnost je použít data. Zde máme 2 díly:
 - přístup: vynechání jednoho pozorování, vložit doho modelu a porovnat predikovanou a pozorovanou hodnotu pro vynechané pozorování

příkl., když vynecháme i-té pozorování, ozn. $\hat{\beta}_{(-i)}$ odhad β a modelu s vynechaným i-tým pozorováním ($M_{(-i)}$) a $\hat{y}_{(-i)}$ predikovanou hodnotu modelu $M_{(-i)}$ ~ hodnota x_i^T ,

$$\text{tzn. } \hat{y}_{(-i)} = x_i^T \hat{\beta}_{(-i)}$$

pokud

$$\hat{e}_{(-i)} = y_i - \hat{y}_{(-i)}, \quad i = 1, \dots, n$$

vynecháme i-teho PRESS reziduum

$$\text{PRESS} = \sum_{i=1}^n \hat{e}_{(-i)}^2 \quad \text{je většinou měří fánskosti predikce}$$

Pozn.: Obrázek je zde použit $\hat{e}_{(-i)}$, $i = 1, \dots, n$

- pro n velké' reprezentativní, kdyže lze mít násobný problém, protože pro hodnoty i v mnoha místech mohou být možné modely mít různé hodnoty, uvažujeme tedy, že
- mít různé hodnoty mít různé rezidua

$$\hat{e}_{(-i)} = \frac{\hat{e}_i}{1-h_{ii}}$$

Tzn. většina $\hat{e}_{(-i)}$ lze mít mít různé rezidua a hodnota h_{ii} je pravděpodobně (druhé) modelu

Strukture \mathbf{x}_z^T - je -1 ' respektiv. matice \mathbf{x}

$\mathbf{x}_{(-z)}^T$ - matice \mathbf{x} bez z -teho radku

Neh: ještěže $l_{zz} \neq 1$, potom

$$[\mathbf{x}_{(-z)}^T \mathbf{x}_{(-z)}]^{-1} = \mathbf{x}^T \mathbf{x}^{-1} + \frac{(\mathbf{x}^T \mathbf{x})^{-1} \mathbf{x}_z \mathbf{x}_z^T (\mathbf{x}^T \mathbf{x})^{-1}}{1 - l_{zz}},$$

takže $\mathbf{x}^T \mathbf{x}$ je -1 ' diag. prodl. matice \mathbf{H} .

Dl: nejdříve užívejme

$$\underline{\mathbf{x}^T \mathbf{x} = \mathbf{x}_{(-z)}^T \mathbf{x}_{(-z)} + \mathbf{x}_z \mathbf{x}_z^T} \quad (+)$$

$$(m+1) \times (m+1) \quad (m+1) \times (m+1) \quad (m+1) \times (m+1)$$

uvol. matice' pravé. $z = n$, kde se de' vztýkají dlešíkové řádky' řádku \mathbf{x}

platí

$$(\mathbf{x}^T \mathbf{x})_{ij} = \sum_{k=1}^m x_{ki} x_{kj} = \sum_{k=1}^{n-1} x_{ki} x_{kj} + x_{ni} x_{nj}$$

$i, j = 1$ ' prodl. $\mathbf{x}_{(n)}^T \mathbf{x}_{(-n)}$ je $\sum_{k=1}^{n-1} x_{ki} x_{kj}$.

$i, j = 1$ ' prodl. $\mathbf{x}_n \mathbf{x}_n^T$ je $x_{ni} x_{nj}$, tzn. (+) platí

Vrh k LA: (Sherman - Morrison - Woodbury)

Nechť \mathbf{A} je $n \times n$ invertibilní' matice a nechť \mathbf{r} je $n \times 1$ sloupcový vektor. Ještěže $\mathbf{r}^T \mathbf{A}^{-1} \mathbf{r} \neq 1$, potom matice $\mathbf{B} = \mathbf{A} - \mathbf{r} \mathbf{r}^T$ je invertibilní' - platí

$$\underline{\mathbf{B}^{-1} = \mathbf{A}^{-1} + \frac{\mathbf{A}^{-1} \mathbf{r} \mathbf{r}^T \mathbf{A}^{-1}}{1 - \mathbf{r}^T \mathbf{A}^{-1} \mathbf{r}}}$$

pulsive $A = \mathbf{x}^T \mathbf{x}$, $\mathbf{B} = \mathbf{x}_i$, $\mathbf{C} = \mathbf{x}_{(-i)}^T \mathbf{x}_{(-i)}$

Nun. $\mathbf{B} = A - \mathbf{C} \mathbf{C}^T$, A ist invertierbar \Leftrightarrow

$$\mathbf{C}^T \mathbf{A}^{-1} \mathbf{C} = \mathbf{x}_i^T (\mathbf{x}^T \mathbf{x})^{-1} \mathbf{x}_i = (\mathbf{x}^T \mathbf{x})^{-1} \mathbf{x}_i^T \mathbf{x}_i = h_{ii} \neq 1$$

nicht mit derselben

$$(\mathbf{x}_{(-i)}^T \mathbf{x}_{(-i)})^{-1} = (\mathbf{x}^T \mathbf{x})^{-1} + \frac{(\mathbf{x}^T \mathbf{x})^{-1} \mathbf{x}_i^T \mathbf{x}_i (\mathbf{x}^T \mathbf{x})^{-1}}{1 - h_{ii}}$$

Q. E. D.

Wth: Rest $\hat{\epsilon}_{(-i)}$ ist i -te PRESS Residuum. Dann

$$\hat{\epsilon}_{(-i)} = \frac{\hat{e}_i}{1 - h_{ii}}, \quad i = 1, \dots, n.$$

2d. Rest $\hat{\beta}_{(-i)}$ ist ortho $\mathbf{B} \sim$ modell $\mathbf{P}_{(-i)}$, Nun.

$$\hat{\beta}_{(-i)} = (\mathbf{x}_{(-i)}^T \mathbf{x}_{(-i)})^{-1} \mathbf{x}_{(-i)}^T \mathbf{y}_{(-i)}, \quad \text{d.h. } \mathbf{y}_{(-i)} \text{ ist der } i\text{-te stochasti}$$

Nun.

$$\begin{aligned} \hat{\beta}_{(-i)} &= \mathbf{x}_i^T \hat{\beta}_{(-i)} = \mathbf{x}_i^T (\mathbf{x}_{(-i)}^T \mathbf{x}_{(-i)})^{-1} \mathbf{x}_{(-i)}^T \mathbf{y}_{(-i)} = \\ &\quad (\mathbf{x}^T \mathbf{x})^{-1} + \frac{(\mathbf{x}^T \mathbf{x})^{-1} \mathbf{x}_i^T \mathbf{x}_i (\mathbf{x}^T \mathbf{x})^{-1}}{1 - h_{ii}} \\ &= \mathbf{x}_i^T (\mathbf{x}^T \mathbf{x})^{-1} \mathbf{x}_{(-i)}^T \mathbf{y}_{(-i)} + \frac{1}{1 - h_{ii}} \mathbf{x}_i^T (\mathbf{x}^T \mathbf{x})^{-1} \mathbf{x}_i^T \mathbf{x}_i (\mathbf{x}^T \mathbf{x})^{-1} \mathbf{x}_{(-i)}^T \mathbf{y}_{(-i)} = \\ &= S_1 + \frac{1}{1 - h_{ii}} S_2 \end{aligned}$$

pulsive $\mathbf{x}_{(-i)}^T \mathbf{y}_{(-i)} = \mathbf{x}^T \mathbf{y} - \gamma_i \mathbf{x}_i$ derselbe

$$\begin{aligned} S_1 &= \mathbf{x}_i^T (\mathbf{x}^T \mathbf{x})^{-1} (\mathbf{x}^T \mathbf{y}) - \gamma_i \mathbf{x}_i^T \mathbf{x}_i = \underbrace{\mathbf{x}_i^T (\mathbf{x}^T \mathbf{x})^{-1} \mathbf{x}^T \mathbf{y}}_{\hat{\beta}} - \gamma_i \underbrace{\mathbf{x}_i^T (\mathbf{x}^T \mathbf{x})^{-1} \mathbf{x}_i}_{h_{ii}} = \\ &= \mathbf{x}_i^T \hat{\beta} + h_{ii} \gamma_i = \hat{\beta}_{(-i)} - h_{ii} \gamma_i \end{aligned}$$

problem

$$S_2 = \underbrace{\hat{x}_{-i}^T (\hat{X}^T \hat{X})^{-1} \hat{x}_{-i}}_{h_{-i}} \underbrace{\hat{\gamma}_{-i}^T (\hat{X}^T \hat{X})^{-1} \hat{y}_{-i}}_{\hat{\gamma}_{-i}} - \gamma_{-i} \underbrace{\hat{x}_{-i}^T (\hat{X}^T \hat{X})^{-1} \hat{x}_{-i}}_{h_{-i}} \underbrace{\hat{\gamma}_{-i}^T (\hat{X}^T \hat{X})^{-1} \hat{x}_{-i}}_{h_{-i}} =$$

$$= h_{-i} \hat{\gamma}_{-i} - \gamma_{-i} h_{-i}^2$$

Lehrz

$$\hat{\gamma}_{(-i)} = \hat{\gamma}_i - h_{ii} \gamma_i + \frac{1}{1-h_{ii}} (h_{ii} \hat{\gamma}_i - \gamma_i h_{ii}^2)$$

stellen leicht

$$\begin{aligned} \hat{\gamma}_{(-i)} &= \gamma_i - \hat{\gamma}_{(-i)} = \gamma_i(1+h_{ii}) - \hat{\gamma}_i - \frac{1}{1-h_{ii}} (h_{ii} \hat{\gamma}_i - \gamma_i h_{ii}^2) \\ &= \frac{1}{1-h_{ii}} (\gamma_i(1-h_{ii}^2) - \hat{\gamma}_i(1-h_{ii}) - h_{ii} \hat{\gamma}_i + \gamma_i h_{ii}^2) \\ &= \frac{1}{1-h_{ii}} (\gamma_i - \hat{\gamma}_i) = \frac{\hat{e}_i}{1-h_{ii}} \end{aligned} \quad \text{Q.E.D.}$$

Bereite 'gewöhnliche' Formel für $\hat{\beta} - \hat{\beta}_{(-i)} \approx SSE_{(-i)}$

Weth: 1) Nach $\hat{\beta}_{-i}$ min LSE für $\beta \sim$ Modell bei i -röhne Parameter.

Ortlich platz'

$$\hat{\beta} - \hat{\beta}_{(-i)} = \frac{(\hat{X}^T \hat{X})^{-1} \hat{e}_{-i}}{1-h_{ii}} = (\hat{X}^T \hat{X})^{-1} \hat{x}_{-i} \hat{e}_{(-i)}$$

2) Über neue residuum mit überprüfen $SSE_{(-i)}$ ~ Modell bei i -röhne pos.

Platz'

$$\underline{SSE_{(-i)}} = \sum_{j=1}^m \hat{e}_j^2 - \frac{\hat{e}_i^2}{1-h_{ii}}$$

Dh:
1) steigt jede ~ dle. 'gewöhnliche' mit Platz'

$$\hat{\beta}_{(-i)} = S_1 + \frac{1}{1-h_{ii}} S_2, \quad \text{d.h.} \quad S_1 = \hat{\beta} - \gamma_i (\hat{X}^T \hat{X})^{-1} \hat{x}_i$$

$$\text{a } S_2 = (\hat{X}^T \hat{X})^{-1} \hat{x}_i \hat{\gamma}_i - \gamma_i (\hat{X}^T \hat{X})^{-1} \hat{x}_i h_{ii}$$

Kerby

$$\hat{\beta} - \hat{\beta}_{(-i)} = \gamma_{-i} (\mathbf{x}^T \mathbf{x})^{-1} \mathbf{x}_{-i} - \frac{1}{1-h_{ii}} ((\mathbf{x}^T \mathbf{x})^{-1} \mathbf{x}_{-i} \hat{\beta}_{-i} - \gamma_{-i} (\mathbf{x}^T \mathbf{x})^{-1} \mathbf{x}_{-i} h_{ii}) =$$

$$= (\mathbf{x}^T \mathbf{x})^{-1} \mathbf{x}_{-i} \left(\gamma_{-i} - \frac{\hat{\beta}_{-i} - \gamma_{-i} h_{ii}}{1-h_{ii}} \right) = (\mathbf{x}^T \mathbf{x})^{-1} \mathbf{x}_{-i} \left(\frac{\gamma_{-i} - \gamma_{-i} h_{ii} - \hat{\beta}_{-i} + \gamma_{-i} h_{ii}}{1-h_{ii}} \right)$$

$$= (\mathbf{x}^T \mathbf{x})^{-1} \mathbf{x}_{-i} \underbrace{\left(\frac{\gamma_{-i} - \hat{\beta}_{-i}}{1-h_{ii}} \right)}_{= \frac{\hat{\epsilon}_i}{1-h_{ii}}} = \hat{\epsilon}_{(i)}$$

2) $\underline{SSE_{(-i)}} = (\gamma_{(-i)} - \mathbf{x}_{(-i)}^T \hat{\beta}_{(-i)})^T (\gamma_{(-i)} - \mathbf{x}_{(-i)}^T \hat{\beta}_{(-i)}) =$

$$= \sum_{\substack{j=1 \\ j \neq i}}^m (\gamma_j - \mathbf{x}_j^T \hat{\beta}_{(-i)})^2 = \sum_{\substack{j=1 \\ j \neq i}}^m (\gamma_j - \mathbf{x}_j^T \hat{\beta}_{(-i)})^2 - (\gamma_i - \mathbf{x}_i^T \hat{\beta}_{(-i)})^2$$

zu bilden 1) $\hat{\beta}_{(-i)} = \hat{\beta} - \frac{(\mathbf{x}^T \mathbf{x})^{-1} \mathbf{x}_{-i} \hat{\epsilon}_i}{1-h_{ii}}$ m.

$$SSE_{(-i)} = \sum_{j=1}^m (\gamma_j - \mathbf{x}_j^T \hat{\beta} + \frac{\mathbf{x}_j^T (\mathbf{x}^T \mathbf{x})^{-1} \mathbf{x}_{-i} \hat{\epsilon}_i}{1-h_{ii}})^2 - (\gamma_i - \mathbf{x}_i^T \hat{\beta} + \frac{\mathbf{x}_i^T (\mathbf{x}^T \mathbf{x})^{-1} \mathbf{x}_{-i} \hat{\epsilon}_i}{1-h_{ii}})^2$$

zu $\mathbf{x}_j^T (\mathbf{x}^T \mathbf{x})^{-1} \mathbf{x}_{-i} = h_{ji}$, d.h. $\hat{\epsilon}_j = \hat{\epsilon}_i$

$$SSE_{(-i)} = \sum_{j=1}^m (\hat{\epsilon}_j + \frac{h_{ji} \hat{\epsilon}_i}{1-h_{ii}})^2 - (\hat{\epsilon}_i + \frac{h_{ii} \hat{\epsilon}_i}{1-h_{ii}})^2 = \underbrace{\sum_{j=1}^m (\hat{\epsilon}_j + \frac{h_{ji} \hat{\epsilon}_i}{1-h_{ii}})^2}_{A} - \frac{\hat{\epsilon}_i^2}{(1-h_{ii})^2}$$

$$A = \sum_{j=1}^m \hat{\epsilon}_j^2 + \frac{2\hat{\epsilon}_i}{1-h_{ii}} \underbrace{\sum_{j=1}^m h_{ji} \hat{\epsilon}_j}_{=0} + \frac{\hat{\epsilon}_i^2}{(1-h_{ii})^2} \underbrace{\sum_{j=1}^m h_{ji}^2}_{=h_{ii}}$$

zu $\hat{\gamma}_i = H\gamma_i = H\hat{\gamma}_i = H^2\gamma_i = H\alpha$ - Kerby

$$H\hat{\beta} = H(\gamma - \hat{\gamma}) = H\gamma - H\hat{\gamma}_i = \underline{0}$$

Kerby

$$SSE_{(-i)} = \sum_{j=1}^m \hat{\epsilon}_j^2 + \frac{\hat{\epsilon}_i^2}{(1-h_{ii})^2} (h_{ii} - 1) = \sum_{j=1}^m \hat{\epsilon}_j^2 - \frac{\hat{\epsilon}_i^2}{1-h_{ii}} .$$

Q.E.D.

Důkaz: V modelu (***) $n = m+1$ proměny β a a lze získat
pozorování' plati'

$$\underline{E(SSE_{(-i)})} = (n - m - 2) \sigma^2$$

Aleží $\hat{\sigma}_{(-i)}^2 = \frac{SSE_{(-i)}}{n - m - 2}$ je nezávislý osobit σ^2 .

dále $\hat{\sigma}_{(-i)}^2 = \frac{(1 - h_{ii}) (n - m - 1) D_m^2 - \hat{e}_i^2}{(1 - h_{ii}) (n - m - 2)} = \frac{1}{n - m - 2} \left(SSE - \frac{\hat{e}_i^2}{1 - h_{ii}} \right)$

aleží $D_m^2 = \frac{1}{n - m - 1} SSE$ (pro plny' model).

Dl: protože $E \hat{e}_i^2 = \text{Var } \hat{e}_i = \sigma^2 (1 - h_{ii})$ dokončme dle požadovaného

$$\underline{E(SSE_{(-i)})} = \sum_{j=1}^m \sigma^2 (1 - h_{jj}) - \sigma^2 = \sigma^2 [m-1 - \underbrace{\sum_{j=1}^m h_{jj}}_{= mH = m+1}] = \sigma^2 (n - m - 2)$$

$$\hat{\sigma}_{(-i)}^2 = \frac{1}{n - m - 2} SSE_{\text{fikt}} = \frac{1}{n - m - 2} \left(\underbrace{\sum_{j=1}^m \hat{e}_j^2 - \frac{\hat{e}_i^2}{1 - h_{ii}}}_{= SSE} \right) = \frac{1}{n - m - 2} \frac{(1 - h_{ii}) SSE - \hat{e}_i^2}{1 - h_{ii}}.$$

Q.E.D.

Pozn: dle výše uvedené, jež $SSE_{(-i)}$ a \hat{e}_i jsou nezávislé n. vel.

protože $\frac{SSE_{(-i)}}{\sigma^2} \sim \chi^2(n - m - 2)$ a $\frac{\hat{e}_i}{\sigma \sqrt{1 - h_{ii}}} \sim N(0, 1)$

dokončme $\frac{\hat{e}_i}{\hat{\sigma}_{(-i)} \sqrt{1 - h_{ii}}} \sim N(n - m - 2)$

\Downarrow

Pozn: Uvažujme model (***) , kde $L(X) = m+1$ a $\epsilon \sim N_m(0, \sigma^2 I_m)$.
Neži pro $i \in \mathbb{N}$ platí $h_{ii} \neq 1$. Potom \hat{e}_i je sice

residuum $\hat{e}_i \sim N(n - m - 2)$

Pozn: $\hat{\lambda}_i$ je pozitivní pro test hypotézy, zda je i -té pozorování 'oddlečí' (outlier)

$H_0: i$ -té pozorování je normálně oddlečí v modelu M

$H_1: i$ -té pozorování je oddlečí v M

Jde o oddlečí normálně oddlečí vzhledem k M: $Y_i \sim N_m(X\beta, \sigma^2 I_m)$:

- a) střední hodnota i -těho poz. je nerovna nějakému danému hodnotě
- b) pozorování hodnoty Y_i je neobvyklé vzhledem k M

H_0 záměrně pojedná $|\hat{\lambda}_i| > \lambda_{1-\alpha/2}(m-m-2)$

$$\approx \lambda_{1-\alpha/2} = 2 \text{ pro } \alpha=0,05 \\ \text{a m velké}$$

- pojedná test pozicije na vědom pozorování; $\hat{\lambda}_i \in (-2, +2)$ OK
je třeba aplikovat nějakou korekci na významné významnosti, např. Bonferroni

Pozn: vztah $\hat{e}_{\text{fit}} \text{ a } \hat{\lambda}_i$

$$\hat{e}_{(-i)} = \frac{\hat{e}_i}{1-\hat{h}_{ii}} \Rightarrow E \hat{e}_{(-i)} = 0 \quad \text{Var } \hat{e}_{(-i)} = \frac{\sigma^2}{1-\hat{h}_{ii}}$$

$$\text{standardizované PRSS residuum } \frac{\hat{e}_{(-i)}}{\sqrt{\text{Var}(\hat{e}_{(-i)})}} = \frac{\hat{e}_i}{\sqrt{1-\hat{h}_{ii}}} = \frac{\hat{e}_i}{\sqrt{\sigma^2}} = \frac{\hat{e}_i}{\sigma} = r_i$$

pojedná pozicije \hat{r}_i^2 jde oddelit σ^2 , zde standardizované PRSS

$$\text{residue } \frac{\hat{e}_i}{\hat{\sigma}_{(-i)} \sqrt{1-\hat{h}_{ii}}} = \hat{\lambda}_i$$

- $\hat{e}_{(-i)} = \frac{\hat{e}_i}{1-\hat{h}_{ii}} \Rightarrow$ pojedná i -té pozorování na nějž' potenciálně hledá, když $\hat{e}_{(-i)}$ ^{standard.} někdy není $\hat{\lambda}_i$, pozorování s nějž' hledá mohou dletočne modelovat, ale měřeno $\hat{e}_{(-i)}$ mohou mít jiné prediktory

to xi dala? welche fit/prediction dilema

(33)

- stejný effect využívá "také" pro

$$\hat{\beta}_i - \hat{\beta}_{(-i)} = (\mathbf{x}^T \mathbf{x})^{-1} \mathbf{x}_i \hat{e}_{(-i)}$$

rozdíl mezi tří „moby“ pokud je „bit“ dobrý, ale může být „velký“ pokud je hra velká.