

BOX-COX Transformation

(100)

- pokud daly nějakou normální rozdělení, lhostáne transformaci, Graw' by nejčastěji lineárního modelu, ale třeba transformace daly, aby byly přísl. normální
- jeho význam je užívání norm. kruž. transf. (power family)

$$y^{(2)} = \begin{cases} \frac{\beta^2 - 1}{2} & \lambda \neq 0 \\ \log y & \lambda = 0 \end{cases}$$

Graw' předpoklady, kdy data y jsou pouze lhostáne (pokud ne, může být konstrukce řešen poz. a analyzovat tak proměnné data)

$$\text{Pozn. } \lim_{\lambda \rightarrow 0} \frac{\beta^2 - 1}{2} = \log \beta$$

- pro založení vložitelných 2 lhostánských předpokladů, kdy transformace veličin $y_i^{(2)}$, $i=1, \dots, n$, splňuje postupně $2M$, t. j.

$$y_i^{(2)} = x_i^T \beta + \varepsilon, \quad \varepsilon \sim N_m(0, \sigma^2 I_m) \quad (y_i^{(2)} \sim N(x_i^T \beta, \sigma^2) \text{ a } y_1^{(2)}, \dots, y_n^{(2)} \text{ nez.})$$

čehož je odhadovat získat $\hat{\beta}, \hat{\sigma}^2$, použijeme MLE

power transformation získané hustotu

$$f_{Y_i}(s_i) = f_{Y_i^{(2)}}(\beta_i^{(2)}) \frac{dY_i^{(2)}}{ds_i} = \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{1}{2\sigma^2} (\beta_i^{(2)} - \mu_i)^2} \cdot \beta_i^{(2)},$$

kde $\mu_i = E Y_i^{(2)} = x_i^T \beta$

verhodnotné funkce pro poz. β_1, \dots, β_m bude

$$L = \prod_{i=1}^n f_{Y_i}(s_i) = \left(\frac{1}{\sqrt{2\pi\sigma^2}} \right)^n e^{-\frac{1}{2\sigma^2} \sum_{i=1}^n (\beta_i^{(2)} - \mu_i)^2} \cdot J(2), \quad J(2) = \prod_{i=1}^n \beta_i^{(2)} = \left(\prod_{i=1}^n \beta_i \right)^{2-1}$$

Log-likelihood:

(107)

$$\ell = \ln L = -\frac{m}{2} \ln 2\pi - \frac{m}{2} \ln \sigma^2 - \frac{1}{2\sigma^2} \sum_{i=1}^m (\gamma_i^{(2)} - \mu_i)^2 + \ln \gamma(2)$$

verhodnost' ronice nenož' esistují analytiké řešení, pro některou 'MLE' je minimem, když pro funkci γ je ℓ propojeném log. verhodností

pro odhad (μ, σ^2) je základní $\hat{\gamma}^{(2)} = (\gamma_1^{(2)}, \dots, \gamma_m^{(2)})^T$, když

$$\begin{aligned}\hat{\beta}^{(2)} &= (\mathbf{x}^T \mathbf{x})^{-1} \mathbf{x}^T \hat{\gamma}^{(2)} \\ \hat{\sigma}^2 &= \frac{1}{m} \sum_{i=1}^m (\gamma_i^{(2)} - \hat{\gamma}_i^{(2)})^2, \quad \hat{\gamma}_i^{(2)} = \mathbf{x}_i^T \hat{\beta}^{(2)} \\ &= \frac{1}{m} \hat{\gamma}^{(2)T} (\mathbf{I}_m - \mathbf{H}) \hat{\gamma}^{(2)}\end{aligned}$$

dosazením do ℓ dosloveně i jí' hodnota maximalizovaná vzhledem
k (μ, σ^2) , tzn. profile log-likelihood

$$\begin{aligned}\underline{\ell_F^{(2)}} &= -\frac{m}{2} \ln 2\pi - \frac{m}{2} \ln \hat{\sigma}^2 - \frac{m}{2} + \ln \gamma(2) = \\ &= C - \frac{m}{2} \ln \hat{\sigma}^2 + (2-1) \sum_{i=1}^m \ln \gamma_i\end{aligned}$$

Pozn.: kvůli komplikované' struktuře ℓ_F ne je možné trénovat
numerické metody pro maximizaci
bez přejetí do formy, když lze mít využít metody LR

$$\ell_F^{(2)} = C - \frac{m}{2} \ln \hat{\sigma}^2 - \frac{m}{2} \ln \gamma(2) = C - \frac{m}{2} \ln \frac{\hat{\sigma}^2}{(\gamma(2))^2}$$

$$(\gamma(2))^{\frac{1}{m}} = \left[\left(\prod_{i=1}^m \gamma_i \right)^{\frac{1}{m}} \right]^{2-1} = (\bar{\gamma})^{2-1} \quad \text{kde je ji geometrický průměr}$$

$$\text{Ne: } \underline{\ell_F^{(2)}} = C - \frac{m}{2} \ln \frac{\hat{\sigma}^2}{[(\bar{\gamma})^{2-1}]^2} = \underline{C - \frac{m}{2} \ln D_2}$$

$$\text{Kde: } D_2 = \frac{\hat{\sigma}^2}{[(\bar{\gamma})^{2-1}]^2} = \frac{1}{m} \sum_{i=1}^m \left(\frac{\gamma_i^{(2)}}{(\bar{\gamma})^{2-1}} - \frac{\bar{\gamma}^{(2)}}{(\bar{\gamma})^{2-1}} \right)^2$$

Nun. $\hat{\sigma}_2^2$ ist residuale' varianz ohne σ^2 (SSE) \approx moldele

$$\frac{\gamma^{(2)}}{(j)^{2-1}} \sim \text{residuale' na } X_i^T$$

(Nun. $\hat{\sigma}_2^2$ ist moldele schat' groen' brule lnt.)

$$\text{ellen: max. } l_F(\lambda) \Leftrightarrow \min \hat{\sigma}_2^2$$

Algorithmus:

1) moldele obekt horst λ , $I = \langle \lambda_{\min}, \lambda_{\max} \rangle$, a bely $\lambda \in I$

(typisch $I = \langle -2, 2 \rangle$ a 10-20 normale' moldele obekt)

2) moldele moldele $\frac{\gamma^{(2)}}{(j)^{2-1}} \sim x$ a moldele $\frac{1}{n} \text{SSE} = \hat{\sigma}_2^2$

3) a groen $(\lambda, \hat{\sigma}_2^2)$ gegen $\hat{\lambda}$, dann' minimisirige $\hat{\sigma}_2^2$

4) pro moldele' $\hat{\lambda}$ moldele moldele $\gamma^{(\lambda)} \sim x$ a groen' moldele' analysis

IS pro 2:

Moldele obekt obekt LRT ist pro 1st $H_0: \lambda = \lambda_0$

($H_0: \lambda = 1$ ist obekt transforme, probt zomme $H_0 \Rightarrow$ transforme groen' λ)

$$\text{LRT statistik} \Lambda = -2 \ln \frac{L(\lambda_0)}{L(\hat{\lambda})} = 2(l_F(\hat{\lambda}) - l_F(\lambda_0))$$

$$\text{wir} \quad \Lambda \stackrel{L}{\rightarrow} \chi^2(n)$$

involutiv' proprie' obekt LRT ist, dorthomme as. $100(1-\alpha)\%$ IS pro 2

$$\Lambda \leq \chi^2_{1-\alpha}$$

$$2 \left(\frac{m}{2} \ln \hat{\sigma}_{20}^2 - \frac{m}{2} \ln \hat{\sigma}_2^2 \right) \leq \chi^2_{1-\alpha}$$

$$m \ln \frac{\hat{\sigma}_{20}^2}{\hat{\sigma}_2^2} \leq \chi^2_{1-\alpha}$$



$$\left\{ 2 \in \mathbb{R} \mid m \cdot \ln \frac{\hat{\sigma}_{20}^2}{\hat{\sigma}_2^2} \leq \chi^2_{1-\alpha}(n) \right\}$$

P024: Když je jednoduchá interpretace ve vztahu deformující závislosti i na nejblíže $\frac{1}{4}$ nebo $\frac{1}{3}$.

(103)

Ově. dle TREES

Transformace nezávislých proměnných x

- pokud diagnostiche modelu naznačuje, že vztah mezi y a x není 'lineární' pro jeden nebo více regresorů, může být vhodné 'transformovat' model pomocí 'transformací' proměnných x
- příkl., když je model $y = \beta_0 + \sum_{j=1}^m \beta_j x_j + e$ nelineární nebo 'lineární' x_j
- jednou z možností je postupem je nahoru x_j pomocí $R_j = f(x_j)$, model tedy bude $y = \beta_0 + \beta_1 x_1 + \dots + \beta_{j-1} x_{j-1} + \beta_j R_j + \dots + \beta_m x_m + e$
- pokud je f 'lineární', jedná se o model LR a lze ho analyzovat standardně
pokud je když transformace vhodná, může být už projekce nezávislosti jeho je R^2, L, F a slepěném zdrobu reziduum' pro R_j správné i pro x_j
- buďžel f něčím máma' něčemu', můžeme použít neparametrické metody funkcií a pak odhadnout tyto parametry uplatnit $\hat{\alpha}$
- Typické parametrisace: $R_j = x_j^2$, $j \in \mathbb{N}$ vzhled
($x_j > 0$ pak $j \in \mathbb{N}$, když x_j může být i negativní, můžeme hodit $j \in \mathbb{Z}$)
- apřesněji f pomocí polynomu vzhledu stupňu, tzn.
 $R_j = \sum_{k=1}^l r_k x_j^k$, kde r_k jsou' vždy oddolný vzhled' modelu abu když připadne zcela lineární
je parametry β_j $j=0, \dots, m$ a r_k , $k=1, \dots, l$

- další možností je použít trigonometrické funkce
nebo splines (piecewise polynomials)

(104)

Zámerové rovny $x_j = x_j^2$:

- model je ojet možit jistou množinu \hat{x} , vlastní modely pro všechny \hat{x}
a výběr modelu → nejlepší shoda → dle R^2 , např. → nejméní SSE
nebo největší R^2 mezi F
- může být výsledek nerozložitelný, můžeme minovat shodou horizontu \hat{x} ,
pokud můžeme v původní množině (než má R^2, F, SSE rozdíl mezi \hat{x})

BOX - TIDWELL metoda

příkl., že x je příliš velký od $x=1$, Taylorovo rozvoj 1. řádu

hodnot $x=1$ dle:

$$x^2 \approx x^1 + (x-1) \frac{dx^2}{dx} \Big|_{x=1}$$

$$\frac{dx^2}{dx} = x^2 \ln x \quad \text{a} \quad \frac{dx^2}{dx} \Big|_{x=1} = x \ln x$$

$$x^2 \approx x + (x-1) \times \ln x$$

dovolení do modelu

$$Y = \beta_0 + \beta_1 x_1 + \dots + \beta_{j-1} x_{j-1} + \beta_j (x_j + (x-1) x_j \ln x_j) + \dots + \beta_m x_m + e$$

$$= \beta_0 + \sum_{k=1}^m \beta_k x_k + \underbrace{\beta_j (x-1) x_j \ln x_j}_{\beta_{m+1}(x)} + e$$

máme lineární model → pro β_l parametry β_l , $0 \leq l \leq m+1$

protože $\beta_{m+1} = (x-1)\beta_j$ můžeme (β_j, β_{m+1}) odhadnout následovně:

- 1) vlastní původní model a srovnání LSE $\hat{\beta}_j$ parametru β_j
- 2) vlastní rozšířený model → $x_{m+1} = x_j \ln x_j$ → srovnání $\hat{\beta}_{m+1}$
- 3) → rovnob.: $\hat{\beta}_{m+1} = (\hat{x}-1)\hat{\beta}_j$ dokládáme $\hat{x} = \frac{\hat{\beta}_{m+1}}{\hat{\beta}_j} + 1$

Některé postupy uvažují testování podležitosti transformace

(105)

$$\underline{H_0 : \lambda = 1} \quad \times \quad H_1 : \lambda \neq 1$$

pomocí 1-testu pro $\underline{H_0 : \beta_{m+1} = 0}$

moží být $(1-\alpha) \cdot 100\%$ pravděpodobnost, že postupem

Počínaje počítaný model náleží vypočítané modelové hodnotě, tzn. postupem iterací až k posl. $\hat{\lambda}(l)$, $l \geq 1$

$\hat{\lambda}(0) = \hat{\lambda}$ a rozvinuté x_j^2 bude $\hat{\lambda}(0)$, tzn.

$$x_j^2 \approx x_j^2 - \hat{\lambda}(0) x_j + (2 - \hat{\lambda}(0)) x_j \ln x_j$$

dosazení do nového modelu

$$y = \beta_0 + \sum_{\substack{j=1 \\ j \neq i}}^m \beta_j x_j + \underbrace{\beta_i \hat{\lambda}(0)}_{\beta_{m+1}} + \underbrace{\beta_i (2 - \hat{\lambda}(0)) x_j \ln x_j}_{\hat{\lambda}(0)} + \varepsilon$$

počítání některého modelu je až po pridání "první" $x_{m+1} = x_j \ln x_j$

zm. $\hat{\beta}_j(1)$ a $\hat{\beta}_{m+1}(1)$ přiblíží osoby

$$\text{počítání} \quad \hat{\lambda}(1) = \hat{\lambda}(0) + \frac{\hat{\beta}_{m+1}(1)}{\hat{\beta}_j(1)}$$

může dle iterativní konvergencie někdy znamenat po několika iteracích

Počínaje delší "vzácí" transformací x, y

a) centrování "první"

$$\underline{x_c} \quad (x_c)_{ij} = x_{ij} - \bar{x}_j \quad i = 1, \dots, m \quad j = 1, \dots, m$$

$$\text{dok. } \bar{x}_j = \frac{1}{m} \sum_{i=1}^m x_{ij} \quad \text{první } j\text{-teh}\}$$

$$y_c \quad (y_c)_i = y_i - \bar{y}$$

$$1) \hat{\beta}_1, \dots, \hat{\beta}_m \text{ je řešení } (\underline{x_c}^T \underline{x_c}) \begin{pmatrix} \hat{\beta}_1 \\ \vdots \\ \hat{\beta}_m \end{pmatrix} = \underline{x_c}^T \underline{y_c}$$

$$2) \hat{\beta}_0 = \bar{y} - \sum_{j=1}^m \hat{\beta}_j \bar{x}_j$$

b) centrové a říšové průměry

(106)

říšové slouží když máme typ 1

$$\text{pr. hodnoty pro } j\text{-tý sloupeček} \quad s_{ij} = \left(\sum_{i=1}^n (x_{ij} - \bar{x}_j)^2 \right)^{\frac{1}{2}}$$

centrové a říšové mohou x_{sc} nebo bude

$$x_{sc} = x_c \cdot S, \quad S = \text{diag} \left(\frac{1}{s_1}, \dots, \frac{1}{s_m} \right)$$

mohou sloužit bude

$$(\text{plátno: } \hat{\beta}_0 = \hat{S}^{-1} \hat{B}_c)$$

$$\underline{Y}_c = X_{sc} \beta_0 + \varepsilon$$

ta funkce $\sim x_c$, když centrové a říšové \approx (viz str. 185)

Vážené nejméně čtverec (weighted least squares WLS)

bademe myšlenku, že chyb ε jsou normální, rozdílné, ale $\text{Var}(\varepsilon_i) = \sigma_i^2$ závisí na i

konkrétně: $\varepsilon_i^2 = \frac{\sigma^2}{w_i}$, kde $w_i > 0$, $i = 1, \dots, n$ je
nazýváno váhy

vážené lesky model

$$\underline{Y} = X \beta + \varepsilon, \quad \text{kde} \quad \varepsilon \sim N_n(0, \sigma^2 W) \quad (1)$$

$$\text{kde } W = \text{diag} \left(\frac{1}{w_1}, \dots, \frac{1}{w_n} \right)$$

pokud máme w_i možné, lze MLE odhad pro $\beta = \sigma^2$ nebo říšové:

$$W = K K^T, \quad \text{kde} \quad K = W^{\frac{1}{2}} = \text{diag} \left(\frac{1}{\sqrt{w_1}}, \dots, \frac{1}{\sqrt{w_n}} \right)$$

def.

$$Z = K^{-1} \underline{Y} \quad M = K^{-1} X \quad \sim \quad \varepsilon = K^{-1} \varepsilon$$

durchogene model

$$\underline{Z = M\beta + \varepsilon}, \quad \text{hier } \underline{\varepsilon \sim N(0, \sigma^2 I_m)} \quad (2)$$

$$\text{transf. rechts } \underline{Z = (\sqrt{w_1} Y_1, \dots, \sqrt{w_m} Y_m)^T}$$

polizei ~~Wissen~~

$$\text{Cov}(\varepsilon) = \underline{IK^{-1}\sigma^2 W(IK^{-1})^T} = \sigma^2 IK^{-1}IKIK^T(K^{-1})^T \\ = \sigma^2 I_m$$

Also wir haben 'normalen' model (1), nur Störten 'gleich'

$$\underline{\hat{\beta}_{\text{nr}} = (M^T M)^{-1} M^T Z} = (\underbrace{X^T (K^{-1})^T K^{-1} X}_{\text{WLS estima}})^{-1} \underbrace{X^T (K^{-1})^T K^{-1} y}_y = (\underbrace{X^T W^{-1} X}_{\text{WLS estima}})^{-1} \underbrace{X^T W^{-1} y}_{\text{WLS estima}}$$

$$\underline{\hat{\sigma}_{\text{nr}}^2 = \frac{1}{m} \sum_{i=1}^m (z_i - \hat{z}_i)^2} = \frac{1}{m} \sum_{i=1}^m w_i (y_i - \hat{y}_i)^2 = \frac{1}{m} SSE_{\text{nr}}$$

$\sqrt{w_i} z_i \quad \sqrt{w_i} \hat{y}_i = \sqrt{w_i} \hat{y}_i$

↑
'rechen' nicht 'chancen'

$$\text{plot': } E \hat{\beta}_{\text{nr}} = (X^T W^{-1} X)^{-1} X^T W^{-1} E y = \beta \quad \hat{\beta}_{\text{nr}} \text{ ist 'restung' aller } \beta$$

$= X \beta$

$$E \left(\frac{SSE_{\text{nr}}}{m-m-1} \right) = \sigma^2, \quad \text{hier } \underline{\hat{\sigma}_{\text{nr}}^2 = \frac{SSE_{\text{nr}}}{m-m-1}} \text{ ist 'restung' aller } \sigma^2$$

Neh: Nehst $\hat{\beta}_{\text{nr}}$ ist WLS schätz β , jellhiz $\text{Cov}(\varepsilon) = \sigma^2 W = \sigma^2 \text{diag}(\frac{1}{w_1}, \dots, \frac{1}{w_m})$.

Dann plot':

$$1) \text{ Cov}(\hat{\beta}_{\text{nr}}) = \sigma^2 (X^T W^{-1} X)^{-1}$$

$$2) \text{ resti } \hat{\varepsilon}_i \text{ ist } i\text{-th diag. prod } (X^T W^{-1} X)^{-1}. \quad \text{jellhiz } e_i \sim N(0, \frac{\sigma^2}{w_i}),$$

 $i = 1, \dots, m$, folan

$$T_i = \frac{\hat{\beta}_{\text{nr},i} - \beta_i}{\hat{\sigma}_{\text{nr}} \sqrt{\hat{\sigma}_i}} \sim t(m-m-1)$$

$$3) \text{ Pro } \hat{Y}_{\text{nr}} = X \hat{\beta}_{\text{nr}} \text{ plot': } E \hat{Y}_{\text{nr}} = X \beta \quad \text{a } \text{Cov}(\hat{Y}_{\text{nr}}) = \sigma^2 X (X^T W^{-1} X)^{-1} X^T$$

$$4) \text{ nechti } \hat{\varepsilon}_{\text{nr}} \text{ ist } \hat{Y}_{\text{nr}} - \hat{Y}_{\text{nr}} \text{ jellhiz residue in modeln (1)}$$

$$\text{a } \hat{\varepsilon}_{\text{nr}} = Z - \hat{Z} = Z - M \hat{\beta}_{\text{nr}} \text{ jellhiz residue in transformation modeln (2).}$$

$$\text{Dolom } \hat{\varepsilon}_{\text{nr}} = \sqrt{W^{-1}} \hat{\varepsilon}_{\text{nr}} = W^{-\frac{1}{2}} \hat{\varepsilon}_{\text{nr}} \quad \text{a } E(\hat{\varepsilon}_{\text{nr}}) = E(\hat{\varepsilon}_{\text{nr}}) = 0$$

5) Nechť $H_{\text{nr}} = \mathbf{x}(\mathbf{x}^T \mathbf{W}^{-1} \mathbf{x})^{-1} \mathbf{x}^T \mathbf{W}^{-1}$ je něžné projekční matici. (108)

Fórmula

$$\hat{\epsilon}_{\text{nr}} = (I - H_{\text{nr}}) \mathbf{e} \quad \text{a} \quad \text{Cov}(\hat{\epsilon}_{\text{nr}}) = \sigma^2 (I - H_{\text{nr}}) \mathbf{W}.$$

$$\text{Již známo: } \text{Cov}(\hat{\epsilon}_{\text{nr}}) = \sigma^2 \mathbf{W}^{-\frac{1}{2}} (I - H_{\text{nr}}) \mathbf{W}^{\frac{1}{2}}.$$

$$\text{Dle: 1)} \quad \text{Cov}(\hat{\beta}_{\text{nr}}) = (\mathbf{x}^T \mathbf{W}^{-1} \mathbf{x})^{-1} \mathbf{x}^T \mathbf{W}^{-1} \underbrace{\text{Cov} \mathbf{y} \mathbf{W}^{-1} \mathbf{x}}_{= \sigma^2 \mathbf{W}} (\mathbf{x}^T \mathbf{W}^{-1} \mathbf{x})^{-1} = \sigma^2 (\mathbf{x}^T \mathbf{W}^{-1} \mathbf{x})^{-1}$$

$$2) \quad \text{Var} \hat{\beta}_{\text{nr},i} = \sigma^2 \delta_i, \quad \text{tzn.} \quad \frac{\hat{\beta}_{\text{nr},i} - \beta_i}{\sigma \sqrt{\delta_i}} \sim N(0,1) \quad \text{a. něm., kde}$$

$$\hat{\beta}_{\text{nr},i} \text{ a } D_{\text{nr}} \text{ jin reziduji, } \frac{\sigma^2 (n-m-1)}{\sigma^2} \sim \chi^2(n-m-1)$$

$$\Rightarrow \frac{\hat{\beta}_{\text{nr},i} - \beta_i}{D_{\text{nr}} \sqrt{\delta_i}} \sim t(n-m-1)$$

$$3) \quad E \hat{\gamma}_{\text{nr}} = \mathbf{X} E \hat{\beta}_{\text{nr}} = \mathbf{X} \mathbf{B}, \quad \text{Cov}(\hat{\gamma}_{\text{nr}}) = \mathbf{X} \text{Cov} \hat{\beta}_{\text{nr}} \mathbf{X}^T = \sigma^2 \mathbf{X} (\mathbf{x}^T \mathbf{W}^{-1} \mathbf{x})^{-1} \mathbf{X}^T$$

$$4) \quad \text{protože } Z = \mathbf{W}^{-\frac{1}{2}} \mathbf{y} \quad \text{a} \quad M = \mathbf{W}^{-\frac{1}{2}} \mathbf{x} \quad \text{dostaneme}$$

$$\hat{\epsilon}_{\text{nr}} = Z - \hat{Z} = \mathbf{W}^{-\frac{1}{2}} \mathbf{y} - \mathbf{W}^{-\frac{1}{2}} \mathbf{x} \hat{\beta}_{\text{nr}} = \mathbf{W}^{-\frac{1}{2}} (\mathbf{y} - \mathbf{x} \hat{\beta}_{\text{nr}}) = \mathbf{W}^{-\frac{1}{2}} \hat{\epsilon}_{\text{nr}}$$

$$E \hat{\epsilon}_{\text{nr}} = E(\mathbf{y} - \hat{\beta}_{\text{nr}}) = \mathbf{X} \mathbf{B} - \mathbf{X} \mathbf{B} = 0 \quad \Rightarrow \quad E \hat{\epsilon}_{\text{nr}} = 0 \quad = \mathbf{y}$$

$$5) \quad \hat{\epsilon}_{\text{nr}} = \mathbf{y} - \hat{\beta}_{\text{nr}} = \mathbf{y} - \mathbf{x} \hat{\beta}_{\text{nr}} = \mathbf{X} \mathbf{B} + \mathbf{e} - \mathbf{X} (\mathbf{x}^T \mathbf{W}^{-1} \mathbf{x})^{-1} \mathbf{X}^T \mathbf{W}^{-1} (\mathbf{X} \mathbf{B} + \mathbf{e})$$

$$= \mathbf{X} \mathbf{B} - \mathbf{X} \mathbf{B} + \mathbf{e} - \underbrace{\mathbf{X} (\mathbf{x}^T \mathbf{W}^{-1} \mathbf{x})^{-1} \mathbf{X}^T \mathbf{W}^{-1} \mathbf{e}}_{H_{\text{nr}}} = (I - H_{\text{nr}}) \mathbf{e}$$

$$\text{Cov}(\hat{\epsilon}_{\text{nr}}) = (I - H_{\text{nr}}) \text{Cov} \mathbf{e} (I - H_{\text{nr}})^T = \sigma^2 (I - \mathbf{X} (\mathbf{x}^T \mathbf{W}^{-1} \mathbf{x})^{-1} \mathbf{X}^T \mathbf{W}^{-1}) \mathbf{W} (I - \mathbf{W}^{-1} \mathbf{X} (\mathbf{x}^T \mathbf{W}^{-1} \mathbf{x})^{-1} \mathbf{X}^T)^T$$

$$= \sigma^2 \mathbf{W} - \sigma^2 \mathbf{X} (\mathbf{x}^T \mathbf{W}^{-1} \mathbf{x})^{-1} \mathbf{X}^T - \sigma^2 \mathbf{X} (\mathbf{x}^T \mathbf{W}^{-1} \mathbf{x})^{-1} \mathbf{X}^T + \sigma^2 \mathbf{X} (\mathbf{x}^T \mathbf{W}^{-1} \mathbf{x})^{-1} \mathbf{X}^T$$

$$= \sigma^2 (I - H_{\text{nr}}) \mathbf{W}$$

$$\text{Cov}(\hat{\epsilon}_{\text{nr}}) = \mathbf{W}^{-\frac{1}{2}} \text{Cov}(\hat{\epsilon}_{\text{nr}}) \mathbf{W}^{-\frac{1}{2}} = \sigma^2 \mathbf{W}^{-\frac{1}{2}} (I - H_{\text{nr}}) \mathbf{W}^{\frac{1}{2}}$$

Q.E.D.

- je odvozeného významu, že odchyly $\hat{\epsilon}_i = \hat{y}_i - y_i$ jsou souborem pozitivní transformovaných modelu (2)
- protože ale transformovaný model neobsahuje intercept, (první sloupec M_0 je $(\sqrt{v_{11}}, \dots, \sqrt{v_{nn}})^T$) nefunguje klasický rozkład souboru čísel a F testu obecně nelze def. odchylám spočítat stejně jako R^2 (vii rozdíl mezi počtem souboru pozitivních a negativních)
- němenejší princip „least sum of squares“ funguje až mezi model interceptu nelze ne
- např. celkový F-test lze provést pomocí sloupců.

$$F_{\text{nr}} = \frac{\frac{SSE_R - SSE_F}{m}}{\frac{SSE_F}{R_{\text{nr}}^2}}, \text{ kde } \frac{SSE_F}{R_{\text{nr}}^2} \text{ je residuální sumu čísel čísel a } SSE_R \text{ je rez. o.č. redukovaného transformovaného modelu } Z = M_0 \beta_0 + \hat{\epsilon}, \\ M_0 = (\sqrt{v_{11}}, \dots, \sqrt{v_{nn}})^T$$

pokud muzí být normálně rozdělen, platí pak $H_0: \beta_1 = \dots = \beta_m = 0$,

$$\text{je } F_{\text{nr}} \sim F(m, m-m-1), \quad H_0 \text{ zavíráme pokud } F_{\text{nr}} > F_{\text{pred}}(m, m-m)$$

- Mr. MHD \otimes
- pro analýzu residuů je třeba použít vhodný typ residuů
 - muzí být celkový residuum $\hat{\epsilon}_i \sim$ pravidelný model (1)
 - $\hat{\epsilon}_i \sim$ transformovaný model (2)
 - testy dvou modelů
 - pro hodnotu homoskedastického rozdílu lze použít i standardizované nebo studentizované residua (pomocí korelačních koefficientů, jež jsou v obou modelech stejné)
 - je třeba být opatrný upřižený homoskedastické residua rozložovat

- grobý $\hat{\epsilon}_i$ proti shaperům M a pretilorom' hledanou $\hat{\beta}$
její ok, neboť nejsí.
- $\sum_{i=1}^m \hat{\beta}_{2,i} \hat{\epsilon}_i = 0$ (její ok, něž by byl všechny rovnosti
odděleny o x)
- dovedením $\hat{\epsilon}_i = \sqrt{w_i} \hat{e}_i$ a $\hat{\beta}_i = \sqrt{w_i} \hat{\beta}_i$ dohlede
- $\sum_{i=1}^m w_i \hat{e}_i \hat{\beta}_i = 0$ tzn. grob $\hat{\epsilon}_i$ proti $\hat{\beta}_i$ lze zavést
- grob $\sqrt{w_i} \hat{e}_i$ proti $\sqrt{w_i} \hat{\beta}_i$ je ale v paralelní
- poslední řešení platí i pro grob $\hat{\epsilon}_i$ proti x_j^* , $i=1, \dots, m$
- (*) původně je def. $R^2 = \rho^2(\hat{\beta}, \beta)$, kde $\rho(\hat{\beta}, \beta)$ je
výberový Korelační koeficient, pro $V = I$ dovedene standardní R^2
- Pozn: - pokud je všechny normovány, lze by být že je vlastnost spolehlivé
 $\sigma \hat{\beta} = \sigma^2 \hat{\epsilon}$ dle
- to ale nemá obecně smysl, pokud nemá vše parametry normovány
- měly by mít smysl, pokud máme delší informace o rozdělení
chyb (tvar kovarianční matici, Ω_2, Ω_0)
- Pozn: celý postup WLS je spolehlivý i ve případě $\epsilon \sim N(0, \sigma^2 V)$,
kde V je smysl, ale nemá diagonální
protože V je myšlenka', ex. reg. K lze, že $V = K K^T$
Myšlenka transformace jeho na WLS ještě nedeje na lineární model,
kde $\epsilon \sim N_m(0, \sigma^2 I_m)$.

Korelace a' chyb

111

- sejměm a' círouže mělo ekonomické důležitě v čase odjezd
korelace jenž. hodnot
- pokud nem' výhru předpoklad nezávislosti chyb,
- tento stav je výzva detektovat (někdy používají grafy residuum)
- možnosti pro korelace' data : Analýza círoužek i s tím

Pokud je průběh autokorelace a chyb např. horizontální násobky
grafu :

- 1) OLS odhad $\hat{\beta}$ je nejmenší, ale neplatí Gauss-Markovova věta,
tn. $\hat{\beta}$ nem' nejmenší násobky
- 2) $MSE = \frac{1}{n-m-1} SSE$ (odhad σ^2) může být poškozen méně než
špatná korelace ρ^2 , což může dívat báleční post primost.
- 3) ~ diskusión 2) mohou být zvýšeny korelace T stabilit
takže testy o parametrech a IS nefungují
- 4) pokud je chyb reziduál, $F\text{-test} = 1\text{-test}$ nejsou pravé
platné ani když je chyb normální

DURBIN - WATSON stabilita

omezime se na pozorování základní v čase $t=1, 2, \dots, n$ a připomí
me chyb je výhru působení autoregresivního procesu 1. řádu (AR(1)),

$$\tilde{e}_t = \rho e_{t-1} + u_t, \quad |\rho| < 1$$

ρ je autokorelační koeficient, $u_t \sim N(0, \sigma^2)$ je reziduál $t=1, \dots, n$
a u_t je reziduál na ex. $t \geq 1$

cílem je pro data círoužit násobky $\rho > 0$ (pozitivní autokorelace)

pro Test $H_0: \rho = 0 \times H_1: \rho > 0$ n. zweiseitig

Durbin-Watson Maßzahlen

$$d = \frac{\sum_{k=2}^n (\hat{e}_k - \hat{e}_{k-1})^2}{\sum_{k=1}^n \hat{e}_k^2}, \text{ falls } \hat{e}_k \text{ gemischte modelle LR}$$

geht aus H_0 , ob die \hat{e}_k gemischte modelle LR
 $\hat{\rho} = \frac{\sum_{k=2}^n \hat{e}_k \hat{e}_{k-1}}{\sum_{k=2}^n \hat{e}_k^2}$

PoZV: da' es unbeschr., si' $d \approx 2(1-\hat{\rho})$

$$\begin{aligned} \sum_{k=2}^n (\hat{e}_k - \hat{e}_{k-1})^2 &= \sum_{k=2}^n \hat{e}_k^2 + \sum_{k=2}^n \hat{e}_{k-1}^2 - 2 \sum_{k=2}^n \hat{e}_k \hat{e}_{k-1} \approx \\ &\approx 2 \left(\sum_{k=2}^n \hat{e}_k^2 - \sum_{k=2}^n \hat{e}_k \hat{e}_{k-1} \right) \end{aligned}$$

Cochrane-Schwarz'sche normiert = $\frac{\sum_{k=2}^n \hat{e}_k \hat{e}_{k-1}}{\sum_{k=2}^n \hat{e}_k^2}$ der pribilis ~ (-1,1)

Nun. d der pribilis ~ (0,4)

$\hat{\rho} \approx 1 \Rightarrow d \approx 0 \quad \hat{\rho} \approx 0 \Rightarrow d \approx 2$ N. pro mali'

horribly ρ d bedene zweiseitig H_0 , pro welche' bedene zweiseitig
 - horribly' horribly' weine' Durbin-Watson' gemischte modelle'

- TEST:
- 1) spezifiziert horribly d
 - 2) messen horribly' (d_L, d_U) pro dase' in a m+1
 - 3) a) zweiseitig H_0 , geht $d < d_L$
 - a) zweiseitig H_0 , geht $d > d_U$
 - c) pro $d_L < d < d_U$ test nerwosthetre

PoZV: pro Test $H_0: \rho = 0 \times H_1: \rho < 0$ der zweit wichtig' test pro $d' = 4-d$

metode pro horribly' anhabeuren: Cochrane-Orcutt