

## Výběr regresního modelu

(113)

- budeme se zabývat výběrem nejdostupnějšího mno. regresoru
- řešme 3 specifické modely (použití jiného než shantečného modelu) máme dva hlavní důvodky:
  - 1) při srovnání několika proměnných modelu, jsou odhady par. ohledně proměnných významené
  - 2) pokud je ~ model příliš mnoho proměnných, jsou obecně rozdíly odhadů pro ostatní "promenne" velké  
(výběr modelu: Model -> menší významnost a přesnost)
- volba „nejlepšího“ modelu je zdešním kompromisem mezi dvěma kritérii
  - a) přesnost modelu
  - b) jednoduchost modelu  
(počtem proměnných)

(- ideální model by měl mít nejméně možnou pогel regresoru;  
také umožňuje adekvátní interpretaci (nebo predikci))
- obvykle neexistuje jednoznačný nejlepší model ani jednomocné statistické procedure, jež ho najde

Pozn.: důležitý významní proměnný je shantečný, ~ buďto nezávislé, model

$$\text{předk. } \gamma_1 = X\beta + \epsilon \quad (\text{tvar model}) \quad \text{a} \quad \beta = (\beta_1^T, \beta_2^T)^T$$

$$\beta_1 = (\beta_0, \dots, \beta_2)^T, \quad \beta_2 = (\beta_{2+1}, \dots, \beta_m)^T$$

problem bei regral  $\mathbf{X} = [X_1 \ X_2] \sim$  model mit Resty (114)

aber

$$Y_i = X_1 \beta_1 + X_2 \beta_2 + \epsilon \rightarrow \hat{\beta} = (X^T X)^{-1} X^T Y$$

reduzierend' model  $Y_i = X_1 \beta_1 + \epsilon \rightarrow \hat{\beta}_1 = (X_1^T X_1)^{-1} X_1^T Y$

- wäre, sei  $\hat{\beta}$  'ji' reduzierend' o. k., als  $\hat{\beta}_1$  'ji' non-reduzierend' o. k.

$$E \hat{\beta} = (X_1^T X_1)^{-1} X_1^T E \epsilon = \beta_1 + (X_1^T X_1)^{-1} X_1^T X_2 \beta_2 = \beta_1 + A \beta_2$$

$\Downarrow$

$$X_1 \beta_1 + X_2 \beta_2$$

denn  $A \neq 0$ , thie  $E \hat{\beta}_1 \neq \beta_1$

- pro reduz. gelt.  $Cov(\hat{\beta}_1) = \sigma^2 (X_1^T X_1)^{-1}$   $Cov(\hat{\beta}_2) = \sigma^2 (X_2^T X_2)^{-1}$

o. k.  $\hat{\beta}_1^*$  LSE  $\beta_1 \sim$  model  $\Rightarrow \hat{\beta} = \begin{pmatrix} \hat{\beta}_1 \\ \hat{\beta}_2 \end{pmatrix}$

da 'ji' reduz.  $Cov(\hat{\beta}_1^*) - Cov(\hat{\beta}_1)$  'ji' PSD, da 'ji'

reduz.  $\hat{\beta}_1^*$  bilden obere rekt. non-reduz.  $\hat{\beta}_1$

reduz. 'ji' primitiv' mojus' primor' o. k.  $\hat{\beta}_1, \dots, \hat{\beta}_r$

- prediktorone' horizont  $\hat{Y} = H_1 Y \quad \hat{F}_1 = H_1 Y$

$$E \hat{Y}_1 = H_1, E Y = H_1 (X_1 \beta_1 + X_2 \beta_2) = X_1 \beta_1 + X_1 A \beta_2 \quad \text{#M104000}$$

$\Downarrow$

$$X_1 (X_1^T X_1)^{-1} X_1^T$$

pro  $A \neq 0$  'ji'  $\hat{Y}_1$  'ji' reduz. o. k.

Kriteria pro ~~reduz.~~ modell

präzessione, 'ji' main & distorsion T primitiv (regression)  
rekt. interess


a. unzügige postunzüg. T primitiv (rekt. interess.)  
 $(T = m+1)$

# A) koeficient racionální determinace $R^2$

$$R^2_F = \frac{SSR_F}{SST} = \frac{\sum_{i=1}^n (\hat{y}_i - \bar{y})^2}{\sum_{i=1}^n (y_i - \bar{y})^2} = 1 - \frac{SSE_F}{SST}$$

- při použití je třeba si uvědomit, že  $R^2_F$  je racionální funkce počtu regresorů ( $SST$  je konst.), tedy maximální hodnota pro  $F=1$
- klesající klesající model ne dlejší pohled na danou regresoru ne odpovídá postupnosti minimu  $R^2_F$
- vztah je používán


$$\bar{R}^2_F = 1 - \frac{\frac{SSE_F}{n-1}}{\frac{SST}{n-1}}$$



## B) (R) MSE

$$MSE_F = \frac{SSE_F}{n-1} = \beta_m^2$$

$$RMSE_F = \beta_m$$



## C) F-test pro možné modely

pro  $X = (X_1, X_2)$      $\beta = \begin{pmatrix} \beta_1 \\ \beta_2 \end{pmatrix}$     umímá dležitou

$$H_0: \beta_2 = 0 \quad \text{přímo F test}$$

extra sum of squares princip

R: anova( ) : porovnává možnosti modelů  
více než pouze v jeho průběhu  
regresory do modelu

# D) Mallows C<sub>p</sub>, AIC, DIC

116

- hledání lepšího modelu → sice s použitím regresionů
- lze ji použít i pro nevypočítatelné modely!

## Mallows C<sub>p</sub>

$$C_p = \frac{SSE_f}{\hat{\sigma}^2} - n + \frac{2p}{n-p}$$

$$\hat{\sigma}^2 = \frac{SSE_f}{n-p}$$

penalizace

Vlastnosti C<sub>p</sub>: 1) model se posílí, SSE<sub>f</sub>,  $\hat{\sigma}^2$  inšpanované'

2) pokud je  $\hat{\sigma}^2$  konstantní vzhledem k  $\hat{\sigma}^2$  (nezávislostí na  $x$ )  
me' C<sub>p</sub> nezávislým interpretací:

porovnání s obecnou vyučitelnou proměnnou modelu  $\Rightarrow$   $n-p$  parametry  
zvyšující pravděpodobnost další generativní pravděpodobnosti  
modelu je třeba odhadnout

3) při výpočtu počtu regresionů

$\hat{\sigma}^2$  je konst., SSE<sub>f</sub> stejný,  $n-p$  roste  
(C<sub>p</sub> se může dle dlejších kritérií zlepšit)


4)  $C_p = T$

5) pokud je správný model s  $T$  parametry, dole neukazuje, že

$$C_p \approx T \text{ pro } n \rightarrow T$$

6) v praxi se vždy model s nejmenším C<sub>p</sub> ne zlepší modelu  
zlepšující C<sub>p</sub> = T

Pozn.: nejhodnota - pro další interpretaci  
je třeba spočítat C<sub>p</sub> pro všechny mnoho  
velikostí počtu regresionů



Bohužel případ místního 'dobre' modelu

# Abschätzen informativer Kriterium AIC

117

obere' definie si k

$$\underline{AIC = -2\ell(\hat{\theta}) + 2f^*}$$

pro mes' model LR

$$L(\beta, \sigma^2) = \frac{1}{(2\pi\sigma^2)^{\frac{n}{2}}} e^{-\frac{1}{2\sigma^2}(\gamma - X\beta)^T(\gamma - X\beta)}$$

$$\ell(\beta, \sigma^2) = -\frac{n}{2} \ln 2\pi - \frac{n}{2} \ln \sigma^2 - \frac{1}{2} \frac{(\gamma - X\beta)^T(\gamma - X\beta)}{\sigma^2}$$

$$AIC = -2\ell(\hat{\beta}, \hat{\sigma}^2) + 2f^* = n \ln 2\pi + n \ln \hat{\sigma}^2 + \frac{(\gamma - X\hat{\beta})^T(\gamma - X\hat{\beta})}{\hat{\sigma}^2} + 2f^*$$

$$\text{ale } \hat{\sigma}^2 = \frac{1}{n} \sum (\gamma - X\hat{\beta})^T(\gamma - X\hat{\beta}) \stackrel{\text{SSE}}{=} \frac{\text{SSE}}{n} \text{ kdy}$$

$$\underline{AIC = \underbrace{n \ln 2\pi + n}_{C} + n \ln \frac{\text{SSE}}{n} + 2f^*}$$

$$\text{alternativ: } \underline{AIC = n \ln \frac{\text{SSE}}{n} + 2f^*}$$

- POZN:
- bleskane model s minimální hodnotou AIC
  - AIC nen' minimální hodnota modelu, je výše pro porování modelů

$$AIC \sim R: \quad \underline{AIC(-)} \quad \text{počtu' } \underline{n \ln 2\pi + n + n \ln \frac{\text{SSE}}{n} + 2f^*}$$

druhé f\* je proč.  $\beta, \sigma^2$  (větší interpret)

$$\underline{\text{extrakt AIC}(-)} \quad \text{počtu' } \underline{n \ln \frac{\text{SSE}}{n} + 2f^*}$$

f\* je jen proč.  $\beta$  (větší interpret)

$\hat{\beta}$  je MLE odhadu v modelu  
 $\ell$  je log-verbal funkce  
 $f^*$  - počet par., které ji  
 můžete odhadnout  
 $(\cdot)$ : ( $f^* = k+1$ )  
 variáns =  $\sigma^2$

- (Schwarzov) bayesovské informační kritérium BIC

$$\underline{BIC = -2\lambda(\hat{\theta}) + f^* \ln n}$$

více penalizuje počet parametrů  $\Rightarrow$  výběr jednoduchých modelů  
 $\Rightarrow$  jednoduché interpretaci než AIC

BIC vyžaduje významný příspěvek promenne', aby byla rozložena do modelu

(AIC je závislý na predikci, BIC je bezvýznamné než interpretovatelnost a predikci)

R: BIC(.), nebo AIC(.), extern AIC(.) ? volba

$$\lambda = \log(n) \text{ols}(fit)$$

Pr. dle HALD

### E) PRESS statistika

pokud je pro nás dôležité kvalita predikce, tzn. počet po  
nešovných modelů statistiky

$$\underline{PRESS = \sum_{i=1}^n \hat{e}_{(i)}^2 = \sum_{i=1}^n \left( \frac{\hat{e}_i}{1-h_{ii}} \right)^2}$$

výběr se modelu  $\rightarrow$  minimální hodnota této statistiky

### Metryky výběru modelu

#### 1) Vyhodnocení výběru mnoha modelů

pro T doložující regresoru tzn. mohou být  $T$  modelů

- pokud je počet promen' výše kritériu

- možnosti pro výběr T (např. T=20 máme 1024 modelů!)

## 2) Zpětné eliminace (backward elimination)

(119)

zadání → složitý model a v horším směru odstraňování jednotlivých proměnných, které nejsou přispívají modelu (metr F stat.) nebo jejich odstraněním modelu nepřináší lepší model (metr AIC)

algoritmus:

- 1) vložit do modelu všechny proměnné
- 2) pro horšší proměnnou uplatnit kritérium F statistiky  
(nebo AIC-statistiky) jehož by měly být přidány do modelu  
(tzn. nejvýplňovanější, nejvýznamnější z nich)  
ještě ~~ještě~~, vynutí se modelu proměnné s nejvýšší hodnotou F
- 3) pokud je nějaký F statistiky menší než kritická hodnota F<sub>krit</sub>  
( $F_{krit} = F_{1-\alpha_{krit}}(1, n-1)$ , kde  $\alpha$  je odstoupení pravděpodobnosti)  
regresoru → model, včetně interceptu,  $\alpha_{krit} = 0,05, 0,1, \dots$
- 4) opakovat krohy 2) a 3) dokud všechny kritérium F statistiky nejsou všechny menší než kritická kritická hodnota F<sub>krit</sub>  
(tzn. nejsou vložit žádat proměnné)

Pozn. místo F lze použít AIC

## 3) Doplňková regrese (forward regression)

zadání poskyt → intercept (nebo nultý minimální model)

a v horším směru přidání jedné proměnné, která nejsou vloženy do modelu nejdříve lepší modelu

(nejdříve vložit F nebo nejdříve podle AIC)

- když modelu nezmění žádat proměnnou, kterou si do modelu bude jednou přidávat

## algoritmus:

(120)

- 1) náležitý minimální model
- 2) pro horším dohlednou proměnnou systému F schätzbar  
pro test významnosti jejího přidání do modelu
- 3) pokud nízký a lehký F schätzbar přehořuje  
kritickou hodnotu  $F_{\text{cr}}$ , přidání do modelu proměnnou  
a nejvyšší hodnota F velká.
- 4) opakování kroků 2) a 3) dokud všechny F-něl. nebudou  
menší než  $F_{\text{cr}}$  nebo dokud nedojde žádoucí proměnné  
ne přidání do modelu

Pozn. i když tento postup sjednocuje různé modely, často  
bohužel vede ne zározeným proměnným, které nemají  
významný příspěvek, jenomže jiné zározeny další proměnné

## 4) Backwards' regrese (stepwise regression)

komplexe dom předchozích metod, v horším hledu algoritmus  
přidává jednu proměnnou a poté sjednocuje, takže nemá  
možné nejúčinnější odstranit  
takto potřebujete dvě kritické hodnoty  $F_{\text{cr}}$ ,  $F_{\text{out}}$  - pro posílení  
F schätzbar

## algoritmus:

- 1) náležitý minimální model
- 2) sjednocí, že přidání ~~ještě~~ nejúčinnější dala proměnné  
může zlepšit model ( $F$  nebo AIC), pokud ani přidání  
do modelu proměnnou, která má se modelu nejvíce  
zlepšit model (negativní hodnota AIC)
- 3) v novém modelu sjednocí, že některé méně účinnou

vynechel (opět pomocí AIC nebo F), pokud ano,  
vynechte pomocí, ježíž vyřízení má' ze všech  
největší zlepšení možné (největší zlepšení AIC)

4) obehajte body 21 a 22 do le'doly, až nebudete moci' přejít ~~am~~ užrat zákon proměna

## Po2K: Price marginality

- pokud jin  $\rightarrow$  modelu výplní možnost někoho regresoru, měly by tomu být ohruzeny i všechny jeho níže vedené (  $\rightarrow$  když jin připadne nejpravděpodobnější)
  - pokud ji  $\rightarrow$  modelu ohruzené interakce dveře regresorů, měly by tomu být i oba individualní regresory
  - $\rightarrow$  horizont interakční výplňka říká, že měl model ohruzenou všechny interakce říká níže  
 $\rightarrow$  všechny interakce říká níže  
 $(a:b:c \rightarrow a:b, a:c, b:c)$

Pozitiv: John'sche no lessere optimale' model, je mehr reale  
overfit jene aderhaltung